
논문을 읽기 위한 통계 최단 학습 경로

의생명과학프로그래밍 2~14주차 통계 기법 통합 정리

고등학생 수준 설명 + 수식 완전 해부 + 문제와 즉시 정답

이 자료의 원칙

- 쉽게 쓰되 **개념을 바꾸지 않는다**. 정의는 교과서 정의 그대로 쓴다.
- 수식은 피하지 않는다. 대신 **기호 하나하나가 무엇인지** 전부 풀어 쓴다.
- 14개 기법을 따로 외우지 않는다. **하나의 뼈대**에 전부 매단다.
- 모든 문제의 정답은 **문제 바로 아래**에 있다.

Contents

1	먼저 지도를 본다	4
1.1	이 자료를 쓰는 방법	4
1.2	최단 경로 지도	4
1.3	STEP 1. 모든 것의 뼈대	5
1.3.1	모집단과 표본 — 통계가 존재하는 이유	5
1.3.2	평균, 분산, 표준편차	5
1.3.3	표준오차 — 이 자료에서 가장 중요한 개념	6
1.3.4	중심극한정리 — 왜 정규분포가 계속 나오는가	7
1.3.5	p 값 — 정확한 정의	7
1.3.6	신뢰구간	8
1.3.7	두 종류의 오류와 검정력	8
2	2주차·자료를 진단한다	10
2.1	왜 필요한가	10
2.2	기술통계 — 분포를 네 가지로 요약한다	10
2.3	Q-Q plot — 정규성을 눈으로 보는 법	11
2.4	Shapiro-Wilk 정규성 검정	12
2.5	Levene 등분산 검정	13
2.6	로그변환 — 근거를 알고 쓰기	13
2.7	복합표본 가중치 — NHANES를 쓸 때 반드시 필요한 것	14
3	3주차·두 군을 비교한다	17
3.1	독립 2표본 t 검정 (pooled)	17
3.2	Welch 검정 — 등분산을 가정하지 않는다	18
3.3	대응 t 검정 — 짝지어진 자료	19
3.4	효과크기 — p 값이 말해 주지 않는 것	19
3.5	Wilcoxon 순위합 검정 — 무엇을 검정하는가	20
3.6	순열검정 — 분포 가정을 아예 없애는 법	21
4	4주차·여러 군을 비교하고, 여러 번 검정한다	24
4.1	일원분산분석 — 변동을 두 조각으로 쪼갬다	24
4.2	Welch ANOVA와 Kruskal-Wallis	25
4.3	경향성 검정 — 순서가 있는 군	25
4.4	다중비교 — 이 장의 핵심	26
4.4.1	문제의 크기	26

4.4.2	두 가지 다른 오류 기준	27
4.4.3	Bonferroni 보정	27
4.4.4	Benjamini-Hochberg (BH) 절차	27
4.5	Tukey HSD 사후검정	28
5	5주차 · 범주형 자료와 분할표	31
5.1	2×2 분할표의 표준 표기	31
5.2	카이제곱 검정	31
5.3	오즈비와 상대위험 — 논문에서 가장 많이 혼동되는 것	32
5.4	Fisher 정확검정	33
5.5	McNemar 검정 — 짝지어진 범주형 자료	34
5.6	Rao-Scott 보정 — 복합표본에서의 χ^2	35
6	6주차 · 상관, 회귀, 그리고 일치도	38
6.1	Pearson 상관계수	38
6.2	단순 선형회귀와 다중 선형회귀	38
6.3	다중공선성과 VIF	39
6.4	급내상관계수 (ICC)	40
6.5	Bland-Altman — 이 장의 핵심	40
7	7주차 · 로지스틱 회귀와 진단 성능	44
7.1	로지스틱 회귀 — 왜 로짓인가	44
7.2	최대우도추정과 우도비 검정	45
7.3	진단 성능 — 2×2 로 돌아간다	46
7.4	ROC 곡선과 AUC	46
7.5	보정(Calibration)과 순이익(Net Benefit)	47
8	8·9주차 · 확률을 직접 계산한다	51
8.1	Fisher 정확검정을 손으로 열거하기	51
8.2	mid- p — 보수성을 절반만 걷어내기	52
8.3	몬테카를로 오차 — 반복을 몇 번 해야 하는가	52
8.4	검정력 — 9주차의 중심	53
8.5	음성대조와 모의실험 설계	55
9	10주차 · 부트스트랩	58
9.1	왜 부트스트랩인가	58
9.2	신뢰구간 5종	59
9.3	피복확률 — 신뢰구간을 평가하는 방법	60
9.4	역확률가중(IPW) — 부트스트랩이 필요한 대표 상황	61

10 11주차 · 생존분석	64
10.1 절단(censoring) — 생존분석이 따로 존재하는 이유	64
10.2 Kaplan–Meier 추정	65
10.3 Log-rank 검정	66
10.4 Cox 비례위험모형	66
10.5 비례위험 가정의 검정 — Schoenfeld 잔차	67
10.6 제한 3차 스플라인 — 선형성 가정을 푸는 법	67
11 12주차 · 교란을 보정한다	71
11.1 교란이란 무엇인가	71
11.2 성향점수	72
11.3 짝짓기와 역확률가중 — 두 가지 사용법	72
11.4 균형 평가 — 표준화 평균차	73
11.5 E-value — 미측정 교란에 대한 정직한 답	74
12 13주차 · 여러 연구를 하나로 합친다	77
12.1 역분산 가중 — 메타분석의 핵심 한 줄	77
12.2 이질성 — 연구들이 정말 같은 것을 재고 있는가	78
12.3 랜덤효과 모형	78
12.4 베이지안 계층모형과 축소	80
12.5 사후분포를 계산하는 두 방법	81
13 14주차 · 재현하고, 교차검증하고, 통합한다	85
13.1 전체 통합 — 한 장으로 보는 개념 지도	85
13.2 재현이 안 될 때 — 원인 규명의 순서	86
13.3 인공지능이 통계 코드에서 실제로 범하는 오류 목록	86
13.4 최종 문제 — 전 과정 통합	87
13.5 최단 경로 요약 — 이 자료를 한 페이지로	89

먼저 지도를 본다

1.1 이 자료를 쓰는 방법

강의계획서에는 2주차부터 13주차까지 서로 다른 이름의 통계 기법이 수십 개 나옵니다. Shapiro-Wilk, Levene, Welch, Kruskal-Wallis, Rao-Scott, Bland-Altman, Youden, BCa, Schoenfeld, E-value... 이름만 보면 전부 다른 세계 같습니다.

그런데 사실은 그렇지 않습니다. 이 기법들은 거의 전부가 딱 하나의 문장을 변형한 것입니다.

이 자료 전체를 관통하는 한 문장

$$\text{검정통계량} = \frac{\text{내가 본 신호}}{\text{그 신호가 우연히 흔들리는 정도}}$$

분자가 **효과(effect)**, 분모가 **표준오차(standard error)**입니다. 2주차의 *t*부터 13주차의 메타분석까지, 이름만 바뀔 뿐 구조는 이것입니다.


이 자료는 이 한 문장을 먼저 완전히 이해시킨 뒤(0장), 주차별로 그 문장의 어느 부분이 어떻게 바뀌는 지만 추가합니다. 그래서 학습량이 14개가 아니라 사실상 1개 + 알파가 됩니다. 이것이 **최단 경로**입니다.

각 절은 다음 순서로 되어 있습니다.

1. **왜 필요한가** — 이 기법이 없으면 논문에서 무엇을 못 읽는지
2. **핵심 수식** (파란 상자) — 정의 그대로, 축약하지 않은 형태
3. **수식 뜯어보기** — 기호 하나하나가 무엇을 뜻하는지
4. **예시** (초록 상자) — 손으로 계산되는 작은 숫자
5. **문제**(주황 상자)와 **정답**(바로 아래)
6. **연결고리** (보라 상자) — 다른 주차와 어떻게 이어지는지

1.2 최단 경로 지도

강의는 2주차부터 13주차까지 순서대로 나가지만, **개념의 논리적 순서**는 조금 다릅니다. 아래가 최단 경로입니다. 이 순서대로 읽으면 뒤 내용이 앞 내용의 반복으로 느껴집니다.



1.3 STEP 1. 모든 것의 빠대

1.3.1 모집단과 표본 --- 통계가 존재하는 이유

모집단(population)은 우리가 진짜 알고 싶은 전체 집단입니다. 예를 들어 “대한민국 성인 전체의 평균 허리둘레”. 하지만 5,000만 명을 다 잴 수는 없습니다. 그래서 **표본(sample)**을 뽑습니다. 예를 들어 NHANES에서 5,000명.

여기서 통계학의 유일한 문제가 생깁니다.

표본에서 잰 값은 진짜 값이 아니다. 그런데 얼마나 다를까?

이 “얼마나 다를까”를 숫자로 만든 것이 **표준오차**이고, 통계학 전체가 여기서 나옵니다.

모수(parameter)는 모집단의 진짜 값이며 그리스 문자로 씁니다($\mu, \sigma, \beta, \theta$). **추정량/추정치(estimator/estimate)**는 표본으로 계산한 값이며 로마자나 모자(^)를 씁니다($\bar{X}, s, \hat{\beta}, \hat{\theta}$). 논문에서 모자가 씌어져 있으면 “이건 표본으로 추정된 값이니 오차가 있다”는 뜻입니다.

1.3.2 평균, 분산, 표준편차

핵심 수식

표본 $X_1, X_2, \dots, X_n$ 에 대하여

$$\bar{X} = \frac{1}{n} \sum_{i=1}^n X_i, \quad s^2 = \frac{1}{n-1} \sum_{i=1}^n (X_i - \bar{X})^2, \quad s = \sqrt{s^2}$$

수식 뜯어보기

- $\sum_{i=1}^n$: “ i 를 1부터 n 까지 바꿔가며 전부 더하라”는 기호일 뿐입니다.
- $(X_i - \bar{X})$: 각 값이 평균에서 얼마나 떨어졌는지. **편차**라고 합니다.
- 편차를 그냥 더하면 항상 0입니다($\sum(X_i - \bar{X}) = 0$). 그래서 **제곱**해서 더합니다.
- 왜 n 이 아니라 $n - 1$ 로 나눌까요? $\bar{X}$ 를 자료에서 이미 계산해 썼기 때문에, 편차 n 개 중 하나는 나머지로써 자동으로 결정됩니다(합이 0이므로). 자유롭게 움직일 수 있는 값은 $n - 1$ 개뿐입니다. 이 개수를 **자유도(degrees of freedom, df)**라 하고, 이렇게 나눠야 $\mathbb{E}[s^2] = \sigma^2$ 가 됩니다(불편성).

1.3.3 표준오차 --- 이 자료에서 가장 중요한 개념

표준편차 s 와 표준오차 SE는 완전히 다른 것인데 자주 혼동됩니다.

- s : **개인들이** 서로 얼마나 다른가 (자료의 산포)
- SE : **내가 계산한 평균값이** 표본을 다시 뽑으면 얼마나 흔들리는가 (추정치의 산포)

핵심 수식

$$SE(\bar{X}) = \frac{s}{\sqrt{n}}$$

더 일반적으로, 어떤 추정치 $\hat{\theta}$ 의 표준오차는 $SE(\hat{\theta}) = \sqrt{\text{Var}(\hat{\theta})}$ 입니다.

수식 뜯어보기

$\sqrt{n}$ 이 분모에 있다는 사실이 통계학에서 가장 실용적인 결론입니다. 표본을 4배로 늘리면 오차가 $\sqrt{4} = 2$ 배 줄어듭니다. **정밀도를 2배 올리려면 돈이 4배 든다**는 뜻이고, 9주차 표본수 산출의 전부가 이 식에서 나옵니다.

왜 $\sqrt{n}$ 일까요? 서로 독립인 값을 더하면 **분산**이 더해집니다.

$$\text{Var}\left(\sum_{i=1}^n X_i\right) = n\sigma^2 \implies \text{Var}(\bar{X}) = \text{Var}\left(\frac{1}{n} \sum_{i=1}^n X_i\right) = \frac{1}{n^2} \cdot n\sigma^2 = \frac{\sigma^2}{n}$$

여기에 제곱근을 씌우면 $\sigma/\sqrt{n}$ 입니다. ($\text{Var}(aX) = a^2 \text{Var}(X)$ 를 썼습니다.)

예시

자료가 2, 4, 4, 4, 6 ($n = 5$)일 때.

$$\bar{X} = \frac{2 + 4 + 4 + 4 + 6}{5} = 4, \quad s^2 = \frac{(-2)^2 + 0^2 + 0^2 + 0^2 + 2^2}{5 - 1} = \frac{8}{4} = 2$$

$$s = \sqrt{2} = 1.414, \quad SE(\bar{X}) = \frac{1.414}{\sqrt{5}} = \frac{1.414}{2.236} = 0.632$$

해석: 개인들은 평균에서 대략 1.41만큼 흩어져 있지만, **평균 4라는 값 자체의 불확실성**은 0.63입니다.

1.3.4 중심극한정리 --- 왜 정규분포가 계속 나오는가

핵심 수식

$X_1, \dots, X_n$ 이 서로 독립이고 같은 분포를 따르며 평균 μ , 분산 $\sigma^2 (< \infty)$ 이면, n 이 커질 때

$$\frac{\bar{X} - \mu}{\sigma/\sqrt{n}} \xrightarrow{d} N(0, 1)$$

수식 뜯어보기

$\xrightarrow{d}$ 는 “분포가 점점 그것에 가까워진다”는 뜻입니다. 핵심은 원자료 X_i 가 정규분포가 아니어도 된다는 점입니다. 자료가 오른쪽으로 심하게 치우쳐 있어도, 평균은 표본이 커지면 정규분포에 가까워집니다.

그래서 2주차의 정규성 검정은 “자료가 정규분포인가”보다 “내 추정치가 정규근사를 써도 될 만큼 안정적인가”를 보는 것에 가깝습니다.

1.3.5 p 값 --- 정확한 정의

핵심 수식

p 값은

귀무가설 H_0 가 참이라고 가정했을 때, 실제로 관측된 검정통계량만큼 또는 그보다 더 극단적인 값이 나올 확률

$$p = P(|T| \geq |t_{\text{obs}}| \mid H_0 \text{ 참}) \quad (\text{양측검정})$$

흔한 오해

p 값은 다음이 아닙니다.

- “귀무가설이 참일 확률” — 아닙니다. 조건이 반대입니다. p 는 $P(\text{자료} \mid H_0)$ 이지 $P(H_0 \mid \text{자료})$ 가 아닙니다.
- “효과의 크기” — 아닙니다. n 이 크면 아주 작은 효과도 $p < 0.001$ 이 됩니다. 그래서 논문은 반드시 효과크기(3주차)와 신뢰구간을 같이 봐야 합니다.
- “ $p > 0.05$ 이면 차이가 없다” — 아닙니다. “차이가 있다는 증거가 부족하다”일 뿐입니다.

p 값의 결정적 성질 (4주차·8주차의 근거)

검정통계량이 연속형이고 H_0 가 참이면, p 값은 $[0, 1]$ 위의 균등분포를 따릅니다.

$$H_0 \text{ 참} \implies p \sim \text{Uniform}(0, 1), \quad P(p \leq u) = u$$

이 한 줄이 왜 중요할까요? $P(p \leq 0.05) = 0.05$ 이므로, 아무 효과가 없어도 20번 검정하면 평균 1번은 유의하게 나옵니다. 이것이 4주차 다중비교 문제의 뿌리이고, 8~9주차 모의실험에서 “제1종 오류율이 정말 0.05인가”를 확인하는 기준입니다.

1.3.6 신뢰구간

핵심 수식

$$\text{신뢰구간} = \hat{\theta} \pm c \times \text{SE}(\hat{\theta})$$

c 는 신뢰수준에 따른 임계값입니다. 정규근사에서 95%면 $c = z_{0.975} = 1.96$, 표본이 작아 t 분포를 쓰면 $c = t_{0.975, \text{df}}$.

수식 뜯어보기

95% 신뢰구간의 뜻은 “참값이 이 구간에 있을 확률이 95%”가 **아닙니다**. 참값은 고정된 상수이고 움직이는 것은 구간입니다. 올바른 뜻은

같은 방식으로 표본을 무한히 반복해서 뽑아 구간을 만들면, 그 구간들 중 95%가 참값을 포함한다

이 “포함하는 비율”을 **피복확률(coverage probability)**이라 부르며, 10주차에서 부트스트랩 구간 5종을 평가하는 바로 그 지표입니다.

1.3.7 두 종류의 오류와 검정력

	H_0 가 실제로 참	H_0 가 실제로 거짓
H_0 기각함	제1종 오류 (α)	정답 (검정력 $1 - \beta$)
H_0 기각 안 함	정답 ($1 - \alpha$)	제2종 오류 (β)

- α (제1종 오류율) = 없는 효과를 있다고 하는 확률. 보통 0.05로 고정.
- β (제2종 오류율) = 있는 효과를 놓치는 확률.
- $1 - \beta$ = **검정력(power)**. 보통 0.80 이상을 목표로 합니다. (9주차)

문제 1

어떤 연구에서 $n = 100$ 으로 평균을 추정해 $\text{SE} = 2.0$ 을 얻었습니다. (a) 오차를 절반인 1.0으로 줄려면 표본이 몇 명 필요합니까? (b) 이 연구자가 “ $p = 0.30$ 이므로 두 군은 같다”고 결론지었습니다. 무엇이 잘못되었습니까?

정답 1

(a) $\text{SE} \propto 1/\sqrt{n}$ 입니다. SE를 1/2로 만들려면 $\sqrt{n}$ 이 2배, 즉 n 이 $2^2 = 4$ 배여야 합니다. 따라서 $n = 400$ 명.

$$\text{SE}_{\text{new}} = \frac{s}{\sqrt{400}} = \frac{s}{20} = \frac{1}{2} \cdot \frac{s}{10} = \frac{1}{2} \cdot 2.0 = 1.0 \quad \checkmark$$

(b) p 값이 크다는 것은 “ H_0 가 참이다”의 증거가 아니라 “ H_0 를 기각할 만한 증거가 부족하다”는 뜻일 뿐입니다. 표본이 작아 검정력이 낮으면, 실제로 큰 차이가 있어도 p 는 얼마든지 커집니다. 올바른 결론은 신뢰구간을 보고하는 것입니다. 예컨대 95% CI가 $(-0.2, 0.3)$ 처럼 좁으면 “임상적으로 무의미한 수준으로 차이가 작다”고 말할 수 있지만, $(-15, 20)$ 처럼 넓으면 “아무것도 모른다”가 정직한 결론입니다.

문제 2

H_0 가 참인 상황에서 서로 독립인 검정을 30번 수행했습니다. 각 검정의 유의수준은 0.05입니다. (a) 적어도 한 번 유의하게 나올 확률은? (b) 유의하게 나오는 검정 개수의 기댓값은?

정답 2

(a) H_0 하에서 각 검정이 유의할 확률은 0.05, 유의하지 않을 확률은 0.95. 독립이므로 30번 모두 유의하지 않을 확률은 0.95^{30} 입니다.

$$P(\text{적어도 1회 유의}) = 1 - 0.95^{30} = 1 - 0.2146 = 0.785$$

즉 78.5%. 아무 효과가 없는데도 열 번 중 여덟 번은 “유의한 발견”이 하나 이상 나옵니다.

(b) 유의 개수 $S \sim \text{Binomial}(30, 0.05)$ 이므로 $\mathbb{E}[S] = 30 \times 0.05 = 1.5$ 개.

이 계산이 4주차 다중비교 보정의 존재 이유 전체입니다.

연결고리

0장에서 세운 뼈대가 각 주차에서 무엇으로 바뀌는지 미리 봅니다. 분자와 분모만 보면 됩니다.

주차	분자(신호)	분모(잡음)	이름
3	$\bar{X}_1 - \bar{X}_2$	$s_p \sqrt{1/n_1 + 1/n_2}$	t 통계량
4	군간 분산	군내 분산	F 통계량
5	$O - E$	$\sqrt{E}$	χ^2
6	$\hat{\beta}_1$	$\text{SE}(\hat{\beta}_1)$	회귀계수의 t
7	$\hat{\beta}_1$	$\text{SE}(\hat{\beta}_1)$	Wald z
11	$O_1 - E_1$	$\sqrt{V}$	log-rank
13	$\hat{\theta}_i - \hat{\theta}_{\text{pool}}$	$\sqrt{v_i}$	Q 통계량

전부 같은 식입니다.

2주차 · 자료를 진단한다

이번 주 기법 기술통계 · Shapiro-Wilk 정규성 검정 · Levene 등분산 검정 · 로그변환 · Q-Q plot · 복합표본 가중치

논문 체중보정 허리둘레지수와 뇌졸중 (BMC Public Health 2023, PMID 37658310) — Table 1 재현

한 줄 요약 본격적인 검정을 하기 전에, 그 검정이 요구하는 가정이 만족되는지 먼저 확인한다.

2.1 왜 필요한가

논문의 Table 1은 거의 항상 “대상자 특성”입니다. 여기서 어떤 변수는 “평균 ± 표준편차”로, 어떤 변수는 “중앙값(사분위범위)”로 적혀 있습니다. 저자가 마음대로 고른 게 아니라, **분포를 진단한 결과에 따라 고른 것**입니다. 이 장은 그 판단 근거를 읽는 법입니다.

2.2 기술통계 --- 분포를 네 가지로 요약한다

핵심 수식

중심 $\bar{X} = \frac{1}{n} \sum X_i$ (평균), Med = 크기순으로 정렬했을 때 가운데 값 (중앙값)

산포 $s = \sqrt{\frac{1}{n-1} \sum (X_i - \bar{X})^2}$, IQR = $Q_3 - Q_1$

비대칭 $g_1 = \frac{\frac{1}{n} \sum (X_i - \bar{X})^3}{\left[\frac{1}{n} \sum (X_i - \bar{X})^2\right]^{3/2}}$ (왜도, skewness)

꼬리 $g_2 = \frac{\frac{1}{n} \sum (X_i - \bar{X})^4}{\left[\frac{1}{n} \sum (X_i - \bar{X})^2\right]^2} - 3$ (초과첨도, excess kurtosis)

수식 뜯어보기

- 왜 왜도는 3제곱일까요? 2제곱은 부호가 사라져서 방향을 못 봅니다. 3제곱은 부호가 살아남습니다. 오른쪽에 큰 값이 길게 늘어져 있으면 $(X_i - \bar{X})^3$ 의 양수 항이 커져 $g_1 > 0$ (**우측 치우침, right-skewed**).
- 왜 분모가 s^3 일까요? 분자의 단위는 (단위)³입니다. 나눠 주면 단위가 사라져 **어떤 변수끼리도 비교 가능**해집니다. 이것을 **표준화**라고 하며, 3주차 Cohen's d , 12주차 SMD도 똑같은 논리입니다.
- 첨도에서 -3을 하는 이유: 정규분포의 첨도가 정확히 3이기 때문입니다. 빼 주면 “정규분포 기준 0”이 됩니다.
- 평균은 극단값에 끌려가고 중앙값은 끌려가지 않습니다. 그래서 우측 치우침이 심한 변수(중성지방, 의료비, CRP)는 논문에서 중앙값으로 보고합니다.

예시

자료 1, 2, 2, 3, 10 ($n = 5$).

$$\bar{X} = \frac{18}{5} = 3.6, \quad \text{Med} = 2$$

평균이 중앙값보다 훨씬 큼니다. 10이라는 값 하나가 평균을 끌어올린 것입니다. 왜도를 계산하면

$$\frac{1}{5} \sum (X_i - 3.6)^2 = 9.84, \quad \frac{1}{5} \sum (X_i - 3.6)^3 = 42.05$$

$$g_1 = \frac{42.05}{9.84^{3/2}} = \frac{42.05}{30.90} = 1.36 > 0$$

$g_1 > 0$ 이므로 우측 치우침입니다. 판단: 이 변수는 Table 1에 중앙값(IQR)으로 적어야 한다.

2.3 Q-Q plot --- 정규성을 눈으로 보는 법

핵심 수식

자료를 크기순으로 정렬해 $x_{(1)} \leq x_{(2)} \leq \dots \leq x_{(n)}$ 이라 할 때, 정규 Q-Q plot은 다음 n 개의 점을 찍은 그림입니다.

$$\left(\underbrace{\Phi^{-1}(p_i)}_{\text{이론분위수 (x축)}}, \underbrace{x_{(i)}}_{\text{표본분위수 (y축)}} \right), \quad p_i = \frac{i - a}{n + 1 - 2a}$$

R의 `ppoints()`는 $n \leq 10$ 이면 $a = 3/8$, $n > 10$ 이면 $a = 1/2$ 를 씁니다.

수식 뜯어보기

- Φ 는 표준정규분포의 **누적분포함수**입니다. $\Phi(z) = P(Z \leq z)$.
- Φ^{-1} 은 그 역함수, 즉 **분위수함수**입니다. $\Phi^{-1}(0.975) = 1.96$ 이 우리가 아는 그 값입니다.
- p_i 는 “ i 번째로 작은 값이면 대략 하위 몇 %쯤인가”입니다. 단순히 i/n 을 쓰지 않는 이유는 $i = n$ 일 때 $p_n = 1$ 이 되어 $\Phi^{-1}(1) = +\infty$ 로 발산하기 때문입니다. 그래서 a 만큼 안쪽으로 당깁니다(연속성 보정).
- 점들이 직선 위에 있으면 정규분포입니다. 왜냐하면 자료가 $N(\mu, \sigma^2)$ 이면 $x_{(i)} \approx \mu + \sigma \Phi^{-1}(p_i)$ 이므로 기울기 σ , 절편 μ 의 직선이 되기 때문입니다.
- 오른쪽 끝이 위로 휘면 오른쪽 꼬리가 정규분포보다 무겁다는 뜻 → 우측 치우침 → 로그변환 후보.

예시

$n = 5$ 이므로 $a = 3/8$, 분모는 $n + 1 - 2a = 5 + 1 - 0.75 = 5.25$.

$$p_i = \frac{i - 0.375}{5.25} \Rightarrow p = (0.119, 0.310, 0.500, 0.690, 0.881)$$

$$\Phi^{-1}(p) = (-1.180, -0.497, 0.000, 0.497, 1.180)$$

이 다섯 값이 Q-Q plot의 x 좌표입니다. 대칭인 것에 주목하세요 — 정규분포가 대칭이기 때문입니다.

2주차 검증과제가 요구하는 것이 정확히 이 계산입니다. 인공지능에게 Q-Q plot을 그리게 한 뒤, x 축 값이 위 다섯 개와 일치하는지 qqnorm()의 출력과 대조하면 됩니다.

2.4 Shapiro--Wilk 정규성 검정

핵심 수식

$$W = \frac{(\sum_{i=1}^n a_i x_{(i)})^2}{\sum_{i=1}^n (x_i - \bar{x})^2}, \quad 0 < W \leq 1$$

H_0 : 자료가 정규분포에서 나왔다. W 가 1에 가까울수록 정규에 가깝고, 작을수록 p 값이 작아집니다.

수식 뜯어보기

- a_i 는 정규분포의 순서통계량으로부터 미리 계산된 상수 가중치입니다(직접 계산할 일은 없습니다).
- 구조를 보세요. 분자는 “자료가 정규 Q-Q 직선에 얼마나 잘 맞는가”를 잰 값(회귀의 설명된 변동에 해당)이고, 분모는 전체 변동입니다. 즉

$$W \approx \text{Q-Q plot 직선의 } R^2$$

Q-Q plot과 Shapiro-Wilk는 같은 것을 그림과 숫자로 표현한 것입니다.

- 여기서 H_0 가 “정규분포이다”라는 점이 중요합니다. 보통의 검정과 방향이 반대라서, $p > 0.05$ 면 “정규성을 기각하지 못했다”가 됩니다.

흔한 오해

표본이 크면 정규성 검정은 항상 유의해집니다. 검정력이 n 에 따라 커지기 때문에, $n = 5,000$ 인 NHANES에서는 실질적으로 무시해도 될 미세한 비정규성도 $p < 0.001$ 을 만듭니다. 반대로 $n = 15$ 면 심하게 치우친 자료도 $p > 0.05$ 가 나옵니다.

따라서 실무 원칙은 이렇습니다.

정규성은 p 값이 아니라 그림(Q-Q plot)과 표본크기로 판단한다.

또한 t 검정이 요구하는 것은 원자료의 정규성이 아니라 표본평균의 정규성이고, 중심극한정리(0장)에 의해 n 이 크면 후자는 저절로 만족됩니다.

2.5 Levene 등분산 검정

핵심 수식

k 개 군, i 번째 군의 크기 n_i , 전체 $N = \sum n_i$. 먼저 각 관측값을 **중심으로부터의 거리**로 바꿉니다.

$$Z_{ij} = |Y_{ij} - \tilde{Y}_i|$$

($\tilde{Y}_i$ 는 i 군의 중앙값. 평균을 쓰면 원래의 Levene, 중앙값을 쓰면 Brown-Forsythe 형태이며 R `car::leveneTest`의 기본값입니다.)

$$W = \frac{N - k}{k - 1} \cdot \frac{\sum_{i=1}^k n_i (\bar{Z}_{i.} - \bar{Z}_{..})^2}{\sum_{i=1}^k \sum_{j=1}^{n_i} (Z_{ij} - \bar{Z}_{i.})^2} \sim F_{k-1, N-k} \quad \text{under } H_0$$

H_0 : 모든 군의 분산이 같다($\sigma_1^2 = \dots = \sigma_k^2$).

수식 뜯어보기

이 식을 처음부터 외울 필요가 전혀 없습니다. **Levene 검정은 Z 에 대한 일원분산분석(ANOVA)일 뿐**이기 때문입니다. 4주차에서 배울 F 통계량

$$F = \frac{\text{군간 변동}/(k - 1)}{\text{군내 변동}/(N - k)}$$

에 Y 대신 $Z = |Y - \tilde{Y}|$ 를 넣은 것이 전부입니다.

논리도 간단합니다. 분산이 크다는 것은 “중심에서 멀리 떨어진 값이 많다”는 뜻이고, Z 는 바로 그 거리입니다. 따라서 **군마다 Z 의 평균이 다르면 분산이 다른 것**입니다. 중앙값을 쓰는 이유는 극단 값에 덜 흔들리기 위해서입니다.

연결고리

- Levene 검정 결과가 유의하면 → 3주차에서 pooled t 대신 **Welch t 검정**을 씁니다.
- 다만 최근의 권고는 “Levene으로 먼저 검사한 뒤 고르는” 2단계 절차를 피하고 **처음부터 항상 Welch**를 쓰는 것입니다. 사전검정 자체가 제1종 오류율을 왜곡시키기 때문입니다. 이 문제가 정확히 3주차 논문(PMID 22697476)의 주제입니다.

2.6 로그변환 --- 근거를 알고 쓰기

핵심 수식

$X > 0$ 이고 $\log X \sim N(\mu, \sigma^2)$ 이면 X 는 **로그정규분포**를 따릅니다. 이때

$$\mathbb{E}[X] = e^{\mu + \sigma^2/2}, \quad \text{Med}(X) = e^{\mu}, \quad \exp(\mathbb{E}[\log X]) = e^{\mu} = \text{기하평균}$$

수식 뜯어보기

결정적인 사실은

$$\mathbb{E}[\log X] \neq \log \mathbb{E}[X]$$

입니다. 로그는 아래로 볼록(concave)한 함수이고, Jensen 부등식에 의해 $\mathbb{E}[\log X] \leq \log \mathbb{E}[X]$ 가 항상 성립합니다.

그래서 **로그 스케일에서 계산한 평균을 다시 지수로 되돌리면 산술평균이 아니라 기하평균(= 중앙값)이 나옵니다.** 논문에서 “geometric mean”이라는 표현이 나오면 이 이야기입니다.

로그변환을 쓰는 세 가지 정당한 근거:

1. **치우침 제거** — 곱셈적으로 커지는 양(농도, 비용, 바이러스 역가)은 로그를 씌우면 대칭이 됩니다.
2. **등분산화** — 분산이 평균에 비례해 커지는 자료($SD \propto \text{mean}$)는 로그 후 분산이 일정해집니다.
3. **해석의 전환** — 로그 차이는 **비율**입니다. $\log a - \log b = \log(a/b)$. 그래서 로그 스케일의 계수는 배수로 해석됩니다(7주차 오즈비, 11주차 위험비, 13주차 로그오즈비의 근거).

예시

자료 1, 10, 100, 1000.

$$\text{산술평균} = \frac{1 + 10 + 100 + 1000}{4} = 277.75$$

$$\log_{10} \text{값} = 0, 1, 2, 3 \Rightarrow \overline{\log_{10} X} = 1.5 \Rightarrow 10^{1.5} = 31.62 = \text{기하평균}$$

277.75와 31.62는 9배 가까이 차이납니다. **같은 자료인데 어느 평균을 보고하느냐로 결론이 달라 집니다.** 이 자료에서 “전형적인 값”은 31.62 쪽이 훨씬 타당합니다.

2.7 복합표본 가중치 --- NHANES를 쓸 때 반드시 필요한 것

핵심 수식

NHANES 같은 국가 조사는 단순임의추출이 아닙니다. 특정 집단(고령자, 소수인종 등)을 일부러 **과대표집합**합니다. 그래서 각 대상자 i 에게 “이 사람이 전국의 몇 명을 대표하는가”를 뜻하는 **표본가중치** w_i 가 붙습니다.

$$\hat{Y}_w = \frac{\sum_{i=1}^n w_i y_i}{\sum_{i=1}^n w_i} \quad (\text{가중평균, Hájek 추정량})$$

$$\text{비율도 같습니다. } \hat{P}_w = \frac{\sum w_i \mathbb{I}(y_i = 1)}{\sum w_i}.$$

수식 뜯어보기

가중치를 무시하면 두 가지가 동시에 틀립니다.

1. **추정치(점추정)가 편향됩니다.** 과대표집된 집단 쪽으로 평균이 끌려갑니다.
2. **표준오차가 과소추정됩니다.** 군집추출(같은 지역 사람끼리 비슷함)과 층화를 무시하면 실제보다 자료가 “더 많은 정보를 가진 것처럼” 계산됩니다. 그 배수를 **설계효과(design effect)** $\hat{d}$ 라

하며, 5주치의 Rao-Scott 보정이 바로 χ^2 를 $\hat{d}$ 로 나누는 절차입니다.

그래서 R에서는 `mean()`이 아니라 `survey::svymean()`, `glm()`이 아니라 `svyglm()`을 써야 합니다.

예시

3명을 뽑았는데 가중치가 $w = (10, 10, 80)$ 이고 측정값이 $y = (1, 2, 3)$ 입니다.

$$\text{단순평균} = \frac{1 + 2 + 3}{3} = 2.00$$

$$\text{가중평균} = \frac{10 \cdot 1 + 10 \cdot 2 + 80 \cdot 3}{10 + 10 + 80} = \frac{10 + 20 + 240}{100} = \frac{270}{100} = 2.70$$

세 번째 사람이 전국 80명을 대표하므로 그의 값이 훨씬 크게 반영됩니다. **2.00과 2.70 — 논문 Table 1을 재현할 때 값이 안 맞는 가장 흔한 원인이 바로 이것입니다.**

문제 3

NHANES 자료로 어떤 논문의 Table 1을 재현했더니, 논문은 평균 혈중 중성지방을 **148.2 mg/dL**이라 보고했는데 여러분의 코드는 **131.5 mg/dL**를 냈습니다. 또 논문은 이 변수를 “median (IQR)”로 보고했고 Shapiro-Wilk $p < 0.001$ 을 부록에 적었습니다. (a) 값 불일치의 가장 유력한 원인 두 가지를 쓰시오. (b) 저자가 median(IQR)을 쓴 근거를 Shapiro-Wilk 결과만으로 정당화할 수 있습니까?

정답 3

(a) 두 가지입니다.

1. **복합표본 가중치 미반영.** `svymean(~TRIGLY, design)` 대신 `mean()`을 썼을 가능성. NHANES에서 이 차이는 통상 수 %~십수 % 수준으로 나타납니다.
2. **대상자 제외 기준(inclusion/exclusion) 불일치.** 논문의 flow chart대로 결측·임신부·특정 연령 등을 단계별로 제외했는지. 2주차 검증과제가 “제외 단계별 인원을 논문과 대조하라”고 명시한 이유입니다. 단계별 n 이 하나라도 다르다면 평균은 반드시 달라집니다.

(추가로 중성지방은 8시간 이상 공복 하위표본에서만 측정되므로 **전용 공복 가중치**를 써야 하는데, 이를 놓치는 것이 매우 흔한 실수입니다.)

(b) 부분적으로만 그렇습니다. n 이 수천인 NHANES에서 Shapiro-Wilk는 사소한 비정규성에도 거의 항상 $p < 0.001$ 을 냅니다. 따라서 p 값 자체는 근거로 약합니다. **정당한 근거**는 왜 $g_1 > 0$ 이 크다는 점, Q-Q plot의 오른쪽 꼬리가 위로 크게 휘어 있다는 점, 그리고 중성지방이 생물학적으로 로그정규에 가깝다는 사전 지식입니다. 이 셋이 함께 제시되어야 합니다.

문제 4

어떤 변수의 로그변환값이 $\log_e X \sim N(\mu = 2, \sigma^2 = 0.5)$ 를 따릅니다. (a) X 의 중앙값과 기하평균을 구하시오. (b) X 의 산술평균 $\mathbb{E}[X]$ 를 구하시오. (c) 두 값이 다른 이유를 한 문장으로 설명하시오.

정답 4

(a) 로그 스케일에서 정규분포는 대칭이므로 중앙값은 $\mu = 2$. 원래 스케일로 되돌리면

$$\text{Med}(X) = e^2 = 7.389$$

기하평균 = $\exp(\mathbb{E}[\log X]) = e^2 = 7.389$ 로 중앙값과 같습니다.

(b) 로그정규분포의 평균 공식 $\mathbb{E}[X] = e^{\mu + \sigma^2/2}$ 를 씁니다.

$$\mathbb{E}[X] = e^{2+0.5/2} = e^{2.25} = 9.488$$

(c) $\exp$ 는 위로 볼록(convex)한 함수라서, 로그 스케일에서 오른쪽으로 조금만 벗어난 값도 원래 스케일에서는 아주 큰 값이 됩니다. 젠센 부등식 $\mathbb{E}[e^Y] \geq e^{\mathbb{E}[Y]}$ 에 의해 산술평균(9.488)은 항상 기하평균(7.389)보다 크거나 같으며, 그 차이는 σ^2 이 클수록 벌어집니다.

논문 읽을 때 확인할 것

2주차 논문(Table 1)을 읽을 때:

- 연속변수가 “mean $\pm$ SD”인가 “median (IQR)”인가? → 저자가 분포를 진단했다는 신호.
- “weighted” 또는 “survey-weighted”라는 단어가 Methods에 있는가? 없다면 NHANES 분석으로서 결함.
- Table 1의 n 과 flow chart 최종 n 이 일치하는가?
- p 값이 Table 1에 붙어 있는가? (RCT의 baseline table에 p 값을 붙이는 것은 권장되지 않습니다. 무작위배정이 제대로 되었다면 H_0 가 정의상 참이므로 p 값은 정보가 없습니다.)

3주차 · 두 군을 비교한다

이번 주 기법 독립 2표본 t 검정 · 대응 t 검정 · Welch 검정 · Wilcoxon 검정 · 순열검정 · 효과크기

논문 t 검정과 비모수 검정의 역설 (BMC Med Res Methodol 2012, PMID 22697476) — 제1종 오류율 모의실험 재현

한 줄 요약 “신호 나누기 잡음”을 처음으로 실제로 계산한다. 그리고 비모수 검정이 무엇을 검정하는지 정확히 안다.

3.1 독립 2표본 t 검정 (pooled)

핵심 수식

군 1: n_1 명, 평균 $\bar{X}_1$, 표준편차 s_1 . 군 2: n_2 명, 평균 $\bar{X}_2$, 표준편차 s_2 .

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p \sqrt{\frac{1}{n_1} + \frac{1}{n_2}}} \quad s_p^2 = \frac{(n_1 - 1)s_1^2 + (n_2 - 1)s_2^2}{n_1 + n_2 - 2}$$

$H_0: \mu_1 = \mu_2$ 하에서 $t \sim t_{n_1+n_2-2}$. 가정: 독립, 정규성, 등분산.

수식 뜯어보기

- 분자 $\bar{X}_1 - \bar{X}_2$ 가 신호입니다. 우리가 궁금한 그 차이.
- 분모는 “ H_0 가 참일 때 이 차이가 우연히 얼마나 흔들리는가”입니다. 유도해 봅시다. 두 군이 독립이므로 분산이 더해집니다.

$$\text{Var}(\bar{X}_1 - \bar{X}_2) = \text{Var}(\bar{X}_1) + \text{Var}(\bar{X}_2) = \frac{\sigma^2}{n_1} + \frac{\sigma^2}{n_2} = \sigma^2 \left(\frac{1}{n_1} + \frac{1}{n_2} \right)$$

등분산 가정 덕분에 σ^2 을 하나로 묶을 수 있고, 그 σ^2 을 두 군의 정보를 합쳐 추정한 것이 s_p^2 입니다. 제곱근을 씌우면 정확히 분모가 됩니다.

- s_p^2 은 자유도로 가중한 평균입니다. 가중치 $(n_1 - 1)$ 과 $(n_2 - 1)$ 의 합이 분모 $n_1 + n_2 - 2$ 이므로, 표본이 큰 군의 분산이 더 크게 반영됩니다.
- 자유도 $n_1 + n_2 - 2$: 자료가 $n_1 + n_2$ 개인데 평균을 두 개($\bar{X}_1, \bar{X}_2$) 계산해 썼으므로 2를 뺍니다.

예시

군1: $n_1 = 10$, $\bar{X}_1 = 100$, $s_1 = 15$. 군2: $n_2 = 10$, $\bar{X}_2 = 90$, $s_2 = 15$.

$$s_p^2 = \frac{9(225) + 9(225)}{18} = 225 \Rightarrow s_p = 15$$

$$SE = 15\sqrt{\frac{1}{10} + \frac{1}{10}} = 15\sqrt{0.2} = 15 \times 0.4472 = 6.708$$

$$t = \frac{100 - 90}{6.708} = 1.491, \quad df = 18 \Rightarrow p = 0.153$$

차이 10점은 커 보이지만, 개인차($s = 15$)에 비하면 신호가 잡음의 1.49배에 불과합니다. **유의하지 않습니다.**

3.2 Welch 검정 --- 등분산을 가정하지 않는다

핵심 수식

$$t_W = \frac{\bar{X}_1 - \bar{X}_2}{\sqrt{\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}}}$$

자유도는 정수가 아니며 **Satterthwaite 근사**로 계산합니다.

$$\nu = \frac{\left(\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}\right)^2}{\frac{(s_1^2/n_1)^2}{n_1 - 1} + \frac{(s_2^2/n_2)^2}{n_2 - 1}}$$

수식 뜯어보기

- 분모에서 s_p 가 사라지고 각 군이 **자기 분산**을 씁니다. 그것이 전부입니다. $\sigma_1 \neq \sigma_2$ 여도 됩니다.
- Satterthwaite 식이 하는 일: 분모 $\frac{s_1^2}{n_1} + \frac{s_2^2}{n_2}$ 는 두 개의 χ^2 을 섞은 것이라 정확한 분포가 없습니다. 그래서 “평균과 분산이 가장 비슷한 하나의 χ^2 ”로 근사하고, 그 χ^2 의 자유도가 ν 입니다.
- 성질: 항상 $\min(n_1 - 1, n_2 - 1) \leq \nu \leq n_1 + n_2 - 2$. 두 군의 s^2/n 이 같으면 최댓값에 도달하고, 한쪽이 압도적이면 최솟값 근처로 떨어집니다.
- **실무 결론**: 분산이 정말 같으면 Welch는 pooled와 거의 같은 답을 냅니다. 분산이 다르면 Welch만 맞습니다. 그러므로 **항상 Welch를 기본으로 쓰는 것이 손해가 없습니다.** (R의 `t.test()` 기본값이 Welch인 이유.)

예시

$n_1 = 10, s_1 = 5$ (작고 균질한 군), $n_2 = 40, s_2 = 20$ (크고 산포가 큰 군).

$$\frac{s_1^2}{n_1} = \frac{25}{10} = 2.5, \quad \frac{s_2^2}{n_2} = \frac{400}{40} = 10$$

$$SE = \sqrt{2.5 + 10} = \sqrt{12.5} = 3.536$$

$$\nu = \frac{(2.5 + 10)^2}{\frac{2.5^2}{9} + \frac{10^2}{39}} = \frac{156.25}{0.6944 + 2.5641} = \frac{156.25}{3.2585} = 47.95$$

pooled를 썼다면 $df = 48$ 였을 텐데 우연히 비슷합니다. 하지만 SE는 완전히 다릅니다. $s_p^2 = \frac{9(25)+39(400)}{48} = 329.7$, $s_p = 18.16$, $SE_{\text{pooled}} = 18.16\sqrt{1/10 + 1/40} = 6.42$. **Welch의 3.54와 pooled의 6.42 — t 값이 거의 두 배 차이납니다.**

3.3 대응 t 검정 --- 짝지어진 자료

핵심 수식

같은 사람에게 전/후 측정이 있거나 짝지어진 쌍이면, 먼저 **차이**를 만듭니다.

$$d_i = X_{i,\text{after}} - X_{i,\text{before}}, \quad i = 1, \dots, n$$

$$t = \frac{\bar{d}}{s_d/\sqrt{n}}, \quad df = n - 1$$

수식 뜯어보기

대응 t 검정은 새로운 검정이 아니라 d_i 에 대한 **1표본 t 검정**입니다. 왜 이렇게 하면 이득일까요? 독립 2표본으로 다루면 분모에 개인차 σ^2 이 그대로 들어옵니다. 그런데 차이를 만들면 개인의 기저 수준이 상쇄됩니다.

$$\text{Var}(d) = \text{Var}(X_{\text{after}}) + \text{Var}(X_{\text{before}}) - 2\text{Cov}(X_{\text{after}}, X_{\text{before}}) = 2\sigma^2(1 - \rho)$$

전후 상관 ρ 가 클수록(같은 사람이니 보통 큼) 분산이 극적으로 줄어듭니다. $\rho = 0.8$ 이면 $\text{Var}(d) = 0.4\sigma^2$ 로 60% 감소. **짝을 무시하고 독립 검정을 쓰면 검정력을 그냥 버리는 것입니다.**

3.4 효과크기 --- p 값이 말해 주지 않는 것

핵심 수식

$$\text{Cohen's } d = \frac{\bar{X}_1 - \bar{X}_2}{s_p}$$

관례적 기준: $|d| \approx 0.2$ 작음, 0.5 중간, 0.8 큼. (절대적 기준이 아니라 분야별 관례입니다.)

수식 뜯어보기

t 와 d 의 관계를 보면 왜 둘 다 필요한지 즉시 알 수 있습니다. $n_1 = n_2 = n$ 일 때

$$t = \frac{\bar{X}_1 - \bar{X}_2}{s_p\sqrt{2/n}} = \frac{d}{\sqrt{2/n}} = d \cdot \sqrt{\frac{n}{2}}$$

$$t\text{값} = \text{효과크기} \times \text{표본크기 요인}$$

따라서 d 가 0.05로 무의미하게 작아도 n 을 충분히 키우면 t 는 얼마든지 커지고 $p < 0.001$ 이 됩니다. p 값은 “**효과 × 표본**”이고, d 는 **표본을 제거한 순수한 효과**입니다.

앞의 예시에서 $d = 10/15 = 0.667$ — 중간 크기의 효과입니다. $p = 0.153$ 으로 유의하지 않았던 것은 효과가 없어서가 아니라 $n = 10$ 으로 검정력이 부족했기 때문입니다(9주차).

3.5 Wilcoxon 순위합 검정 --- 무엇을 검정하는가

핵심 수식

두 군 자료를 합쳐서 작은 것부터 순위를 매깁니다. 군1 관측치들의 순위 합을 W_1 이라 할 때

$$U_1 = W_1 - \frac{n_1(n_1 + 1)}{2}$$

H_0 하에서 (동점이 없을 때)

$$\mathbb{E}[W_1] = \frac{n_1(N + 1)}{2}, \quad \text{Var}(W_1) = \frac{n_1 n_2 (N + 1)}{12}, \quad N = n_1 + n_2$$

$$z = \frac{W_1 - \mathbb{E}[W_1]}{\sqrt{\text{Var}(W_1)}} \quad (\text{정규근사})$$

수식 뜯어보기

- U_1 의 의미가 아름답습니다. U_1 은 (군1의 값이 군2의 값보다 큰 쌍의 개수)입니다. 가능한 쌍은 총 $n_1 n_2$ 개이므로

$$\frac{U_1}{n_1 n_2} = \hat{P}(X_1 > X_2)$$

이 값이 7주차의 AUC와 정확히 같은 양입니다. 놀랍지만 사실입니다.

- W_1 의 최솟값은 $1 + 2 + \dots + n_1 = n_1(n_1 + 1)/2$ 이므로, U_1 은 그 최솟값을 빼서 0부터 시작하게 만든 것입니다.
- 여기서 가장 중요한 사실: H_0 는 “두 군의 중앙값이 같다”가 아닙니다. 정확한 H_0 는

$$H_0 : P(X_1 > X_2) = \frac{1}{2} \quad (\text{확률적 동등, stochastic equality})$$

또는 더 강하게 “두 분포가 동일하다”입니다. 중앙값 차이로 해석하려면 두 분포의 모양이 같고 위치만 다르다는 추가 가정(location shift)이 필요합니다.

흔한 오해

“비모수 검정은 가정이 없어서 안전하다”는 말은 틀렸습니다.

Wilcoxon 검정은 가정이 다를 뿐이지 없지는 않습니다. 두 군의 분산이 크게 다르면(이분산) Wilcoxon의 제1종 오류율은 명목 0.05를 크게 벗어날 수 있습니다. 반면 Welch t 검정은 이분산 상황에서 오히려 안정적입니다.

3주차 논문(PMID 22697476)이 “역설”이라 부른 것이 바로 이것입니다. 정규성이 의심스러워서 비모수로 도피했는데, 실제 문제가 이분산이었다면 상황이 더 나빠집니다.

검증과제: 중앙값이 같은데 Wilcoxon이 유의한 반례

군1 = {−10, −9, −8, 0, 8, 9, 10}, 군2 = {−1, −1, −1, 0, 1, 1, 1}.

두 군의 중앙값은 모두 0이고 평균도 모두 0입니다. 그러나 군1은 산포가 훨씬 큼니다. 이때 순위를 매기면 군1의 값들은 양 끝(아주 낮은 순위와 아주 높은 순위)에 몰리고 군2는 가운데에 몰립니다.

n 을 늘려 이 구조를 유지하면(예: 각 군 50명씩 같은 패턴), $P(X_1 > X_2)$ 가 1/2에서 벗어나거나 순위합의 분산 구조가 H_0 가정과 어긋나면서 **중앙값이 동일함에도 Wilcoxon이 유의해집니다**. 교훈: Wilcoxon이 유의하다고 해서 “중앙값이 다르다”고 쓰면 안 됩니다. 정확한 진술은 “한 군의 값이 다른 군보다 클 경향이 있다”입니다.

3.6 순열검정 --- 분포 가정을 아예 없애는 법

핵심 수식

1. 실제 자료로 통계량 T_{obs} 를 계산한다 (예: $\bar{X}_1 - \bar{X}_2$).
2. H_0 가 참이라면 **군 라벨은 아무 의미가 없다**. 그러니 라벨을 무작위로 섞고 통계량을 다시 계산한다: T_1^* .
3. 이것을 B 번 반복해 $T_1^*, \dots, T_B^*$ 를 얻는다. 이것이 **귀무분포**이다.
4. p 값 =

$$\hat{p} = \frac{1 + \#\{b : |T_b^*| \geq |T_{\text{obs}}|\}}{1 + B}$$

수식 뜯어보기

- 이 방법은 정규성도, 등분산도, 어떤 분포도 가정하지 않습니다. 오직 **교환가능성(exchangeability)**만 가정합니다.
- 분자·분모에 +1이 왜 붙을까요? 관측된 자료 자체도 하나의 유효한 순열이기 때문입니다. 이 보정이 없으면 $\hat{p} = 0$ 이 나올 수 있는데, 확률이 정확히 0이라는 것은 불가능합니다. 이 보정으로 $\hat{p} \geq 1/(1+B)$ 가 보장되고, **제1종 오류율이 명목 수준을 넘지 않음이 증명됩니다**.
- $B = 999$ 면 최소 p 값은 $1/1000 = 0.001$ 입니다. $p < 0.001$ 을 보고하고 싶으면 B 를 더 키워야 합니다.

연결고리

순열검정의 아이디어 “컴퓨터로 귀무분포를 직접 만든다”는 이 강의의 척추입니다.

- 3주차 순열검정: 라벨을 섞는다 → **귀무분포**를 만든다.
- 8주차 Fisher 정확검정: 섞는 대신 **모든 경우를 전부 세어** 정확한 귀무분포를 만든다.
- 10주차 부트스트랩: 라벨이 아니라 **자료를 복원추출**한다 → **추정치**의 분포를 만든다.
- 9주차 검정력 모의실험: 자료를 **생성**한다 → 검정의 성능을 잴다.

셋의 차이는 “무엇을 섞거나 뽑는가” 하나뿐입니다.

문제 5

두 군의 요약통계가 다음과 같습니다. 군A: $n = 12$, $\bar{X} = 54.0$, $s = 6.0$. 군B: $n = 30$, $\bar{X} = 49.5$, $s = 15.0$. (a) pooled t 와 Welch t 를 각각 구하시오. (b) Welch 자유도를 Satterthwaite 식으로 구하시오. (c) 어느 결과를 보고해야 하며 그 이유는?

정답 5

(a) pooled.

$$s_p^2 = \frac{11(36) + 29(225)}{12 + 30 - 2} = \frac{396 + 6525}{40} = \frac{6921}{40} = 173.03, \quad s_p = 13.154$$

$$SE_{\text{pooled}} = 13.154 \sqrt{\frac{1}{12} + \frac{1}{30}} = 13.154 \sqrt{0.08333 + 0.03333} = 13.154 \times 0.34157 = 4.493$$

$$t_{\text{pooled}} = \frac{54.0 - 49.5}{4.493} = \mathbf{1.002} \quad (df = 40)$$

Welch.

$$\frac{s_A^2}{n_A} = \frac{36}{12} = 3.0, \quad \frac{s_B^2}{n_B} = \frac{225}{30} = 7.5$$

$$SE_W = \sqrt{3.0 + 7.5} = \sqrt{10.5} = 3.240, \quad t_W = \frac{4.5}{3.240} = \mathbf{1.389}$$

(b)

$$\nu = \frac{(3.0 + 7.5)^2}{\frac{3.0^2}{11} + \frac{7.5^2}{29}} = \frac{110.25}{\frac{9}{11} + \frac{56.25}{29}} = \frac{110.25}{0.8182 + 1.9397} = \frac{110.25}{2.7579} = \mathbf{39.98}$$

(c) Welch입니다. $s_B/s_A = 15/6 = 2.5$ 로 분산비가 6.25배나 되어 등분산 가정이 명백히 깨졌습니다. 이 상황에서 pooled는 표본이 큰 군B의 큰 분산을 작은 군A에도 강제로 적용해 SE를 부풀렸고(4.49 vs 3.24), 그 결과 t 가 1.002로 과소평가되었습니다. 두 결론이 갈리지는 않았지만(둘 다 $p > 0.05$), 신뢰구간의 폭은 크게 달라집니다.

주의: 이때 “Levene 검정을 먼저 하고 골랐다”고 쓰면 안 됩니다. 사전검정을 거치는 2단계 절차는 전체 제1종 오류율을 왜곡합니다. **처음부터 Welch로 계획했다**고 쓰는 것이 옳습니다.

문제 6

어떤 임상시험에서 $n_1 = n_2 = 400$, $\bar{X}_1 - \bar{X}_2 = 0.6$ 점, $s_p = 12$ 점을 얻었습니다. (a) t 와 대략적인 p 값을 구하시오. (b) Cohen's d 를 구하시오. (c) 이 결과를 논문에 어떻게 써야 하는가?

정답 6

(a)

$$SE = 12 \sqrt{\frac{1}{400} + \frac{1}{400}} = 12 \sqrt{0.005} = 12 \times 0.070711 = 0.8485$$

$$t = \frac{0.6}{0.8485} = 0.707, \quad df = 798 \Rightarrow p \approx 0.48$$

(b) $d = 0.6/12 = \mathbf{0.05}$ — 매우 작습니다.

(c) 여기서는 $p > 0.05$ 이고 d 도 무시할 만큼 작으므로 “차이가 관찰되지 않았다”로 충분합니다. 그러나 핵심은 n 이 더 컸다면 이야기가 달라진다는 점입니다. $t = d\sqrt{n/2}$ 이므로 같은 $d = 0.05$ 에서

$$n = 400 \Rightarrow t = 0.05\sqrt{200} = 0.71 \quad (p = 0.48)$$

$$n = 10,000 \Rightarrow t = 0.05\sqrt{5000} = 3.54 \quad (p < 0.001)$$

즉 똑같이 무의미한 0.6점 차이가 대규모 코호트에서는 “highly significant”로 보고됩니다. 따라서 논문에는 반드시 (i) 효과크기 또는 원단위 차이, (ii) 95% 신뢰구간, (iii) 임상적 최소 중요 차이(MCID)와의 비교를 함께 써야 합니다. 여기서는 95% CI가 $0.6 \pm 1.96(0.8485) = (-1.06, 2.26)$ 입니다.

논문 읽을 때 확인할 것

- Methods에 “Student’s *t*-test”라고만 쓰여 있으면 pooled인지 Welch인지 확인. R 기본값은 Welch, SPSS 기본 출력은 둘 다.
- “Mann-Whitney U test”와 “Wilcoxon rank-sum test”는 같은 검정입니다(통계량이 상수만큼 다를 뿐).
- 비모수 검정 결과를 “median difference”로 해석했다면, 두 군의 분포 모양이 비슷한지 그림으로 확인했는지 보세요.
- *p*값만 있고 효과크기·신뢰구간이 없으면 그 결과는 해석할 수 없습니다.

4주차 · 여러 군을 비교하고, 여러 번 검정한다

이번 주 기법 일원분산분석 · Welch ANOVA · Kruskal-Wallis · 경향성 검정 · Tukey 사후검정 · Bonferroni · Benjamini-Hochberg

논문 노쇠지수와 혈구 계수 유래 염증지표의 상관 (BMC Public Health 2024, PMID 39695452)

한 줄 요약 군이 3개 이상이면 t 검정을 반복하면 안 된다. 그 이유가 $1 - (1 - \alpha)^k$ 한 줄에 들어 있다.

4.1 일원분산분석 --- 변동을 두 조각으로 쪼갬다

핵심 수식

k 개 군, i 군의 크기 n_i , 전체 $N = \sum n_i$. 전체평균 $\bar{Y}_{..}$, i 군 평균 $\bar{Y}_{i.}$.

$$\underbrace{\sum_i \sum_j (Y_{ij} - \bar{Y}_{..})^2}_{SST \text{ (전체 변동)}} = \underbrace{\sum_i n_i (\bar{Y}_{i.} - \bar{Y}_{..})^2}_{SSB \text{ (군간 변동)}} + \underbrace{\sum_i \sum_j (Y_{ij} - \bar{Y}_{i.})^2}_{SSW \text{ (군내 변동)}}$$

$$F = \frac{SSB/(k-1)}{SSW/(N-k)} = \frac{MSB}{MSW} \quad H_0 : \mu_1 = \mu_2 = \dots = \mu_k$$

H_0 하에서 $F \sim F_{k-1, N-k}$.

수식 뜯어보기

- 이 분해식이 성립하는 이유: $Y_{ij} - \bar{Y}_{..} = (\bar{Y}_{i.} - \bar{Y}_{..}) + (Y_{ij} - \bar{Y}_{i.})$ 로 쪼개고 제곱하면 교차항이 나오는데, 안쪽 합 $\sum_j (Y_{ij} - \bar{Y}_{i.}) = 0$ 이므로 사라집니다.
- F 도 0장의 뼈대입니다. 분자 MSB 는 “군 평균들이 서로 얼마나 벌어졌나”(신호), 분모 MSW 는 “같은 군 안에서도 사람들이 얼마나 다른가”(잡음). H_0 가 참이면 둘 다 σ^2 을 추정하므로 $F \approx 1$ 입니다.
- 자유도: 군 평균 k 개가 전체평균으로 묶여 있으므로 군간은 $k-1$, 각 군에서 평균을 하나씩 썼으니 군내는 $N-k$.
- $k=2$ 면 ANOVA는 pooled t 검정과 완전히 동일합니다: $F = t^2$. 3주차의 확장일 뿐입니다.
- MSW 는 3주차의 s_p^2 을 k 개 군으로 확장한 것입니다. 등분산 가정도 그대로 상속됩니다.

예시

세 군, 각 $n_i = 3$: A = {5, 6, 7}, B = {8, 9, 10}, C = {11, 12, 13}.

군평균 = 6, 9, 12, 전체평균 = 9.

$$SSB = 3(6 - 9)^2 + 3(9 - 9)^2 + 3(12 - 9)^2 = 27 + 0 + 27 = 54$$

각 군의 군내 제곱합이 $(-1)^2 + 0^2 + 1^2 = 2$ 씩이므로 $SSW = 6$.

$$F = \frac{54/(3-1)}{6/(9-3)} = \frac{27}{1} = 27.0, \quad df = (2, 6) \Rightarrow p = 0.0010$$

군간 변동이 군내 변동의 27배입니다. 군들이 확실히 다릅니다.

4.2 Welch ANOVA와 Kruskal--Wallis

핵심 수식

Welch ANOVA — 등분산 가정을 버린 ANOVA. 각 군에 $w_i = n_i/s_i^2$ 의 가중치를 주어 평균과 변동을 계산합니다. 3주차 Welch t 의 k 군 확장이며, 자유도도 마찬가지로 근사값입니다.

Kruskal--Wallis — 순위 기반. 전체 N 개를 합쳐 순위를 매기고, i 군의 평균순위를 $\bar{R}_i$ 라 할 때

$$H = \frac{12}{N(N+1)} \sum_{i=1}^k n_i \bar{R}_i^2 - 3(N+1) \sim \chi_{k-1}^2 \text{ (근사)}$$

수식 뜯어보기

H 식의 12와 $3(N+1)$ 은 마법의 숫자가 아닙니다. 순위 $1, 2, \dots, N$ 자체가 평균 $(N+1)/2$, 분산 $(N^2-1)/12$ 를 갖기 때문에 나오는 정규화 상수입니다. 즉 H 는 **순위에 ANOVA를 적용한 뒤 MSW 대신 이론적 분산으로 나눈 것**입니다.

관계를 정리하면:

	2군	k 군
정규 + 등분산	pooled t	ANOVA (F)
정규 + 이분산	Welch t	Welch ANOVA
순위 기반	Wilcoxon	Kruskal--Wallis
분포 무가정	순열검정	순열 ANOVA

표의 각 열은 같은 아이디어의 반복입니다. 새로 배울 것은 사실상 없습니다.

4.3 경향성 검정 --- 순서가 있는 군

핵심 수식

군이 사분위군($Q_1 < Q_2 < Q_3 < Q_4$)처럼 순서를 가질 때, “아무거나 다르다”보다 “용량이 늘수록 결과가 커진다”를 검정하는 것이 훨씬 강력합니다. **선형대비(linear contrast)**를 씁니다.

$$L = \sum_{i=1}^k c_i \bar{Y}_i, \quad \text{제약: } \sum_i c_i = 0$$

$k = 4$ 일 때 표준 선형계수는 $c = (-3, -1, 1, 3)$.

$$t = \frac{L}{\sqrt{MSW \sum_i \frac{c_i^2}{n_i}}} \quad (\text{df} = N - k)$$

범주형 결과(비율)의 경향성이면 **Cochran--Armitage 경향성 검정**을 씁니다.

수식 뜯어보기

- $\sum c_i = 0$ 인 이유: 그래야 H_0 가 참일 때 $\mathbb{E}[L] = \mu \sum c_i = 0$ 이 됩니다. 전체 수준이 아니라 **패**턴만 보게 만드는 장치입니다.
- 왜 더 강력한가? ANOVA는 자유도 $k - 1 = 3$ 을 쓰지만 경향성 검정은 자유도 1만 씁니다. 검정할 방향을 미리 하나로 좁혔기 때문에 같은 자료에서 더 낮은 p 값이 나옵니다.
- 단, 관계가 U자형이면 경향성 검정은 아무것도 못 찾습니다($L \approx 0$). **그림을 보고 사후에 고르는 것이 아니라 가설을 미리 정해야 합니다.**

4.4 다중비교 --- 이 장의 핵심

4.4.1 문제의 크기

핵심 수식

m 개의 독립인 검정을 각각 유의수준 α 로 수행할 때, H_0 가 전부 참이라면

$$\text{FWER} = P(\text{적어도 하나 거짓 유의}) = 1 - (1 - \alpha)^m$$

m	1	5	10	20	100
$1 - 0.95^m$	0.050	0.226	0.401	0.642	0.994

$m = 20$ 이면 아무 효과가 없어도 **64%**의 확률로 “유의한 발견”이 하나 이상 나옵니다.

4.4.2 두 가지 다른 오류 기준

핵심 수식

FWER (가족단위 오류율, Family-Wise Error Rate)

$$\text{FWER} = P(V \geq 1), \quad V = \text{거짓 기각의 개수}$$

“단 하나의 거짓 발견도 허용하지 않겠다.”

FDR (거짓발견율, False Discovery Rate)

$$\text{FDR} = \mathbb{E} \left[\frac{V}{\max(R, 1)} \right], \quad R = \text{총 기각 개수}$$

“내가 발견했다고 말한 것들 중 평균 5%까지는 틀려도 좋다.”

FWER은 확증적 연구(임상시험의 주평가변수)에, FDR은 탐색적 연구(유전체, 다수의 염증지표 스크리닝)에 적합합니다. 4주차 논문처럼 여러 염증지표를 한꺼번에 보는 상황은 FDR 영역입니다.

4.4.3 Bonferroni 보정

핵심 수식

각 검정을 α/m 수준에서 판정합니다. 동등하게 p 값을 m 배 합니다.

$$p_i^{\text{adj}} = \min(1, m p_i)$$

수식 뜯어보기

정당성은 **Boole 부등식**(합집합 상계) 한 줄입니다. 독립을 가정할 필요조차 없습니다.

$$P \left(\bigcup_{i=1}^m \{p_i \leq \alpha/m\} \right) \leq \sum_{i=1}^m P(p_i \leq \alpha/m) = m \cdot \frac{\alpha}{m} = \alpha$$

따라서 어떤 상관구조에서도 $\text{FWER} \leq \alpha$ 가 보장됩니다. 매우 안전하지만 매우 보수적이며, m 이 크면 검정력이 거의 0이 됩니다.

4.4.4 Benjamini--Hochberg (BH) 절차

핵심 수식

p 값을 오름차순 정렬: $p_{(1)} \leq p_{(2)} \leq \dots \leq p_{(m)}$.

$$\text{조건을 만족하는 가장 큰 } i: \quad p_{(i)} \leq \frac{i}{m} q$$

그 i 를 i^* 라 할 때 $p_{(1)}, \dots, p_{(i^*)}$ 를 모두 기각합니다. 이때 $\text{FDR} \leq q$ 가 보장됩니다(독립 또는 양의 의존 하).

수식 뜯어보기

- Bonferroni는 문턱이 α/m 으로 일정합니다. BH는 문턱이 $\frac{i}{m}q$ 로 순위에 따라 커집니다. 그래서 덜 보수적입니다.
- “가장 큰 i ”를 찾는다는 점이 핵심입니다(step-up). 중간에 조건을 만족하지 못하는 p 값이 있어도, 더 뒤쪽에서 조건을 만족하면 그 앞의 것까지 전부 기각합니다.
- 직관: H_0 가 전부 참이면 p 값은 균등분포이므로(0장) $p_{(i)} \approx i/m$ 입니다. BH는 관측된 $p_{(i)}$ 가 이 “귀무 기대선”보다 q 배 아래로 내려간 지점까지를 발견으로 인정합니다.

예시

$m = 5$ 개의 p 값: 0.001, 0.008, 0.039, 0.041, 0.042. $\alpha = q = 0.05$.

Bonferroni: 문턱 = $0.05/5 = 0.01$. 0.001과 0.008만 통과 $\Rightarrow$ 2개 기각.

BH: 문턱 = $\frac{i}{5}(0.05)$.

i	$p_{(i)}$	$\frac{i}{m}q$	$p_{(i)} \leq \frac{i}{m}q?$
1	0.001	0.010	예
2	0.008	0.020	예
3	0.039	0.030	아니오
4	0.041	0.040	아니오
5	0.042	0.050	예 $\leftarrow$ 가장 큰 i

$i^* = 5$ 이므로 5개 전부 기각. $i = 3, 4$ 에서 실패했는데도 기각된다는 점이 step-up 절차의 정의입니다.

2개 대 5개. 같은 자료, 다른 오류 기준.

흔한 오해

BH가 Bonferroni보다 “더 좋은” 방법이 아닙니다. 통제하는 대상이 다릅니다. BH로 5개를 기각했다면 그중 평균 5%(약 0.25개)는 거짓 발견일 것으로 예상하고 받아들인 것입니다. 확증적 임상시험에서는 용납되지 않습니다.

4.5 Tukey HSD 사후검정

핵심 수식

ANOVA가 유의하면 “어느 군끼리 다른가”를 봅니다. 모든 쌍 $\binom{k}{2}$ 개를 비교하되 FWER을 α 로 통제합니다.

$$q = \frac{\bar{Y}_i - \bar{Y}_j}{\sqrt{\frac{MSW}{2} \left(\frac{1}{n_i} + \frac{1}{n_j} \right)}} \sim q_{k, N-k} \quad (\text{studentized range 분포})$$

수식 뜯어보기

t 분포가 아니라 **스튜던트화 범위분포**를 쓰는 것이 핵심입니다. 실제로 하는 일은 “ k 개 평균 중 가장 큰 것과 가장 작은 것의 차이가 얼마나 큰가”인데, 최댓값과 최솟값의 차이는 임의의 두 값의 차이보다 확률적으로 큼니다. Tukey는 그 사실을 분포 자체에 반영해서 **Bonferroni보다 덜 보수적** 이면서 FWER을 정확히 α 로 맞춥니다(균형설계에서).

문제 7

어떤 연구가 노쇠지수 사분위군(Q1~Q4)에서 8개 염증지표를 각각 비교했습니다(지표마다 ANOVA 1회, 총 8회). p 값이 다음과 같습니다.

0.0004, 0.006, 0.011, 0.021, 0.028, 0.033, 0.20, 0.62

- (a) 보정 없이 $\alpha = 0.05$ 면 몇 개가 유의한가? (b) Bonferroni로는? (c) BH($q = 0.05$)로는?
(d) 탐색적 스크리닝이라면 무엇을 보고해야 하는가?

정답 7

(a) 0.05 미만은 0.0004, 0.006, 0.011, 0.021, 0.028, 0.033 → **6개**.

(b) **Bonferroni**. 문턱 = $0.05/8 = 0.00625$.

$0.0004 \leq 0.00625 \checkmark$, $0.006 \leq 0.00625 \checkmark$, $0.011 > 0.00625 \times$

→ **2개**. (동등하게 $p^{\text{adj}} = 8p$: 0.0032, 0.048, 0.088, ...)

(c) **BH**. $m = 8$, 문턱 $\frac{i}{8}(0.05) = 0.00625 i$.

i	$p_{(i)}$	$\frac{i}{8}(0.05)$	만족?
1	0.0004	0.00625	예
2	0.006	0.01250	예
3	0.011	0.01875	예
4	0.021	0.02500	예
5	0.028	0.03125	예
6	0.033	0.03750	예 ← 가장 큰 i
7	0.20	0.04375	아니오
8	0.62	0.05000	아니오

$i^* = 6 \rightarrow$ **6개 기각**.

(d) 탐색적 스크리닝이면 **BH(FDR)**가 적절합니다. 6개를 후속 검증 대상으로 제시하되 “이 6개 중 평균 5% 정도(약 0.3개)는 거짓 발견일 수 있다”를 명시합니다. Bonferroni를 쓰면 2개만 남아 실제 신호를 대량으로 놓칩니다(제2종 오류 급증). **보정을 안 한 (a)는 어떤 경우에도 정당화되지 않습니다** — $m = 8$ 이면 FWER이 이미 $1 - 0.95^8 = 0.337$ 입니다.

문제 8

H_0 가 모두 참인 상황을 컴퓨터로 만들어 $m = 20$ 개 독립 검정을 $B = 10,000$ 번 반복했습니다. (a) “적어도 하나 유의”의 이론적 비율은? (b) 모의실험에서 6,380번 나왔습니다. 이론값과 일치하는가? (c) 모든 p 값의 히스토그램은 어떤 모양이어야 하는가?

정답 8

(a) $1 - 0.95^{20} = 1 - 0.3585 = \mathbf{0.6415}$.

(b) 관측 비율 $\hat{\pi} = 6380/10000 = 0.6380$. 몬테카를로 표준오차는

$$\text{MCSE} = \sqrt{\frac{\hat{\pi}(1 - \hat{\pi})}{B}} = \sqrt{\frac{0.638 \times 0.362}{10000}} = 0.00481$$

차이는 $|0.6380 - 0.6415| = 0.0035$ 로 0.73 MCSE에 불과합니다. ± 2 MCSE 구간 (0.6284, 0.6476)이 이론값 0.6415를 포함합니다. **일치합니다.**

(c) H_0 가 참이므로 $p \sim \text{Uniform}(0, 1)$ 이고 히스토그램은 **평평**해야 합니다. 왼쪽 끝이 솟아 있으면 진짜 효과가 섞였거나 코드에 버그가 있는 것이고, 계단 모양이면 검정통계량이 이산형(예: Fisher 정확검정)이거나 검정이 보수적인 것입니다.

연결고리

- 3주차: ANOVA의 $MSW = \text{pooled } s_p^2$ 의 확장. $k = 2$ 면 $F = t^2$.
- 2주차: Levene 검정은 $|Y - \tilde{Y}|$ 에 대한 ANOVA. 같은 F 식.
- 5·8주차: 검정통계량이 이산형이면 p 값의 균등성이 깨지고 검정이 **보수적**이 됩니다.
- 13주차: 베이지안 계층모형의 축소는 다중성 문제에 대한 전혀 다른 해법입니다.

5주차 · 범주형 자료와 분할표

이번 주 기법 카이제곱 검정 · 연속성 보정 · Fisher 정확검정 · Rao-Scott 보정 · McNemar 검정 · 오즈비와 상대위험

논문 치주질환·구강건강과 고혈압의 연관 (BMC Public Health 2023, PMID 37308938)

한 줄 요약 결과가 “있다/없다”인 자료를 다룬다. 그리고 논문에서 가장 많이 오해되는 숫자인 오즈비를 정확히 이해한다.

5.1 2×2 분할표의 표준 표기

	질병 있음	질병 없음	합계
노출됨	a	b	$a + b$
노출 안 됨	c	d	$c + d$
합계	$a + c$	$b + d$	n

5.2 카이제곱 검정

핵심 수식

$$E_{ij} = \frac{(\text{행 } i \text{의 합}) \times (\text{열 } j \text{의 합})}{n},$$

$$\chi^2 = \sum_i \sum_j \frac{(O_{ij} - E_{ij})^2}{E_{ij}}$$

H_0 (독립) 하에서 $\chi^2 \sim \chi^2_{(r-1)(c-1)}$.

수식 뜯어보기

- E_{ij} 공식의 유래: 독립이면 $P(\text{행 } i \cap \text{열 } j) = P(\text{행 } i)P(\text{열 } j)$ 입니다. 기대 개수는

$$n \cdot \frac{R_i}{n} \cdot \frac{C_j}{n} = \frac{R_i C_j}{n}$$

- 이것도 0장의 뼈대입니다. 각 칸의 도수는 대략 포아송/이항이므로 분산 $\approx E_{ij}$, 표준오차 $\approx \sqrt{E_{ij}}$ 입니다. 따라서

$$\frac{(O - E)^2}{E} = \left(\frac{O - E}{\sqrt{E}} \right)^2 = \left(\frac{\text{신호}}{\text{잡음}} \right)^2$$

즉 χ^2 은 표준화된 잔차의 제곱합입니다. z^2 을 여러 칸에 대해 더한 것이고, 그래서 χ^2 분포가 나옵니다.

- 자유도 $(r-1)(c-1)$: 행합과 열합이 고정되면 2×2 표에서 한 칸만 정하면 나머지 셋이 자동 결정됩니다. 그래서 $df = 1$.

- $\frac{O - E}{\sqrt{E}}$ 를 **Pearson 잔차**라 하며, 어느 칸이 독립에서 크게 벗어났는지 보여줍니다(잔차도).

Yates 연속성 보정

$$\chi^2_{\text{Yates}} = \sum \frac{(|O_{ij} - E_{ij}| - 0.5)^2}{E_{ij}}$$

도수는 정수(이산)인데 χ^2 분포는 연속입니다. 이 불일치를 메우려고 각 편차에서 0.5를 뺍니다. **결과적으로 p 값이 커집니다(보수적)**. 표본이 크면 차이가 사라지므로 요즘은 잘 쓰지 않습니다.

예시

$a = 30, b = 70, c = 10, d = 90$ ($n = 200$).

기대도수: 행합 100, 100, 열합 40, 160.

$$E_{11} = \frac{100 \times 40}{200} = 20, \quad E_{12} = 80, \quad E_{21} = 20, \quad E_{22} = 80$$

$$\begin{aligned} \chi^2 &= \frac{(30 - 20)^2}{20} + \frac{(70 - 80)^2}{80} + \frac{(10 - 20)^2}{20} + \frac{(90 - 80)^2}{80} \\ &= 5 + 1.25 + 5 + 1.25 = \mathbf{12.5}, \quad \text{df} = 1 \Rightarrow p = 0.00041 \end{aligned}$$

Yates 보정을 하면 $\chi^2_{\text{Yates}} = 11.28, p = 0.00078$ 로 조금 커집니다.

5.3 오즈비와 상대위험 --- 논문에서 가장 많이 혼동되는 것

핵심 수식

$$\text{위험(risk)} \quad p = \frac{a}{a+b}, \quad \text{오즈(odds)} \quad \frac{p}{1-p} = \frac{a}{b}$$

$$\text{OR} = \frac{a/b}{c/d} = \frac{ad}{bc}$$

$$\text{RR} = \frac{a/(a+b)}{c/(c+d)} = \frac{p_1}{p_0}$$

로그 오즈비의 표준오차 (Woolf 공식):

$$\text{SE}(\log \text{OR}) = \sqrt{\frac{1}{a} + \frac{1}{b} + \frac{1}{c} + \frac{1}{d}}$$

95% 신뢰구간은 반드시 **로그 스케일에서** 만든 뒤 되돌립니다.

$$\text{CI}_{95\%} = \exp(\log \text{OR} \pm 1.96 \times \text{SE}(\log \text{OR}))$$

수식 뜯어보기

- **왜 로그를 씌우는가?** OR은 $(0, \infty)$ 범위이고 1을 중심으로 심하게 비대칭입니다(“2배”와 “절반”은 2와 0.5). 로그를 씌우면 $(-\infty, \infty)$ 로 퍼지고 0을 중심으로 대칭이 되며, 이때 비로소 정규 근사가 성립합니다. 2주차 **로그변환의 직접적 응용**입니다.

- 그래서 forest plot의 x 축이 항상 로그 스케일인 것입니다. $OR = 0.5$ 와 $OR = 2$ 가 1로부터 같은 거리에 있어야 하니까요.

- **OR과 RR의 관계:**

$$OR = RR \times \frac{1 - p_0}{1 - p_1}$$

결과가 드물면($p_0, p_1 \rightarrow 0$) 보정항이 1에 가까워져 $OR \approx RR$ 입니다. 이것이 **희귀질병 가정 (rare disease assumption)**입니다.

- 결과가 흔하면 OR은 RR을 과장합니다. 이것이 5주차 검증과제입니다.

예시

위 표에서

$$OR = \frac{30 \times 90}{70 \times 10} = \frac{2700}{700} = 3.857$$

$$p_1 = \frac{30}{100} = 0.30, \quad p_0 = \frac{10}{100} = 0.10 \Rightarrow RR = \frac{0.30}{0.10} = 3.00$$

검산: $OR = RR \cdot \frac{1-p_0}{1-p_1} = 3.00 \times \frac{0.90}{0.70} = 3.857 \checkmark$

OR 3.86이 RR 3.00을 29% 과장했습니다. 유병률이 30%로 높기 때문입니다.

신뢰구간:

$$SE(\log OR) = \sqrt{\frac{1}{30} + \frac{1}{70} + \frac{1}{10} + \frac{1}{90}}$$

$$= \sqrt{0.0333 + 0.0143 + 0.1000 + 0.0111} = \sqrt{0.1587} = 0.3984$$

$$\log OR = \log 3.857 = 1.3499 \Rightarrow 1.3499 \pm 1.96(0.3984) = (0.5691, 2.1307)$$

$$CI_{95\%} = (e^{0.5691}, e^{2.1307}) = (1.77, 8.42)$$

1을 포함하지 않으므로 유의합니다. **구간이 1을 중심으로 비대칭**(1.77은 아래로 2.2배, 8.42는 위로 2.2배)인 것에 주목하세요 — 로그 스케일에서는 대칭입니다.

흔한 오해

OR을 “몇 배 위험”으로 읽으면 안 됩니다. OR은 “오즈의 비”이지 “위험의 비”가 아닙니다. 결과가 흔한 단면연구에서 $OR = 3.86$ 을 “위험이 3.86배”라고 쓰면 실제(3.00배)를 크게 과장하는 것입니다.

그럼에도 OR을 쓰는 이유는 (i) 환자-대조군 연구에서는 RR을 계산할 수 없지만 OR은 계산되고, (ii) 로지스틱 회귀(7주차)가 자연스럽게 OR을 내놓기 때문입니다.

5.4 Fisher 정확검정

핵심 수식

행합과 열합을 모두 고정시키면, H_0 (독립) 하에서 칸 a 의 분포는 **초기하분포**입니다.

$$P(A = a) = \frac{\binom{a+b}{a} \binom{c+d}{c}}{\binom{n}{a+c}}$$

가능한 모든 a 값에 대해 이 확률을 계산한 뒤, **관측된 표보다 확률이 같거나 작은 표들의 확률을 모두 더한 것이 양측 p 값**입니다.

수식 뜯어보기

- “정확(exact)”이라는 말은 **근사 분포(χ^2)를 쓰지 않고 확률을 직접 다 센다**는 뜻입니다. 3주차 순열검정에서 무작위로 섞는 대신 **모든 경우를 열거**하는 것과 정확히 같은 아이디어입니다.
- 기대도수가 5 미만인 칸이 있으면 χ^2 근사가 나빠지므로 Fisher를 씁니다.
- 초기하분포의 직관: 공이 n 개 있고 그중 $a+c$ 개가 “질병”이라는 표시가 되어 있습니다. 여기서 $a+b$ 개를 무작위로 뽑았을 때 표시된 공이 a 개일 확률 — 그것이 위 식입니다.

흔한 오해

Fisher 정확검정은 “정확”하지만 “보수적”입니다. 검정통계량이 이산형이라서 p 값이 $\{1/70, 17/70, \dots\}$ 같은 띄엄띄엄한 값만 가질 수 있습니다. 따라서 $P(p \leq 0.05)$ 가 정확히 0.05가 되지 못하고 그보다 **작아집니다**. 실제 유의수준이 명목 수준에 미달하는 것이며, 그만큼 검정력을 잃습니다.

이것이 5주차 검증과제이고, 이를 완화한 것이 8주차의 **mid- p** 입니다. 그리고 4주차에서 확인한 “ H_0 하 p 값의 균등성”이 이산형에서는 깨진다는 사실의 구체적 사례입니다.

5.5 McNemar 검정 --- 짝지어진 범주형 자료

핵심 수식

같은 사람을 두 번 측정하거나 짝지은 경우, 표를 **쌍 단위**로 만듭니다.

	검사2 양성	검사2 음성
검사1 양성	a (일치)	b (불일치)
검사1 음성	c (불일치)	d (일치)

$$\chi^2_{\text{McNemar}} = \frac{(b-c)^2}{b+c} \sim \chi^2_1$$

수식 뜯어보기

a 와 d (일치하는 쌍)가 식에 **전혀 등장하지 않는다**는 점이 핵심입니다. 두 검사가 똑같이 답한 사람은 어느 쪽이 더 나은지에 대한 정보를 주지 않습니다. 정보는 오직 **불일치 쌍 b 와 c** 에 있습니다.

H_0 가 참이면 불일치가 어느 방향으로 갈지는 동전 던지기(1/2)입니다. 따라서 $b \sim \text{Binomial}(b+c, 1/2)$ 이고

$$\mathbb{E}[b] = \frac{b+c}{2}, \quad \text{Var}(b) = \frac{b+c}{4}$$

$$z = \frac{b - \frac{b+c}{2}}{\sqrt{\frac{b+c}{4}}} = \frac{\frac{b-c}{2}}{\frac{\sqrt{b+c}}{2}} = \frac{b-c}{\sqrt{b+c}} \implies z^2 = \frac{(b-c)^2}{b+c}$$

또 0장의 뼈대입니다. 3주차 대응 t 검정이 연속형 짝자료를 다뤘다면, McNemar는 범주형 짝자료를 다룹니다.

예시

새 검사와 기존 검사를 100명에게 모두 시행. 둘 다 양성 40명, 둘 다 음성 25명, 새 검사만 양성 25명(b), 기존 검사만 양성 10명(c).

$$\chi^2 = \frac{(25 - 10)^2}{25 + 10} = \frac{225}{35} = 6.43, \quad p = 0.011$$

새 검사가 유의하게 더 많이 양성으로 판정합니다. 일치한 65명은 계산에 쓰이지 않았습니다.

5.6 Rao--Scott 보정 --- 복합표본에서의 χ^2

핵심 수식

NHANES 같은 복합표본에서는 관측치가 독립이 아닙니다(같은 조사구역 안의 사람들은 서로 비슷함). 이를 무시하면 χ^2 이 부풀려집니다.

$$X_{RS}^2 = \frac{X_{\text{Pearson}}^2}{\hat{d}}$$

$\hat{d}$ 는 설계효과(design effect, DEFF)의 추정치입니다.

$$\text{DEFF} = \frac{\text{Var}_{\text{복합표본}}(\hat{\theta})}{\text{Var}_{\text{단순임의추출}}(\hat{\theta})}$$

수식 뜯어보기

DEFF가 2라는 것은 “이 복합표본 $n = 5000$ 은 사실상 단순임의추출 $n = 2500$ 만큼의 정보밖에 없다”는 뜻입니다. 그 실질적 크기를 유효표본수(effective sample size) $n_{\text{eff}} = n/\text{DEFF}$ 라 합니다.

χ^2 은 n 에 비례해서 커지므로, 정보가 절반이면 χ^2 도 절반이어야 맞습니다. 그래서 $\hat{d}$ 로 나눕니다. R에서는 svychisq()가 자동으로 해 줍니다. 2주차의 가중치 이야기가 검정으로 확장된 것입니다.

문제 9

치주질환과 고혈압의 연관을 본 단면연구에서 다음 표를 얻었습니다.

	고혈압 있음	고혈압 없음	합계
치주질환 있음	180	320	500
치주질환 없음	120	380	500
합계	300	700	1000

- (a) χ^2 과 자유도를 구하시오. (b) OR과 RR을 구하시오. (c) OR이 RR을 몇 % 과장했는가?
(d) log OR의 95% CI로부터 OR의 95% CI를 구하시오.

정답 9

(a) 기대도수:

$$E_{11} = \frac{500 \times 300}{1000} = 150, \quad E_{12} = 350, \quad E_{21} = 150, \quad E_{22} = 350$$

$$\chi^2 = \frac{(180 - 150)^2}{150} + \frac{(320 - 350)^2}{350} + \frac{(120 - 150)^2}{150} + \frac{(380 - 350)^2}{350}$$

$$= \frac{900}{150} + \frac{900}{350} + \frac{900}{150} + \frac{900}{350} = 6 + 2.571 + 6 + 2.571 = 17.14, \quad df = 1$$

$$p < 0.0001.$$

(b)

$$OR = \frac{180 \times 380}{320 \times 120} = \frac{68400}{38400} = 1.781$$

$$p_1 = \frac{180}{500} = 0.36, \quad p_0 = \frac{120}{500} = 0.24 \Rightarrow RR = \frac{0.36}{0.24} = 1.500$$

(c) 계산: $RR \cdot \frac{1-p_0}{1-p_1} = 1.5 \times \frac{0.76}{0.64} = 1.5 \times 1.1875 = 1.781 \checkmark$

$$\frac{1.781 - 1.500}{1.500} = 0.1875 \Rightarrow 18.75\% \text{ 과장}$$

고혈압 유병률이 24~36%로 매우 흔하기 때문입니다. 이 논문 결과를 “치주질환이 있으면 고혈압 위험이 1.78배”라고 쓰면 틀립니다. 정확한 위험비는 1.50입니다.

(d)

$$SE(\log OR) = \sqrt{\frac{1}{180} + \frac{1}{320} + \frac{1}{120} + \frac{1}{380}} = \sqrt{0.005556 + 0.003125 + 0.008333 + 0.002632}$$

$$= \sqrt{0.019646} = 0.14017$$

$$\log(1.781) = 0.5772 \Rightarrow 0.5772 \pm 1.96(0.14017) = (0.3025, 0.8519)$$

$$CI_{95\%} = (e^{0.3025}, e^{0.8519}) = (1.353, 2.344)$$

1을 포함하지 않으므로 유의합니다.

추가: NHANES 자료였다면 여기에 Rao-Scott 보정이 필요합니다. $\hat{d} = 1.8$ 이라면 $X_{RS}^2 = 17.14/1.8 = 9.52$ 로 줄어들고, 신뢰구간도 $\sqrt{1.8} = 1.34$ 배 넓어집니다.

문제 10

2×2 표 $\begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$ 에 대해, (a) 기대도수를 구하고 χ^2 근사가 적절한지 판단하시오. (b) 왜 Fisher 정확검정을 써야 하는지 설명하시오.

정답 10

(a) 행합 = 4, 4, 열합 = 4, 4, $n = 8$.

$$E_{ij} = \frac{4 \times 4}{8} = 2 \quad (\text{네 칸 모두})$$

모든 기대도수가 $2 < 5$ 입니다. 통상적 기준(“기대도수가 5 미만인 칸이 20%를 넘으면 안 된다”)을 명백히 위반하므로 χ^2 근사는 부적절합니다.

(b) χ^2 분포는 연속분포인데, $n = 8$ 인 표에서 가능한 a 값은 0, 1, 2, 3, 4 다섯 개뿐이라 검정통계량도 다섯 개 값만 가질 수 있습니다. 이렇게 이산성이 극단적일 때 연속분포로 근사하면 p 값이 크게 틀립니다(보통 너무 작게 나와 제1종 오류가 증가).

Fisher 정확검정은 근사 없이 초기화 확률을 전부 열거합니다. 8주차에서 이것을 C로 직접 구현하게 되며, 실제 값은

$$P(A = a) = \frac{\binom{4}{a} \binom{4}{4-a}}{\binom{8}{4}}, \quad \binom{8}{4} = 70$$

$$P(0) = \frac{1}{70}, P(1) = \frac{16}{70}, P(2) = \frac{36}{70}, P(3) = \frac{16}{70}, P(4) = \frac{1}{70}$$

관측된 $a = 3$ 의 확률은 $16/70 = 0.2286$ 이고, 이보다 확률이 같거나 작은 표($a = 0, 1, 3, 4$)를 모두 더하면

$$p_{\text{양측}} = \frac{1 + 16 + 16 + 1}{70} = \frac{34}{70} = 0.4857$$

전혀 유의하지 않습니다.

논문 읽을 때 확인할 것

- 논문이 OR을 보고했다면 **결과의 유병률**을 확인하세요. 10%를 넘으면 OR을 RR로 읽으면 안 됩니다.
- 신뢰구간이 1을 중심으로 비대칭인가? 대칭이면 로그 스케일에서 계산하지 않았을 가능성이 있습니다.
- NHANES/KNHANES 분석인데 svychisq 언급이 없으면 표준오차가 과소추정되었을 수 있습니다.
- “paired”라는 단어가 있는데 일반 χ^2 을 썼다면 McNemar를 써야 했던 것입니다.

6주차 · 상관, 회귀, 그리고 일치도

이번 주 기법 Pearson·Spearman 상관 · 다중 선형회귀 · 다중공선성 · 급내상관계수(ICC) · Bland-Altman 일치한계 · 비례편의
논문 손목착용 기기와 수면다원검사의 일치도 (PLOS ONE 2025, PMID 41026691)
한 줄 요약 상관이 높다고 일치하는 것이 아니다. 이 한 문장이 6주차의 전부다.

6.1 Pearson 상관계수

핵심 수식

$$r = \frac{\sum_i (x_i - \bar{x})(y_i - \bar{y})}{\sqrt{\sum_i (x_i - \bar{x})^2} \sqrt{\sum_i (y_i - \bar{y})^2}} = \frac{\widehat{\text{Cov}}(x, y)}{s_x s_y}, \quad -1 \leq r \leq 1$$

수식 뜯어보기

- 분자 $\sum (x_i - \bar{x})(y_i - \bar{y})$ 는 **공분산**입니다. x 가 평균보다 크고 y 도 평균보다 크면 양수, 반대 방향이면 음수. 그래서 부호가 방향을 말합니다.
- 분모는 각 변수의 산포입니다. 나눠 주면 단위가 사라지고 $[-1, 1]$ 에 갇힙니다. **또 표준화**입니다(2주차 왜도, 3주차 d 와 같은 논리).
- r 은 직선 관계만 잡니다. $y = x^2$ 처럼 완벽한 관계여도 x 가 0을 중심으로 대칭이면 $r = 0$ 입니다.
- **Spearman 상관**은 원자료를 순위로 바꾼 뒤 Pearson을 계산한 것입니다. 따라서 단조증가 관계면 직선이 아니어도 잡아내고, 극단값에 강합니다. (3주차 Wilcoxon이 순위를 쓴 것과 같은 발상.)

6.2 단순 선형회귀와 다중 선형회귀

핵심 수식

$$Y_i = \beta_0 + \beta_1 X_{i1} + \cdots + \beta_p X_{ip} + \varepsilon_i, \quad \varepsilon_i \stackrel{iid}{\sim} N(0, \sigma^2)$$

최소제곱추정량은 $\sum_i (Y_i - \hat{Y}_i)^2$ 을 최소화하며, 행렬로는

$$\hat{\beta} = (\mathbf{X}^T \mathbf{X})^{-1} \mathbf{X}^T \mathbf{y}$$

단순회귀($p = 1$)에서는

$$\hat{\beta}_1 = r \cdot \frac{s_y}{s_x}, \quad \hat{\beta}_0 = \bar{y} - \hat{\beta}_1 \bar{x}$$

수식 뜯어보기

- $\hat{\beta}_1 = r s_y / s_x$ 는 **상관과 회귀가 같은 것**임을 보여줍니다. r 은 단위 없는 버전, $\hat{\beta}_1$ 은 단위를 되살린 버전입니다.
- **다중회귀에서 β_j 의 정확한 해석**: “다른 모든 공변량을 고정했을 때, X_j 가 1단위 증가하면 Y 의 기댓값이 β_j 만큼 변한다.” 논문의 “adjusted”가 바로 이 뜻입니다.
- 계수의 검정도 0장의 뼈대입니다.

$$t = \frac{\hat{\beta}_j - 0}{\text{SE}(\hat{\beta}_j)} \sim t_{n-p-1}$$

- 잔차 진단 4종(잔차 대 적합값, Q-Q plot, scale-location, 영향점)은 각각 선형성, 정규성, 등분산성, 이상점을 봅니다. 2주차 진단 도구가 여기서 그대로 재사용됩니다.

예시

$x = (1, 2, 3, 4, 5), y = (2, 4, 5, 4, 5)$.

$$\bar{x} = 3, \quad \bar{y} = 4, \quad \sum (x - \bar{x})(y - \bar{y}) = (-2)(-2) + (-1)(0) + 0 + 1(0) + 2(1) = 6$$

$$\sum (x - \bar{x})^2 = 10, \quad \sum (y - \bar{y})^2 = 4 + 0 + 1 + 0 + 1 = 6$$

$$r = \frac{6}{\sqrt{10}\sqrt{6}} = \frac{6}{7.746} = 0.775$$

$$s_x = \sqrt{10/4} = 1.581, \quad s_y = \sqrt{6/4} = 1.225 \Rightarrow \hat{\beta}_1 = 0.775 \times \frac{1.225}{1.581} = 0.60$$

$$\hat{\beta}_0 = 4 - 0.60(3) = 2.20 \quad \Rightarrow \quad \hat{y} = 2.20 + 0.60x$$

(참고: Spearman 상관은 0.738로 조금 다릅니다. y 에 동점이 있고 관계가 완전한 직선이 아니기 때문입니다.)

6.3 다중공선성과 VIF

핵심 수식

공변량 X_j 를 나머지 모든 공변량으로 회귀시켰을 때의 결정계수를 R_j^2 이라 하면

$$\text{VIF}_j = \frac{1}{1 - R_j^2}$$

그리고 이 계수의 표준오차가 다음과 같이 부풀려집니다.

$$\text{SE}(\hat{\beta}_j) = \frac{\sigma}{s_j \sqrt{n-1}} \times \sqrt{\text{VIF}_j}$$

수식 뜯어보기

- VIF는 **분산팽창인자**입니다. 이름 그대로 “분산이 몇 배 부풀었는가”입니다.
- $R_j^2 = 0$ (완전 독립)이면 $VIF = 1$ (팽창 없음). $R_j^2 = 0.9$ 면 $VIF = 10$ 이고, 표준오차는 $\sqrt{10} = 3.16$ 배가 됩니다.
- 관례적 기준: $VIF > 5$ 주의, > 10 심각.
- 공선성이 있어도 예측은 멀쩡합니다. 망가지는 것은 **개별 계수의 해석**입니다. 키와 몸무게를 같이 넣으면 “몸무게를 고정하고 키만 1cm 늘리면”이라는 상황이 자료에 거의 없어서, 그 계수를 추정할 정보가 없습니다. BMI와 허리둘레, 체중보정 허리둘레지수를 함께 넣는 2주차 논문 상황이 정확히 이렇습니다.

6.4 급내상관계수 (ICC)

핵심 수식

같은 대상을 여러 번 재거나 여러 평가자가 잴 때, 총 변동을 대상간 변동과 측정오차로 쪼갭니다.

$$Y_{ij} = \mu + \alpha_i + \varepsilon_{ij}, \quad \alpha_i \sim N(0, \sigma_b^2), \quad \varepsilon_{ij} \sim N(0, \sigma_w^2)$$

$$ICC = \frac{\sigma_b^2}{\sigma_b^2 + \sigma_w^2}$$

수식 뜯어보기

- 뜻: 전체 변동 중 “사람이 진짜 다른 것”이 차지하는 비율. 나머지는 측정오차입니다.
- $ICC = 0.9$ 면 관측된 변동의 90%가 진짜 개인차이고 10%가 오차입니다.
- 관례: < 0.5 나쁨, $0.5-0.75$ 보통, $0.75-0.9$ 좋음, > 0.9 매우 좋음.
- ICC는 형태가 여러 개입니다 (Shrout-Fleiss의 $ICC(1,1)$, $ICC(2,1)$, $ICC(3,1)$, $ICC(2,k)$ 등). 평가자를 무작위효과로 보는지 고정효과로 보는지, 개별 측정인지 평균인지에 따라 값이 달라 집니다. 6주차 검증과제가 요구하는 것이 이 차이의 확인이며, 논문은 반드시 어떤 형태를 썼는지 명시해야 합니다.
- ICC는 2주차의 설계효과(DEFF)와 형제입니다. 군집 크기 m 일 때 $DEFF \approx 1 + (m - 1) ICC$.

6.5 Bland--Altman --- 이 장의 핵심

핵심 수식

두 측정법 A(기준)와 B(신규)를 같은 사람 n 명에게 적용합니다.

$$d_i = B_i - A_i \quad (\text{차이}), \quad m_i = \frac{A_i + B_i}{2} \quad (\text{평균})$$

x 축에 m_i , y 축에 d_i 를 찍습니다. 그리고

$$\text{편의(bias)} = \bar{d},$$

$$95\% \text{ 일치한계(LoA)} = \bar{d} \pm 1.96 s_d$$

수식 뜯어보기

- $1.96 s_d$ 이지 $1.96 s_d / \sqrt{n}$ 이 아닙니다. 여기서 s_d (표준편차)를 쓰지 SE를 쓰지 않는 이유는, 우리가 알고 싶은 것이 “평균 차이가 얼마나 정확한가”가 아니라 “다음 환자 한 명에게서 두 기계가 얼마나 다를 수 있는가”이기 때문입니다. 이것은 신뢰구간이 아니라 **예측구간**입니다.
- x 축이 왜 A 가 아니라 평균 m 일까요? A 도 오차가 있는 측정값이기 때문입니다. d 대 A 를 그리면 A 의 오차가 $d = B - A$ 에도 들어 있어 **인위적인 음의 상관**이 생깁니다(회귀 회석). 평균을 쓰면 이 인공물이 크게 줄어듭니다.
- **비례편의(proportional bias)**: d_i 를 m_i 에 회귀시켰을 때 기울기가 0이 아니면, 측정값이 커질수록 두 기계의 차이가 커진다는 뜻입니다. 이때는 단일한 LoA가 부적절하고 회귀 기반 LoA를 써야 합니다.
- LoA가 넓으면 두 기계를 바꿔 쓸 수 없습니다. **판단 기준은 통계가 아니라 임상**입니다: “이 정도 오차를 임상적으로 감당할 수 있는가?”

흔한 오해

상관계수로 일치도를 평가하면 안 됩니다. 이것이 Bland와 Altman이 1986년 논문에서 지적한 바로 그 오류이고, 6주차 검증과제입니다.
이유는 세 가지입니다.

1. r 은 **체계적 편의를 감지하지 못합니다**. 기계 B가 항상 정확히 10을 더 크게 잴다면 $r = 1.000$ 인데 두 기계는 전혀 일치하지 않습니다.
2. r 은 **눈금 차이도 감지하지 못합니다**. $B = 2A$ 여도 $r = 1$ 입니다.
3. r 은 **대상자의 범위에 의존합니다**. 건강인과 중증환자를 섞어서 재면 s_x 가 커져 r 이 자동으로 올라갑니다. 측정법은 하나도 안 좋아졌는데도 말입니다.

상관은 완벽한데 일치는 최악인 자료 (검증과제 구성)

수면다원검사 $A = (300, 350, 400, 450, 500)$ 분, 손목기기 $B = (330, 385, 440, 495, 550)$ 분.
 $B = 1.1A$ 이므로 $r = 1.000$ 입니다 (완벽한 직선).
그러나 차이는

$$d = (30, 35, 40, 45, 50), \quad \bar{d} = 40, \quad s_d = \sqrt{\frac{100 + 25 + 0 + 25 + 100}{4}} = \sqrt{62.5} = 7.906$$

$$\text{LoA} = 40 \pm 1.96(7.906) = (24.5, 55.5) \text{ 분}$$

손목기기가 수면시간을 **평균 40분 과대측정**하고, 개인에 따라 24분~56분까지 벌어집니다. 임상적으로 사용 불가능합니다.

게다가 d 가 m 에 따라 증가하므로(30→50) **비례편의**가 있습니다. 회귀하면 기울기가 정확히 0.1입니다. 단일 LoA조차 부적절합니다.

$r = 1.000$ 이라는 숫자만 보고 “훌륭한 일치도”라고 쓴 논문은 완전히 틀린 것입니다.

문제 11

어떤 연구가 신규 혈압계와 기존 혈압계를 60명에게 적용해 $r = 0.96$ ($p < 0.001$)을 보고하며 “우수한 일치도”라고 결론지었습니다. 여러분이 원자료로 계산해 보니 $\bar{d} = 6.2$ mmHg, $s_d = 9.4$ mmHg였습니다. (a) 95% 일치한계를 구하시오. (b) 평균 편의의 95% 신뢰구간을 구하고, (a)와 무엇이 다른지 설명하시오. (c) 이 결론이 타당한지 판단하시오. (혈압계 허용 기준: 편의 ≤ 5 mmHg, SD ≤ 8 mmHg)

정답 11

(a)

$$\begin{aligned} \text{LoA} &= \bar{d} \pm 1.96 s_d = 6.2 \pm 1.96(9.4) = 6.2 \pm 18.42 \\ &= (-12.2, +24.6) \text{ mmHg} \end{aligned}$$

즉 개별 환자에서 신규 기기는 기존보다 12 mmHg 낮게 나올 수도, 25 mmHg 높게 나올 수도 있습니다.

(b) 편의의 표준오차는

$$SE(\bar{d}) = \frac{s_d}{\sqrt{n}} = \frac{9.4}{\sqrt{60}} = \frac{9.4}{7.746} = 1.213$$

$$CI_{95\%}(\bar{d}) = 6.2 \pm 1.96(1.213) = (3.82, 8.58) \text{ mmHg}$$

차이: (b)는 “평균 편의가 얼마인가”의 불확실성이라 n 이 커지면 좁아집니다. (a)는 “다음 한 명에게서 얼마나 벌어질까”라 n 이 아무리 커져도 좁아지지 않습니다. 일치도 평가에 필요한 것은 (a)입니다. (b)만 보고하면 표본을 늘려서 “정밀하다”고 주장하는 오류를 범합니다.

(c) 타당하지 않습니다. 세 가지 근거:

1. $r = 0.96$ 은 일치도의 증거가 아닙니다. 체계적 편의를 전혀 반영하지 못합니다.
2. 편의 6.2 mmHg는 허용 기준 5 mmHg를 초과하며, 신뢰구간 (3.82, 8.58)의 대부분이 5를 넘습니다.
3. SD 9.4 mmHg도 허용 기준 8 mmHg를 초과합니다. LoA 폭이 약 37 mmHg로 임상적으로 수용 불가능합니다.

올바른 결론: “신규 기기는 기존 대비 체계적으로 높게 측정하며(편의 +6.2 mmHg), 일치한계가 -12.2~+24.6 mmHg로 넓어 기존 기기를 대체할 수 없다.”

문제 12

어떤 다중회귀에서 BMI, 허리둘레, 체중보정 허리둘레지수를 동시에 공변량으로 넣었습니다. 출력에서 허리둘레의 $R_j^2 = 0.94$ 였습니다. (a) VIF를 구하시오. (b) 표준오차는 몇 배 부풀었는가? (c) 어떻게 대응해야 하는가?

정답 12

(a) $VIF = \frac{1}{1 - R_j^2} = \frac{1}{0.06} = 16.7$. 기준 10을 크게 넘습니다.

(b) $SE \propto \sqrt{VIF}$ 이므로 $\sqrt{16.7} = 4.08$ 배. 신뢰구간이 4배 넓어지고, 실제로 존재하는 효과도 유의하지 않게 나옵니다. 계수의 부호가 뒤집히는 일도 흔합니다.

(c) 세 가지 선택지:

1. **하나만 남긴다.** 세 지표는 사실상 같은 것(복부비만)을 재고 있습니다. 연구가설에 가장 부합하는 하나(여기서는 체중보정 허리둘레지수)만 넣습니다. 가장 일반적인 해법입니다.
2. **합성한다.** 주성분분석 등으로 하나의 지표를 만듭니다. 단, 해석이 어려워집니다.
3. **그대로 둔다 — 단, 예측이 목적일 때만.** 공선성은 예측 성능을 해치지 않습니다. 개별 계수를 해석하지 않겠다고 명시해야 합니다.

하면 안 되는 것: p 값이 유의한 것만 골라 남기는 단계적 선택(stepwise). 이는 제1종 오류율을 왜곡하고 재현성을 무너뜨립니다.

연결고리

- → **7주차:** 결과 Y 가 이분형이면 선형회귀 대신 로지스틱 회귀. 구조는 동일하고 좌변이 logit으로 바뀔 뿐입니다.
- → **11주차:** 결과가 “시간”이면 Cox 회귀. 역시 β 의 선형결합 구조는 그대로입니다.
- → **12주차:** 회귀로 교란을 보정하는 것과 성향점수로 보정하는 것의 차이가 12주차 주제입니다. 다중공선성과 “어떤 변수를 넣을 것인가”의 문제도 여기서 이어집니다.

7주차 · 로지스틱 회귀와 진단 성능

이번 주 기법 로지스틱 회귀 · 오즈비 · 우도비 검정 · 민감도/특이도 · ROC와 AUC · Youden 절단점 · 보정(calibration) · 순이익(net benefit)

논문 신규 인체계측지표의 근감소증 예측력 (Scientific Reports 2024, PMID 39738342)

한 줄 요약 5주차의 오즈비를 회귀모형 안으로 가져온다. 그리고 “예측이 잘 되는가”를 세 가지 다른 방식으로 평가한다.

7.1 로지스틱 회귀 --- 왜 로짓인가

결과 Y 가 0/1일 때 선형회귀 $p = \beta_0 + \beta_1 x$ 를 쓰면 안 되는 이유는 명백합니다. 우변은 $-\infty$ 부터 $+\infty$ 까지 갈 수 있는데 p 는 $[0, 1]$ 에 갇혀 있습니다. 확률이 -0.3 이나 1.4 가 되어 버립니다.

핵심 수식

확률 p 를 세 단계로 펼칩니다.

$$p \in [0, 1] \xrightarrow{\frac{p}{1-p}} \text{오즈} \in [0, \infty) \xrightarrow{\log} \text{로그오즈} \in (-\infty, \infty)$$

$$\text{logit}(p) = \log \frac{p}{1-p} = \beta_0 + \beta_1 x_1 + \cdots + \beta_p x_p$$

역변환(**로지스틱 함수** 또는 시그모이드):

$$p = \frac{1}{1 + e^{-(\beta_0 + \beta_1 x_1 + \cdots)}} = \frac{e^\eta}{1 + e^\eta}, \quad \eta = \beta_0 + \sum_j \beta_j x_j$$

수식 뜯어보기

- β_j 의 정확한 해석: 다른 변수를 고정한 채 x_j 가 1단위 증가하면 **로그오즈**가 β_j 만큼 증가합니다. 지수를 씌우면

$$e^{\beta_j} = \text{OR} \quad (x_j \text{ 1단위 증가에 대한 오즈비})$$

- k 단위 증가면 $\text{OR} = e^{k\beta_j}$ 입니다. 논문이 “per 1-SD increase”라고 쓰면 $k = \text{SD}$ 를 쓴 것입니다.
- 5주차와의 연결: 공변량이 이분형 노출 하나뿐이면, 로지스틱 회귀의 e^{β_1} 은 2×2 표의 ad/bc 와 정확히 같습니다. 로지스틱 회귀는 “교란변수를 넣을 수 있는 오즈비 계산기”입니다.
- 계수 검정(Wald):

$$z = \frac{\hat{\beta}_j}{\text{SE}(\hat{\beta}_j)} \sim N(0, 1)$$

— 다시 0장의 뼈대입니다.

예시

$\text{logit}(p) = -3 + 0.05 \cdot \text{BMI}$ 인 모형.

BMI	$\eta = -3 + 0.05 \text{ BMI}$	오즈 $= e^\eta$	$p = \frac{e^\eta}{1+e^\eta}$
20	-2.0	0.135	0.119
30	-1.5	0.223	0.182
40	-1.0	0.368	0.269

BMI 1 증가당 $\text{OR} = e^{0.05} = 1.051$ (5.1% 증가). BMI 5 증가당 $\text{OR} = e^{0.25} = 1.284$ (28.4% 증가).

오즈는 정확히 $e^{0.05}$ 배씩 곱해지지만, 확률은 그렇지 않습니다. $0.119 \rightarrow 0.182$ 는 1.53배이고 $0.182 \rightarrow 0.269$ 는 1.48배로 다릅니다. 로지스틱 함수가 S자 곡선이기 때문입니다. 이것이 OR을 확률의 배수로 읽으면 안 되는 근본 이유입니다.

7.2 최대우도추정과 우도비 검정

핵심 수식

로지스틱 회귀는 최소제곱이 아니라 **최대우도**로 추정합니다.

$$L(\beta) = \prod_{i=1}^n p_i^{y_i} (1 - p_i)^{1-y_i}, \quad \ell(\beta) = \sum_{i=1}^n [y_i \log p_i + (1 - y_i) \log(1 - p_i)]$$

우도비 검정(LRT): 축소모형(H_0)과 완전모형을 비교합니다.

$$\Lambda = -2(\ell_{\text{축소}} - \ell_{\text{완전}}) \sim \chi_q^2$$

q = 두 모형의 모수 개수 차이.

수식 뜯어보기

- L 은 “이 β 가 맞다면 지금 관측한 자료가 나올 확률”입니다. 그것을 가장 크게 만드는 β 를 고릅니다.
- 곱을 로그로 바꾸면 합이 되어 계산이 쉬워집니다. 그래서 항상 로그우도 ℓ 을 씁니다.
- -2ℓ 을 **이탈도(deviance)**라 하며, 선형회귀의 잔차제곱합에 해당합니다. LRT는 “변수를 뺐을 때 이탈도가 얼마나 늘어나는가”입니다.
- Wald 검정과 LRT는 대표본에서 같은 답을 내지만 소표본에서는 다릅니다. 계수가 매우 크거나($|\hat{\beta}|$ 가 큰 경우) 완전분리가 있으면 Wald가 무너지므로 LRT가 더 신뢰할 만합니다.

7.3 진단 성능 --- 2×2로 돌아간다

	실제 질병 O	실제 질병 X
검사 양성	TP (진양성)	FP (위양성)
검사 음성	FN (위음성)	TN (진음성)

핵심 수식

$$\begin{aligned}\text{민감도(Sensitivity)} &= \frac{TP}{TP + FN} = P(\text{양성} \mid \text{질병 O}) \\ \text{특이도(Specificity)} &= \frac{TN}{TN + FP} = P(\text{음성} \mid \text{질병 X}) \\ \text{PPV} &= \frac{TP}{TP + FP} = P(\text{질병 O} \mid \text{양성}), \quad \text{NPV} = \frac{TN}{TN + FN}\end{aligned}$$

수식 뜯어보기

민감도/특이도와 PPV/NPV의 결정적 차이는 조건의 방향입니다.

- 민감도·특이도는 **질병 상태를 조건**으로 합니다. 그래서 **유병률과 무관**하며 검사 자체의 고유 성질입니다.
- PPV·NPV는 **검사 결과를 조건**으로 합니다. 그래서 **유병률에 극도로 민감**합니다. 베이지 정리로

$$\text{PPV} = \frac{\text{민감도} \times \pi}{\text{민감도} \times \pi + (1 - \text{특이도})(1 - \pi)}$$

(π = 유병률). 민감도 99%, 특이도 99%인 훌륭한 검사라도 유병률이 0.1%면

$$\text{PPV} = \frac{0.99 \times 0.001}{0.99 \times 0.001 + 0.01 \times 0.999} = \frac{0.00099}{0.01098} = 0.090$$

즉 **양성이 나와도 실제 환자일 확률은 9%**입니다. 이것이 선별검사에서 위양성이 쏟아지는 이유입니다.

- p 값을 “ H_0 가 참일 확률”로 오해하는 것(0장)과 정확히 같은 종류의 조건 뒤집기 오류입니다.

7.4 ROC 곡선과 AUC

핵심 수식

연속형 점수(예: 로지스틱 회귀의 예측확률)에 대해 절단점 c 를 $-\infty$ 에서 $+\infty$ 까지 움직이며

$$(1 - \text{특이도}(c), \text{민감도}(c))$$

를 찍은 곡선이 **ROC 곡선**입니다. 그 아래 면적이 **AUC**입니다.

$$\text{AUC} = P(\text{점수}_{\text{환자}} > \text{점수}_{\text{비환자}})$$

수식 뜯어보기

- AUC의 뜻: 환자 한 명과 비환자 한 명을 무작위로 뽑았을 때, 환자의 점수가 더 높을 확률. 이것이 정확한 정의이며 “정확도”가 아닙니다.
- $AUC = 0.5$ 면 동전 던지기, 1.0 이면 완벽. 0.5 미만이면 부호를 뒤집으면 됩니다.
- 3주차와의 놀라운 연결: Mann-Whitney U 통계량과의 관계가

$$AUC = \frac{U}{n_1 n_0}$$

입니다. 즉 AUC와 Wilcoxon 검정은 같은 양을 계산합니다. Wilcoxon의 $H_0 : P(X_1 > X_0) = 1/2$ 는 정확히 $H_0 : AUC = 0.5$ 입니다.

- 한계: AUC는 **판별력(discrimination)**만 잹니다. 순위만 보기 때문에, 모든 예측확률을 10으로 나뉘도 AUC는 변하지 않습니다. 그래서 보정(calibration)을 따로 봐야 합니다.

Youden 지수

$$J(c) = \text{민감도}(c) + \text{특이도}(c) - 1$$

J 를 최대화하는 c 가 **Youden 절단점**입니다. ROC 곡선에서 대각선으로부터 수직으로 가장 먼 점입니다.

J 는 민감도와 특이도에 똑같은 가중치를 줍니다. 그런데 암 선별에서 위음성(놓친 암)과 위양성(불필요한 조직검사)의 대가는 결코 같지 않습니다. **Youden 절단점이 항상 임상적으로 최적인 것은 아닙니다.** 이 한계를 정면으로 다루는 것이 다음의 결정곡선입니다.

7.5 보정(Calibration)과 순이익(Net Benefit)

핵심 수식

보정: 모형이 “위험 20%”라고 말한 사람들 중 실제로 20%가 발병하는가? 예측확률로 10분위를 나뉘 (평균 예측확률, 관측 발생률)을 찍은 것이 **보정곡선**이며, 이상적으로 기울기 1, 절편 0의 대각선입니다.

순이익 (결정곡선분석, DCA): 문턱확률 p_t 에서

$$NB(p_t) = \frac{TP}{n} - \frac{FP}{n} \cdot \frac{p_t}{1 - p_t}$$

수식 뜯어보기

- p_t 는 “내가 위험이 p_t 이상이면 치료(또는 정밀검사)를 받겠다”는 개인의 문턱입니다.
- $\frac{p_t}{1 - p_t}$ 는 그 문턱의 **오즈**이며, “위양성 1건의 손해가 진양성 1건의 이득에 비해 몇 배인가”라는 **교환비**입니다. 예컨대 $p_t = 0.2$ 면 교환비 = 0.25: 위양성 4건까지는 진양성 1건으로 상쇄된다는 뜻입니다.
- 순이익은 세 가지를 하나로 합칩니다 — 판별력, 보정, 그리고 임상적 가치판단. AUC로는 절대

알 수 없는 “이 모형을 실제로 쓰면 이득인가”를 답합니다.

- 비교 대상은 두 개의 기준선입니다: “전부 치료”와 “아무도 치료 안 함($NB = 0$)”. 모형 곡선이 두 기준선보다 위에 있는 p_t 구간에서만 그 모형은 쓸모가 있습니다.

예시

$n = 500$ 명, 실제 환자 100명. 어떤 절단점에서 $TP = 80$, $FN = 20$, $FP = 50$, $TN = 350$.

$$\text{민감도} = \frac{80}{100} = 0.80, \quad \text{특이도} = \frac{350}{400} = 0.875$$

$$J = 0.80 + 0.875 - 1 = \mathbf{0.675}$$

$$\text{PPV} = \frac{80}{80 + 50} = \frac{80}{130} = 0.615$$

$p_t = 0.2$ 에서의 순이익:

$$NB = \frac{80}{500} - \frac{50}{500} \times \frac{0.2}{0.8} = 0.160 - 0.100 \times 0.25 = 0.160 - 0.025 = \mathbf{0.135}$$

해석: 이 모형을 쓰면 **100명당 13.5명분의 순 진양성**을 얻는 것과 같습니다(위양성 비용을 차감한 뒤).

비교: “전부 양성으로 판정”하면 $TP = 100$, $FP = 400$ 이므로

$$NB_{\text{all}} = \frac{100}{500} - \frac{400}{500}(0.25) = 0.20 - 0.20 = \mathbf{0}$$

“아무도 치료 안 함”도 0입니다. 따라서 이 모형(0.135)은 두 기준선보다 확실히 낫습니다.

문제 13

근감소증 예측을 위해 세 모형을 비교했습니다.

	모형 A	모형 B	모형 C
AUC	0.82	0.82	0.75
보정 절편	0.02	-1.40	0.01
보정 기울기	0.98	0.45	1.02
$p_t = 0.2$ 에서 NB	0.11	0.03	0.09

- (a) A와 B는 AUC가 같은데 왜 NB가 다른가? (b) B의 보정 기울기 0.45는 무엇을 뜻하는가? (c) 임상 적용 대상으로 무엇을 선택하겠는가?

정답 13

(a) AUC는 예측확률의 **순위**만 봅니다. 모든 예측값에 같은 단조 변환을 가해도 AUC는 변하지 않습니다. 따라서 A와 B는 환자를 똑같이 **잘 줄 세우지만**, B는 확률의 **절대 수준**이 틀려 있습니다. NB는 절단점 $p_t = 0.2$ 를 실제 예측확률에 적용하므로 보정이 나쁘면 잘못된 사람들을 양성 판정하게 되어 NB가 급락합니다.

(b) 보정 기울기 < 1 은 **과대적합(overfitting)**의 전형적 신호로, 예측확률이 **너무 극단적으로 퍼져 있다**는 뜻입니다. 낮은 위험군은 실제보다 더 낮게, 높은 위험군은 실제보다 더 높게 예측합니

다. 절편 -1.40 은 전반적으로 위험을 **과대추정**하고 있음을 뜻합니다(예측 위험이 관측보다 체계적으로 높음). 개발 자료에서만 평가하고 외부검증이나 재표본 보정을 하지 않았을 때 흔히 나타납니다.

(c) **모형 A**입니다. AUC가 가장 높으면서(0.82) 보정도 거의 완벽하고(절편 ≈ 0 , 기울기 ≈ 1) NB도 가장 큼니다(0.11).

C는 AUC가 낮지만 보정이 좋아 NB가 0.09 로 나쁘지 않다는 점을 주목하세요 — **AUC가 높다고 임상적으로 더 유용한 것이 아닙니다**. B는 AUC만 보면 A와 동급이지만 실제로는 쓸 수 없는 모형입니다. **판별력·보정·순이익 셋을 모두 보고해야 하는 이유입니다**.

문제 14

7주차 검증과제입니다. 같은 자료·같은 모형식으로 (i) R의 `glm(family=binomial)`, (ii) Python `statsmodels.Logit`, (iii) `sklearn.LogisticRegression`을 돌렸더니 (i)과 (ii)는 소수 넷째 자리까지 일치했는데 (iii)만 계수가 일관되게 0에 가깝게 축소되어 있었습니다. 원인과 해결책은?

정답 14

원인: 규제(regularization)의 기본값 차이입니다.

`sklearn.LogisticRegression`은 기본적으로 **L2 규제를 적용**하며 기본 강도가 $C=1.0$ 입니다. 최소화하는 목적함수가 순수 음의 로그우도가 아니라

$$-\ell(\beta) + \frac{1}{2C} \sum_j \beta_j^2$$

입니다. 두 번째 항이 β 를 0 쪽으로 끌어당기므로(축소), 최대우도추정치보다 절댓값이 작아집니다. R의 `glm`과 `statsmodels.Logit`은 규제가 없는 순수 MLE이므로 서로 일치합니다.

해결책:

- `LogisticRegression(penalty=None)` 으로 규제를 끄거나, C 를 아주 크게(예: 10^{10}) 설정합니다.
- 최적화 알고리즘과 수렴 허용오차도 맞춥니다(`solver='newton-cg'` 또는 `'lbfgs'`, `tol`을 충분히 작게, `max_iter` 충분히 크게).
- 절편에 규제가 걸리는지도 확인합니다(`fit_intercept`, `intercept_scaling`).

교훈: 이것은 “인공지능이 만든 코드의 오류”로 오해하기 쉬운 대표 사례입니다. 세 라이브러리 모두 자기 기본값에서는 정상 작동하고 있습니다. **문제는 기본값이 서로 다르다는 사실을 확인하지 않은 것입니다**. 언어 간 교차검증(10·14주차)에서 반드시 점검해야 할 항목입니다.

논문 읽을 때 확인할 것

- AUC만 보고하고 보정곡선이 없는 예측모형 논문은 절반만 보고한 것입니다.
- AUC의 95% CI가 있는가? 없으면 두 모형의 AUC 차이를 판단할 수 없습니다.
- 절단점을 자료에서 골랐다면(Youden 등) 같은 자료로 성능을 평가한 것은 아닌가? (낙관적 편의)
- 외부검증 또는 최소한 부트스트랩 내부검증(10주차)이 있는가?

- “OR = 3.5이므로 위험이 3.5배”라고 썼다면 5주차의 오류입니다.

8·9주차 · 확률을 직접 계산한다

8주차 Fisher 정확검정의 초기하 확률 열거 · mid- p · 순열검정 · 몬테카를로 오차와 반복 횟수 (C 구현)

9주차 검정력 함수 · 표본수 산출 · 효과크기 설정 · 모의실험 설계 · 몬테카를로 표준오차 (C++ 구현)

논문 8주차는 5주차 논문(PMID 37308938)의 분할표 재현, 9주차는 음성대조설계의 가설검정과 표본수 (BMC Med Res Methodol 2024, PMID 39014324)

한 줄 요약 표에서 찾던 p 값을 직접 만든다. 그리고 연구를 시작하기 전에 필요한 사람 수를 계산한다.

8.1 Fisher 정확검정을 손으로 열거하기

핵심 수식

행합과 열합을 고정하면 2×2 표의 자유도는 1입니다. 즉 칸 a 하나만 정하면 표 전체가 결정됩니다. H_0 하에서

$$P(A = a) = \frac{\binom{r_1}{a} \binom{r_2}{c_1 - a}}{\binom{n}{c_1}}, \quad \max(0, c_1 - r_2) \leq a \leq \min(r_1, c_1)$$

(r_1, r_2 = 행합, c_1 = 첫 열합, n = 총합)

양측 p 값: 관측된 표의 확률 P_{obs} 이하인 모든 표의 확률 합.

$$p_{\text{two-sided}} = \sum_{a: P(a) \leq P_{\text{obs}}} P(a)$$

완전 열거 --- 8주차 C 구현의 목표

표 $\begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$, 즉 $r_1 = r_2 = 4, c_1 = 4, n = 8$. 분모는 $\binom{8}{4} = 70$.

a	표	$\binom{4}{a} \binom{4}{4-a}$	$P(a)$	$P(a) \leq P_{\text{obs}}?$
0	$\begin{pmatrix} 0 & 4 \\ 4 & 0 \end{pmatrix}$	$1 \times 1 = 1$	$1/70 = 0.0143$	예
1	$\begin{pmatrix} 1 & 3 \\ 3 & 1 \end{pmatrix}$	$4 \times 4 = 16$	$16/70 = 0.2286$	예
2	$\begin{pmatrix} 2 & 2 \\ 2 & 2 \end{pmatrix}$	$6 \times 6 = 36$	$36/70 = 0.5143$	아니오
3	$\begin{pmatrix} 3 & 1 \\ 1 & 3 \end{pmatrix}$	$4 \times 4 = 16$	$16/70 = 0.2286$	관측
4	$\begin{pmatrix} 4 & 0 \\ 0 & 4 \end{pmatrix}$	$1 \times 1 = 1$	$1/70 = 0.0143$	예

확률 합 계산: $(1 + 16 + 36 + 16 + 1)/70 = 70/70 = 1 \checkmark$

$$p_{\text{two-sided}} = \frac{1 + 16 + 16 + 1}{70} = \frac{34}{70} = 0.4857$$

단측 ($a \geq 3$): $p_{\text{one}} = \frac{16+1}{70} = \frac{17}{70} = 0.2429$.

8.2 mid- p --- 보수성을 절반만 걷어내기

핵심 수식

$$p_{\text{mid}} = P(\text{관측보다 더 극단}) + \frac{1}{2} P(\text{관측된 표})$$

수식 뜯어보기

- 이유: 이산형 검정통계량에서 “관측된 값 그 자체”를 통째로 극단 영역에 포함시키기 때문에 p 값이 필요 이상으로 커집니다(5주차 “흔한 오해” 참조). mid- p 는 그 덩어리의 절반만 셉니다.
- 성질: 실제 유의수준이 명목 α 에 훨씬 가까워지고 검정력이 올라갑니다. 대신 “ α 를 절대 넘지 않는다”는 보장은 사라집니다(약간 넘을 수 있음). 정확성과 검정력의 교환입니다.
- 위 예시의 단측 mid- p :

$$p_{\text{mid}} = \underbrace{\frac{1}{70}}_{a=4} + \frac{1}{2} \cdot \underbrace{\frac{16}{70}}_{a=3} = \frac{1}{70} + \frac{8}{70} = \frac{9}{70} = 0.1286$$

정확 단측 $p = 0.2429$ 에서 0.1286으로 크게 줄었습니다.

8.3 몬테카를로 오차 --- 반복을 몇 번 해야 하는가

핵심 수식

어떤 확률 π (예: 제1종 오류율, 검정력, 피복확률)를 B 번의 독립 반복으로 추정하면

$$\hat{\pi} = \frac{\#\{\text{성공}\}}{B}, \quad \text{MCSE} = \sqrt{\frac{\hat{\pi}(1 - \hat{\pi})}{B}}$$

95% 몬테카를로 구간: $\hat{\pi} \pm 1.96 \text{ MCSE}$.

수식 뜯어보기

- 성공/실패의 반복이므로 $\#\{\text{성공}\} \sim \text{Binomial}(B, \pi)$ 이고, $\text{Var}(\hat{\pi}) = \pi(1 - \pi)/B$ 입니다. 제공 근을 씌운 것이 MCSE. 0장의 $\text{SE} = s/\sqrt{n}$ 과 완전히 같은 식입니다 — 여기서는 n 이 반복 횟수 B 일 뿐입니다.

- 필요한 B 구하기: $\pi \approx 0.05$ 를 오차 ± 0.005 이내로 추정하려면

$$1.96 \sqrt{\frac{0.05 \times 0.95}{B}} \leq 0.005 \implies B \geq \frac{1.96^2 \times 0.0475}{0.005^2} = \frac{0.18251}{0.000025} = 7300$$

그래서 제1종 오류를 확인에는 흔히 $B = 10,000$ 을 씁니다.

- MCSE는 $1/\sqrt{B}$ 로만 줄어듭니다. 정밀도를 10배 올리려면 계산량이 **100배**입니다. 이것이 8주차를 C로, 9주차를 C++/OpenMP로 구현하는 실질적 이유입니다.

8주차 검증과제: 인공지능의 C 코드에서 찾아야 할 것

1. 나머지 연산에 의한 난수 편향(modulo bias). `rand() % n`은 균등하지 않습니다. `RAND_MAX+1`이 n 의 배수가 아니면 작은 값들이 더 자주 나옵니다. `RAND_MAX = 32767`이고 $n = 10000$ 이면 0-2767이 나올 확률이 나머지보다 50% 높습니다. **해결**: 거부표집(rejection sampling)을 쓰거나 좋은 생성기(PCG, xoshiro, <random>의 mt19937)를 씁니다.
2. 기억장치 누수와 경계 초과. `malloc` 후 `free` 누락, 배열 인덱스가 n 까지 도는 off-by-one. `valgrind`나 `-fsanitize=address`로 확인합니다.
3. 조합수의 오버플로. $\binom{n}{k}$ 를 정수로 직접 계산하면 n 이 조금만 커도 넘칩니다. **로그 감마 함수**를 써야 합니다.

$$\log \binom{n}{k} = \log \Gamma(n+1) - \log \Gamma(k+1) - \log \Gamma(n-k+1)$$

그리고 확률은 `exp`로 되돌립니다. C의 `lgamma()`가 그 함수입니다.

8.4 검정력 --- 9주차의 중심

핵심 수식

검정력은 “실제로 효과가 있을 때 그것을 찾아낼 확률”입니다.

$$\text{Power} = 1 - \beta = P(H_0 \text{ 기각} \mid H_1 \text{ 이 참})$$

두 군 평균 비교(n 명씩, 공통 σ , 참 차이 Δ)에서 정규근사로

$$\text{Power} \approx \Phi \left(\frac{\Delta}{\sigma \sqrt{2/n}} - z_{1-\alpha/2} \right)$$

수식 뜯어보기

- $\frac{\Delta}{\sigma \sqrt{2/n}}$ 을 **비중심 모수(noncentrality parameter)**라 하며, “효과가 표준오차의 몇 배인가”입니다. 이것이 커야 검정력이 올라갑니다.
- 검정력을 올리는 방법은 정확히 네 가지뿐입니다: (i) n 늘리기, (ii) σ 줄이기(측정 정밀화, 동질적 대상), (iii) Δ 키우기(더 강한 개입), (iv) α 키우기(권장되지 않음).

- 짝짓기 설계(3주차 대응 t)는 (ii)를 하는 것입니다. 그래서 검정력이 크게 오릅니다.

표본수 산출 공식

검정력 $1 - \beta$ 를 달성하는 **군당** 표본수는

$$n = \frac{2(z_{1-\alpha/2} + z_{1-\beta})^2 \sigma^2}{\Delta^2}$$

비율 비교(p_1 vs p_2)에서는

$$n = \frac{(z_{1-\alpha/2} + z_{1-\beta})^2 [p_1(1-p_1) + p_2(1-p_2)]}{(p_1 - p_2)^2}$$

수식 뜯어보기

- 흔히 쓰는 상수: $\alpha = 0.05$ 양측이면 $z_{0.975} = 1.960$, 검정력 80%면 $z_{0.80} = 0.8416$, 90%면 $z_{0.90} = 1.2816$.

$$(1.960 + 0.8416)^2 = 2.8016^2 = 7.849 \quad (1.960 + 1.2816)^2 = 3.2416^2 = 10.508$$

- **가장 중요한 성질:** $n \propto 1/\Delta^2$. 찾고자 하는 효과가 절반이면 필요한 사람은 **4배**입니다. 그래서 “작은 효과를 찾는 연구”는 필연적으로 거대해집니다.
- 실무에서는 여기에 탈락률 보정을 합니다. 탈락률 r 이면 $n_{\text{모집}} = n/(1-r)$.

예시

$\sigma = 10$, 임상적으로 의미 있는 차이 $\Delta = 5$, $\alpha = 0.05$ (양측), 검정력 80%.

$$n = \frac{2 \times 7.849 \times 100}{25} = \frac{1569.8}{25} = 62.79 \Rightarrow \mathbf{63 \text{ 명/군}}$$

역방향 확인: 만약 예산 때문에 30명/군밖에 못 모은다면 검정력은?

$$SE = \sigma\sqrt{2/n} = 10\sqrt{2/30} = 10 \times 0.2582 = 2.582$$

$$ncp = \frac{5}{2.582} = 1.936$$

$$\text{Power} \approx \Phi(1.936 - 1.960) = \Phi(-0.024) = \mathbf{0.49}$$

검정력이 49% — 동전 던지기와 다를 바 없습니다. 실제로 효과가 있어도 절반의 확률로 놓칩니다. 이런 연구는 수행 전에 재설계해야 합니다.

사후 검정력(post-hoc power)을 계산하지 마시오

연구가 끝난 뒤 **관측된 효과크기**를 넣어 검정력을 계산하는 것은 의미가 없습니다. 관측 효과크기와 p 값은 일대일로 대응하므로, 사후 검정력은 p 값을 다시 쓴 것에 불과합니다(p 가 크면 사후 검정력은 항상 낮게 나옵니다). 순환논법입니다.

올바른 대안은 **신뢰구간**을 보고하는 것입니다. 구간이 좁고 0 근처면 “효과가 없다”고 말할 수 있

고, 넓으면 “자료가 부족하다”고 말합니다.

8.5 음성대조와 모의실험 설계

음성대조(negative control)는 “효과가 없어야 마땅한 것”을 일부러 분석하는 설계입니다. 예컨대 어떤 노출이 뇌졸중을 일으킨다는 가설을 검증할 때, 인과적으로 관련이 없어야 할 결과(예: 골절)를 함께 분석합니다. 여기서 **유의한 연관**이 나오면 **교란**이나 **편향**이 남아 있다는 증거입니다.

모의실험에서는 이것이 “ H_0 가 참인 자료를 생성해서 제1종 오류율이 정말 α 인지 확인하는” 절차로 나타납니다. 4주차의 p 값 균등성 확인과 같은 것입니다.

모의실험 설계의 표준 골격

1. **시나리오 격자**: 모수 조합(n, Δ, σ , 분포 형태)을 `expand.grid`로 나열.
2. **시드 고정**: 재현 가능해야 함. 병렬화 시 스레드마다 **독립적인** 생성기를 줘야 함.
3. **반복**: 각 조합에서 B 번 자료 생성 → 검정 → 기각 여부 기록.
4. **요약**: $\hat{\pi}$ 와 MCSE를 함께 보고. 이론값과 겹치는지 확인.

9주차 검증과제: 병렬화의 함정

OpenMP로 병렬화할 때 **모든 스레드가 같은 난수 생성기를 공유하면** 두 가지가 동시에 망가집니다.

1. **경쟁 상태(race condition)**: 여러 스레드가 생성기의 내부 상태를 동시에 수정해 결과가 실행할 때마다 달라집니다. 재현 불가.
2. **난수 스트림 중복**: 스레드별로 시드를 `seed+thread_id`처럼 단순하게 주면 스트림이 겹칠 수 있어 반복들이 독립이 아니게 됩니다. MCSE 공식이 무효가 됩니다.

올바른 방법: 스레드마다 별도 생성기 객체를 두고, 겹치지 않는 스트림(예: `philox/counter-based` 생성기, 또는 충분히 분리된 `jump/leapfrog`)을 배정합니다.

검증법은 단순합니다. **병렬화 전후의 결과가 비트 단위로 동일한지 확인**하십시오. 다르다면 난수 관리가 잘못된 것입니다.

문제 15

어떤 임상시험을 설계합니다. 대조군 사건 발생률 $p_0 = 0.20$, 치료군 목표 $p_1 = 0.12$, $\alpha = 0.05$ (양측), 검정력 90%. (a) 군당 필요 표본수를 구하십시오. (b) 예상 탈락률이 15%일 때 실제 모집 인원은? (c) 실제 치료 효과가 예상의 절반($p_1 = 0.16$)이었다면 (a)의 표본수로 얻는 검정력은 대략 얼마인가?

정답 15

(a) $(z_{0.975} + z_{0.90})^2 = (1.960 + 1.2816)^2 = 10.508$.

$$p_0(1 - p_0) = 0.20 \times 0.80 = 0.16, \quad p_1(1 - p_1) = 0.12 \times 0.88 = 0.1056$$

$$n = \frac{10.508 \times (0.16 + 0.1056)}{(0.20 - 0.12)^2} = \frac{10.508 \times 0.2656}{0.0064} = \frac{2.7909}{0.0064} = 436.1$$

⇒ 437명/군, 총 874명.

(b) $n_{\text{모집}} = \frac{437}{1 - 0.15} = \frac{437}{0.85} = 514.1 \Rightarrow 515\text{명/군}$, 총 1,030명.

(c) 차이가 0.08 → 0.04로 절반이 되었습니다. 검정력 공식으로 되짚습니다.

$$p_1(1 - p_1) = 0.16 \times 0.84 = 0.1344$$

$$SE = \sqrt{\frac{0.16 + 0.1344}{437}} = \sqrt{\frac{0.2944}{437}} = \sqrt{0.000674} = 0.02596$$

$$n_{cp} = \frac{0.04}{0.02596} = 1.541$$

$$\text{Power} \approx \Phi(1.541 - 1.960) = \Phi(-0.419) = 0.34$$

검정력이 90%에서 34%로 무너집니다. $n \propto 1/\Delta^2$ 이므로 같은 검정력을 유지하려면 $437 \times 4 \approx 1,748\text{명/군}$ 이 필요합니다.

교훈: 표본수 산출에서 가장 위험한 입력은 Δ 입니다. “바라는 효과”가 아니라 **선행연구에 근거한 보수적인 효과**를 넣어야 합니다.

문제 16

제1종 오류율이 0.05인지 확인하는 모의실험을 $B = 20,000$ 번 돌려 1,064번 기각했습니다. (a) $\hat{\pi}$ 와 MCSE를 구하시오. (b) 명목 수준 0.05와 일치한다고 볼 수 있는가? (c) 만약 이 검정이 Fisher 정확검정이었다면 어떤 결과를 기대해야 하는가?

정답 16

(a)

$$\hat{\pi} = \frac{1064}{20000} = 0.0532$$

$$MCSE = \sqrt{\frac{0.0532 \times 0.9468}{20000}} = \sqrt{\frac{0.050369}{20000}} = \sqrt{2.5185 \times 10^{-6}} = 0.001587$$

(b) 95% 몬테카를로 구간:

$$0.0532 \pm 1.96(0.001587) = 0.0532 \pm 0.00311 = (0.0501, 0.0563)$$

이 구간이 0.05를 **아슬아슬하게 포함하지 않습니다**(하한 0.0501). 즉 제1종 오류율이 명목보다 통계적으로 유의하게 약간 높다는 신호입니다. 다만 실질적 초과분은 0.003 수준으로 작으므로, 원인을 점검하되(정규근사의 소표본 부정확성, 이산성, 코드 버그) 곧바로 치명적 결함이라 단정하지는 않습니다. B 를 더 늘려 재확인하는 것이 적절합니다.

(c) Fisher 정확검정은 **보수적**이므로 $\hat{\pi}$ 가 0.05보다 **작게** 나와야 합니다(예: 0.02–0.04). 만약 0.05를 넘게 나온다면 구현이 잘못된 것입니다. 반대로 mid- p 를 쓰면 0.05에 훨씬 가까워지고 때로는 살짝 넘습니다. **이 세 값의 대소 관계를 확인하는 것이 5주차와 8주차를 잇는 검증 과제입니다.**

연결고리

- **3주차 순열검정** = 무작위로 섞어서 귀무분포를 근사. **8주차 Fisher** = 전부 세어서 귀무분포를 정확히 구성. 같은 아이디어, 다른 계산 예산.
- **MCSE 공식** $\sqrt{\hat{\pi}(1 - \hat{\pi})/B}$ 는 0장 $SE = s/\sqrt{n}$ 의 이항 버전이며, 10주차 부트스트랩 피복확률 평가에서 그대로 재사용됩니다.
- **9주차** $n \propto 1/\Delta^2$ 는 0장 $SE \propto 1/\sqrt{n}$ 의 뒷면입니다.

10주차 · 부트스트랩

이번 주 기법 부트스트랩 신뢰구간 5종(정규근사·기본·백분위수·BCa·스튜던트화) · 피복확률 · 역확률가중
논문 역확률가중으로 추정된 류마티스관절염의 연간 비용 (PLOS ONE 2025, PMID 40853930)
한 줄 요약 표준오차 공식이 없는 추정치에도 신뢰구간을 만들 수 있다. 자료를 다시 뽑아서.

9.1 왜 부트스트랩인가

0장에서 신뢰구간은 $\hat{\theta} \pm c \text{SE}(\hat{\theta})$ 였습니다. 그런데 SE를 어떻게 구하죠? 평균이면 $s/\sqrt{n}$ 이라는 공식이 있습니다. 그러면 **중앙값**의 표준오차는? **두 중앙값의 비**는? **역확률가중 평균 비용**은? 공식이 없거나 매우 복잡합니다.

부트스트랩의 핵심 아이디어

이상적으로는 모집단에서 표본을 여러 번 뽑아 $\hat{\theta}$ 의 흠어짐을 보면 됩니다. 그런데 모집단이 없습니다. 그래서 우리가 가진 표본을 모집단인 셈 치고 거기서 다시 뽑습니다.

	이상	부트스트랩
무엇에서 뽑나	모집단 F	경험분포 $\hat{F}$ (= 내 표본)
어떻게 뽑나	크기 n 의 새 표본	크기 n 복원추출
몇 번	∞	B 번 (1000~10000)

절차

1. 원표본 $x_1, \dots, x_n$ 에서 복원추출로 크기 n 의 표본 x^* 를 만든다.
2. 그 표본에서 통계량 $\hat{\theta}_1^*$ 을 계산한다.
3. B 번 반복 $\Rightarrow \hat{\theta}_1^*, \dots, \hat{\theta}_B^*$ (**부트스트랩 분포**).

$$\widehat{\text{SE}}_{\text{boot}} = \sqrt{\frac{1}{B-1} \sum_{b=1}^B (\hat{\theta}_b^* - \bar{\hat{\theta}})^2}, \quad \widehat{\text{bias}} = \bar{\hat{\theta}} - \hat{\theta}$$

수식 뜯어보기

복원추출이 핵심입니다. 비복원으로 n 개를 뽑으면 항상 원표본과 똑같아서 아무 정보도 안 나옵니다. 복원추출을 하면 어떤 값은 두 번 뽑히고 어떤 값은 안 뽑혀서, “표본이 조금 달랐다면”이라는 상황이 만들어집니다.

참고로 한 관측치가 부트스트랩 표본에 **안 뽑힐** 확률은

$$\left(1 - \frac{1}{n}\right)^n \xrightarrow{n \rightarrow \infty} e^{-1} = 0.368$$

즉 각 부트스트랩 표본은 평균적으로 원자료의 63.2%만 담고 있습니다. 이 0.632가 부트스트랩 기반 내부검증(.632 추정량)에 등장하는 그 숫자입니다.

9.2 신뢰구간 5종

$\hat{\theta}_{(\alpha)}^*$ 를 부트스트랩 분포의 100α 백분위수라 합시다.

핵심 수식

① 정규근사(normal)

$$\hat{\theta} \pm z_{1-\alpha/2} \widehat{SE}_{boot}$$

가장 단순. 부트스트랩을 SE 계산에만 씁니다. 분포가 치우쳐 있으면 부정확합니다.

② 백분위수(percentile)

$$\left[\hat{\theta}_{(\alpha/2)}^*, \hat{\theta}_{(1-\alpha/2)}^* \right]$$

부트스트랩 분포의 양 끝을 그대로 씁니다. 가장 직관적이며 변환에 불변입니다.

③ 기본(basic / pivotal)

$$\left[2\hat{\theta} - \hat{\theta}_{(1-\alpha/2)}^*, 2\hat{\theta} - \hat{\theta}_{(\alpha/2)}^* \right]$$

백분위수 구간을 $\hat{\theta}$ 기준으로 뒤집은 것입니다.

④ BCa (bias-corrected and accelerated)

$$\hat{z}_0 = \Phi^{-1} \left(\frac{\#\{\hat{\theta}_b^* < \hat{\theta}\}}{B} \right), \quad \hat{a} = \frac{\sum_i (\bar{\theta}_{(\cdot)} - \hat{\theta}_{(i)})^3}{6 \left[\sum_i (\bar{\theta}_{(\cdot)} - \hat{\theta}_{(i)})^2 \right]^{3/2}}$$

($\hat{\theta}_{(i)}$ 는 i 번째 관측치를 뺀 jackknife 추정치)

$$\alpha_1 = \Phi \left(\hat{z}_0 + \frac{\hat{z}_0 + z_{\alpha/2}}{1 - \hat{a} (\hat{z}_0 + z_{\alpha/2})} \right), \quad \alpha_2 = \Phi \left(\hat{z}_0 + \frac{\hat{z}_0 + z_{1-\alpha/2}}{1 - \hat{a} (\hat{z}_0 + z_{1-\alpha/2})} \right)$$

$$\text{구간} = \left[\hat{\theta}_{(\alpha_1)}^*, \hat{\theta}_{(\alpha_2)}^* \right]$$

⑤ 스튜던트화(studentized / bootstrap-t)

$$t_b^* = \frac{\hat{\theta}_b^* - \hat{\theta}}{\widehat{SE}_b^*}, \quad \left[\hat{\theta} - t_{(1-\alpha/2)}^* \widehat{SE}, \hat{\theta} - t_{(\alpha/2)}^* \widehat{SE} \right]$$

부트스트랩 표본마다 또 표준오차를 구해야 하므로(이중 부트스트랩) 계산량이 가장 큽니다.

수식 뜯어보기

- ② 백분위수 vs ③ 기본이 왜 다른가? 부트스트랩 분포가 오른쪽으로 치우쳐 있다고 합시다. 백분위수 구간은 오른쪽으로 길어집니다. 그런데 논리적으로는 " $\hat{\theta}^*$ 이 $\hat{\theta}$ 보다 자주 크게 나온다"는 것은 " $\hat{\theta}$ 가 참값 θ 보다 클 가능성이 높다"는 뜻이므로, 구간은 오히려 **왼쪽**으로 길어야 합니다.

기본 구간이 그 뒤집기를 합니다. 두 구간은 $\hat{\theta}$ 에 대해 정확히 거울상입니다.

• ④ BCa의 두 보정:

- $\hat{z}_0$ (편의 보정): 부트스트랩 분포의 중앙값이 $\hat{\theta}$ 와 일치하면 $\#\{\hat{\theta}^* < \hat{\theta}\}/B = 0.5$ 이므로 $\hat{z}_0 = \Phi^{-1}(0.5) = 0$ 입니다. 어긋난 만큼 백분위수를 밀어 줍니다.
- $\hat{a}$ (가속): 표준오차가 θ 의 값에 따라 변하는 정도(왜도)를 잡아 줍니다.

둘 다 0이면 BCa는 백분위수 구간과 정확히 같아집니다.

- 이론적 정확도: BCa와 스튜던트화는 **2차 정확**(오차 $O(n^{-1})$), 백분위수·기본·정규근사는 **1차 정확**(오차 $O(n^{-1/2})$)입니다. 그래서 **비용** 자료처럼 심하게 치우친 자료에서는 BCa 또는 스튜던트화를 써야 합니다. 10주차 논문이 의료비를 다루는 이유입니다.

예시

$B = 1000$, $\hat{\theta} = 50.0$, 부트스트랩 분포의 백분위수가 $\hat{\theta}_{(0.025)}^* = 44.0$, $\hat{\theta}_{(0.975)}^* = 62.0$, $\widehat{SE}_{boot} = 4.5$, 그리고 $\widehat{\theta}^* = 51.2$.

① 정규근사: $50.0 \pm 1.96(4.5) = (41.2, 58.8)$

② 백분위수: $(44.0, 62.0)$

③ 기본: $(2(50) - 62, 2(50) - 44) = (38.0, 56.0)$

편의: $bias = 51.2 - 50.0 = +1.2$ (부트스트랩 분포가 오른쪽으로 치우침)

세 구간이 확연히 다릅니다. 백분위수는 오른쪽으로, 기본은 왼쪽으로 길고, 정규근사는 대칭입니다. 치우친 자료에서 어느 것을 쓰느냐로 결론이 바뀔 수 있습니다. 이때는 BCa로 판단해야 합니다.

BCa의 편의보정 항: 만약 1000개 중 600개가 $\hat{\theta} = 50$ 보다 작았다면

$$\hat{z}_0 = \Phi^{-1}(0.600) = 0.2533$$

$\hat{z}_0 > 0$ 이므로 구간 전체가 위쪽으로 밀립니다.

9.3 피복확률 --- 신뢰구간을 평가하는 방법

핵심 수식

참값 θ 를 아는 상황을 컴퓨터로 만들고, 자료 생성 → 구간 계산을 B 번 반복합니다.

$$\widehat{\text{피복확률}} = \frac{\#\{b : \theta \in CI_b\}}{B}$$

95% 구간이라면 이 값이 0.95에 가까워야 합니다.

수식 뜯어보기

- 이것이 0장에서 말한 신뢰구간의 **정확한 정의를 실험으로 확인하는 절차**입니다.
- 피복확률이 0.90이면 **과소피복**: 구간이 너무 좁아 참값을 자주 놓칩니다. 실제 제1종 오류율이 0.10인 셈으로, 위험합니다.

- 피복확률이 0.99면 **과대피복**: 너무 보수적이라 검정력을 잃습니다.
- 평가에는 MCSE가 함께 필요합니다(8·9주차). $B = 2000$, 참 피복확률 0.95라면

$$MCSE = \sqrt{\frac{0.95 \times 0.05}{2000}} = 0.00487$$

따라서 $0.95 \pm 1.96(0.00487) = (0.940, 0.960)$ 안에 들면 정상입니다. 0.945가 나왔다고 놀랄 일이 아닙니다.

- 피복확률만 보면 안 됩니다. **구간 폭과 양쪽 비피복의 균형**(왼쪽으로 놓친 비율 vs 오른쪽으로 놓친 비율이 각각 2.5%인지)도 봐야 합니다. 치우친 자료에서 백분위수 구간은 전체 피복은 95%인데 한쪽으로만 몰려서 놓치는 경우가 흔합니다.

9.4 역확률가중(IPW) --- 부트스트랩이 필요한 대표 상황

핵심 수식

각 개인이 처치를 받을 확률(**성향점수**) $e(X_i) = P(A_i = 1 | X_i)$ 를 추정된 뒤, 그 역수로 가중합니다.

$$\hat{\mu}_1 = \frac{1}{n} \sum_{i=1}^n \frac{A_i Y_i}{\hat{e}(X_i)}, \quad \hat{\mu}_0 = \frac{1}{n} \sum_{i=1}^n \frac{(1 - A_i) Y_i}{1 - \hat{e}(X_i)}$$

(Horvitz-Thompson 형태. 분모를 가중치 합으로 바꾸면 Hájek 형태이며 보통 더 안정적입니다.)

수식 뜯어보기

- 직관: 성향점수가 0.2인 사람이 실제로 처치를 받았다면, 그런 사람은 드물게 처치를 받으므로 자기 같은 사람 5명을 대표합니다. 가중치 $1/0.2 = 5$.
- 2주차 표본가중치와 정확히 같은 논리입니다. 거기서는 설계로 정해진 확률이었고, 여기서는 자료로 추정한 확률입니다.
- 왜 부트스트랩이 필요한가: $\hat{e}$ 를 자료에서 추정했기 때문에 $\hat{\mu}_1$ 의 표준오차 공식이 매우 복잡합니다(추정된 가중치의 불확실성이 전파됨). 부트스트랩은 **성향점수 추정 단계부터 통째로 반복**하면 이를 자동으로 반영합니다.
- 중요: 부트스트랩 표본마다 성향점수 모형을 다시 적합해야 합니다. 원자료에서 한 번 추정한 $\hat{e}$ 를 고정한 채 결과만 재표집하면 표준오차가 과소추정됩니다. 인공지능이 작성한 코드에서 흔히 나오는 오류입니다.

극단 가중치

$\hat{e}(X_i)$ 가 0이나 1에 가까우면 가중치가 폭발합니다($1/0.01 = 100$). 한 사람이 추정치를 지배하게 되어 분산이 거대해집니다.

대응: (i) **절단(truncation)** — 상위 1% 가중치를 잘라냄, (ii) **안정화 가중치** — 분자에 주변확률을 곱함, (iii) **겹침 확인** — 성향점수 분포가 두 군에서 겹치는 영역만 분석(12주차의 positivity).

문제 17

연간 의료비 자료($n = 200$, 심한 우측 치우침)에서 평균 비용을 부트스트랩($B = 2000$)했습니다. $\hat{\theta} = 4,820$ 천원, $\hat{\theta}^* = 4,835$, $\widehat{SE}_{boot} = 640$, $\hat{\theta}_{(0.025)}^* = 3,690$, $\hat{\theta}_{(0.975)}^* = 6,220$. (a) 정규근사·백분위수·기본 구간을 각각 구하시오. (b) 세 구간의 모양을 비교하고 어느 것을 보고해야 하는지 논하시오. (c) 부트스트랩 편향 추정치는?

정답 17

(a)

① 정규근사: $4820 \pm 1.96(640) = 4820 \pm 1254.4 = (3565.6, 6074.4)$

② 백분위수: (3690, 6220)

③ 기본: $(2(4820) - 6220, 2(4820) - 3690) = (9640 - 6220, 9640 - 3690) = (3420, 5950)$

(b) $\hat{\theta} = 4820$ 을 기준으로 각 구간의 좌우 길이를 봅니다.

	왼쪽 길이	오른쪽 길이	대칭성
정규근사	1254	1254	완전 대칭
백분위수	1130	1400	오른쪽으로 김
기본	1400	1130	왼쪽으로 김

백분위수와 기본이 정확히 거울상입니다. 자료가 심하게 우측 치우침이므로 대칭인 정규근사는 부적절합니다.

보고해야 할 것은 BCa 또는 스튜던트화 구간입니다. 이 셋은 모두 1차 정확에 그치고, 치우침이 클수록 실제 피복확률이 95%에서 벗어납니다. 특히 의료비 자료에서는 백분위수 구간이 종종 과소피복을 보입니다. BCa는 편향($\hat{\zeta}_0$)과 왜도($\hat{a}$)를 모두 보정하므로 이런 상황을 위해 설계된 것입니다.

(c)

$$\widehat{bias} = \hat{\theta}^* - \hat{\theta} = 4835 - 4820 = +15 \text{ 천원}$$

$\widehat{SE} = 640$ 에 비하면 $15/640 = 2.3\%$ 로 작습니다. 일반적으로 편향/표준오차 비가 0.25 미만이면 무시할 만합니다. 여기서는 편향 보정이 크게 필요하지 않으며, 따라서 BCa와 백분위수의 차이는 주로 $\hat{a}$ (왜도)에서 올 것입니다.

문제 18

10주차 검증과제입니다. 같은 부트스트랩을 R, Python, Rust로 구현했더니 $\widehat{SE}$ 가 각각 640, 637, 645로 조금씩 달랐습니다. (a) 원인은 무엇인가? (b) 세 언어의 결과가 완전히 동일하도록 만들려면 어떻게 설계해야 하는가? (c) 그것이 불가능하다면 무엇으로 “일치”를 판정해야 하는가?

정답 18

(a) 난수 생성기가 언어마다 다르기 때문입니다. R의 기본은 Mersenne-Twister에 Inversion 방식, NumPy는 PCG64(신버전) 또는 MT19937(레거시), Rust의 rand는 ChaCha 또는 Xoshiro 계열입니다. 시드를 같은 숫자로 줘도 생성되는 난수열이 전혀 다릅니다. 또한 같은 생성기라도 “0~ $n-1$ 의 정수를 뽑는” 방법(나머지 연산, 거부표집, Lemire 기법)이 달라 추출 인덱스가 달라 집니다.

따라서 637, 640, 645의 차이는 **버그가 아니라 몬테카를로 변동**입니다.

(b) 교차검증이 가능하도록 하려면 **난수를 언어 밖으로 빼내야** 합니다.

- 한 언어(또는 독립 스크립트)에서 $B \times n$ 크기의 **부트스트랩 인덱스 행렬**을 한 번 생성해 CSV로 저장한다.
- 세 언어 모두 그 파일을 읽어 **같은 재표본**에 대해 통계량을 계산한다.
- 이렇게 하면 세 결과가 부동소수점 오차 수준(대략 10^{-12})까지 일치해야 합니다. 일치하지 않으면 **그때는 진짜 구현 오류**입니다.

이것이 “교차검증이 가능한 조건을 직접 설계하라”는 검증과제의 답입니다.

(c) 난수를 공유할 수 없다면, **일치 여부는 MCSE 기준으로** 판정합니다. $B = 2000$, $\widehat{SE} \approx 640$ 일 때 표준오차 추정치 자체의 몬테카를로 변동은 대략

$$SE(\widehat{SE}) \approx \frac{\widehat{SE}}{\sqrt{2(B-1)}} = \frac{640}{\sqrt{3998}} = \frac{640}{63.2} \approx 10.1$$

관측된 최대 차이는 $645 - 637 = 8$ 로 1 MCSE 이내입니다. **일치한다고 판정합니다**. 만약 차이가 3 MCSE(약 30)를 넘는다면 구현을 의심해야 합니다.

연결고리

- → **3·8주차**: 순열검정은 라벨을 섞어 **귀무분포**를, 부트스트랩은 자료를 복원추출해 **추정치**의 분포를 만듭니다. 목적이 다릅니다.
- → **2주차**: IPW 가중치와 NHANES 표본가중치는 같은 구조(1/선택확률)입니다.
- → **12주차**: 여기서 나온 성향점수가 12주차의 주인공이 됩니다.
- → **7주차**: 예측모형의 내부검증(낙관적 편의 보정)도 부트스트랩으로 합니다.

11주차 · 생존분석

이번 주 기법 Kaplan–Meier 추정 · log-rank 검정 · Cox 비례위험모형 · 비례위험 가정 검정 · 제한 3차 스플라인

논문 암 생존자의 혈당 수준과 전체 사망의 연관 (BMC Public Health 2024, PMID 39061034)

한 줄 요약 결과가 “발생했는가”가 아니라 “언제 발생했는가”일 때. 그리고 아직 발생하지 않은 사람을 버리지 않는 법.

10.1 절단(censoring) --- 생존분석이 따로 존재하는 이유

10년 추적 연구에서 어떤 참가자가 7년 시점에 이사를 가서 연락이 끊겼습니다. 그 사람은 죽었나요? 모릅니다. 아는 것은 “적어도 7년은 살았다”뿐입니다. 이것을 **우측 절단(right censoring)**이라 합니다.

흔한 오해

이 사람을 어떻게 처리하느냐가 생존분석의 전부입니다.

- 제외한다 → 정보 손실이 크고, 추적 실패가 무작위가 아니면 편향됩니다.
- “생존”(=0)으로 코딩한다 → 완전히 틀립니다. 10년 내내 관찰된 생존자와 7년만 관찰된 사람을 같게 취급하는 것입니다.
- 생존분석 → 7년까지는 위험집합에 포함시키고, 그 이후부터 제외합니다. 가진 정보만큼만 씁니다.

11주차 검증과제가 “인공지능이 절단 자료를 이분형으로 축약하는지 확인하라”고 하는 이유입니다. 시간 정보를 버리고 로지스틱 회귀를 돌리는 것은 매우 흔한 오류입니다.

생존분석의 기본 함수들

$S(t) = P(T > t)$ 생존함수: t 시점까지 살아 있을 확률

$h(t) = \lim_{\Delta t \rightarrow 0} \frac{P(t \leq T < t + \Delta t \mid T \geq t)}{\Delta t}$ 위험함수

$H(t) = \int_0^t h(u) du$ 누적위험함수, $S(t) = \exp(-H(t))$

$h(t)$ 의 조건 $T \geq t$ 가 핵심입니다. “지금까지 살아 있는 사람 중에서” 바로 다음 순간 사건이 일어날 순간적 비율입니다. S 는 누적, h 는 순간속도라고 생각하면 됩니다.

10.2 Kaplan--Meier 추정

핵심 수식

사건이 발생한 시점들을 $t_1 < t_2 < \dots$ 라 하고, t_j 직전의 **위험집합** 크기를 n_j , 그 시점의 사건 수를 d_j 라 하면

$$\hat{S}(t) = \prod_{j: t_j \leq t} \left(1 - \frac{d_j}{n_j}\right)$$

분산은 Greenwood 공식:

$$\widehat{\text{Var}}(\hat{S}(t)) = \hat{S}(t)^2 \sum_{j: t_j \leq t} \frac{d_j}{n_j(n_j - d_j)}$$

수식 뜯어보기

- $\left(1 - \frac{d_j}{n_j}\right)$ 은 “ t_j 까지 살아 있던 사람이 그 순간을 넘길 조건부 확률”입니다.
- 전체 생존확률은 그 조건부 확률들의 곱입니다. 확률의 곱셈법칙 그대로입니다.

$$P(T > t_3) = P(T > t_1) \cdot P(T > t_2 | T > t_1) \cdot P(T > t_3 | T > t_2)$$

그래서 KM을 **곱-한계 추정량(product-limit estimator)**이라 부릅니다.

- 절단은 n_j 를 줄일 뿐 d_j 에 들어가지 않습니다. 이것이 절단을 다루는 정확한 방식입니다.
- KM 곡선은 사건이 있을 때만 아래로 떨어지는 계단함수입니다. 절단은 보통 + 표시로 나타냅니다.
- 논문의 KM 그림에는 반드시 **위험집합표(number at risk)**가 아래에 붙어야 합니다. 곡선 끝 부분은 n_j 가 아주 작아 매우 불안정하기 때문입니다.

예시

10명으로 시작. $t = 2$ 에 1명 사망, $t = 4$ 에 1명 절단, $t = 5$ 에 2명 사망.

t_j	위험집합 n_j	사건 d_j	절단	$1 - d_j/n_j$	$\hat{S}(t_j)$
2	10	1	0	$1 - \frac{1}{10} = 0.900$	0.900
4	9	0	1	—	0.900
5	8	2	0	$1 - \frac{2}{8} = 0.750$	$0.900 \times 0.750 = \mathbf{0.675}$

$t = 4$ 의 절단자는 곡선을 떨어뜨리지 않지만 위험집합을 $9 \rightarrow 8$ 로 줄입니다. 그 결과 $t = 5$ 의 분모가 8이 되어 **남은 사람들의 사망이 더 큰 무게를** 갖습니다. 절단자를 그냥 제외했다면 분모가 달라져 추정치가 편향됩니다.

10.3 Log-rank 검정

핵심 수식

각 사건 시점 t_j 에서 2×2 표를 만듭니다. 주변합이 고정된 상태에서 H_0 (두 군의 생존곡선이 같다) 하의 기대값과 분산은 초기하분포로부터

$$E_{1j} = d_j \cdot \frac{n_{1j}}{n_j}, \quad V_j = \frac{n_{1j} n_{2j} d_j (n_j - d_j)}{n_j^2 (n_j - 1)}$$

$$\chi^2_{\log\text{-rank}} = \frac{\left(\sum_j O_{1j} - \sum_j E_{1j}\right)^2}{\sum_j V_j} \sim \chi^2_1$$

수식 뜯어보기

- 이것은 5주차 χ^2 과 8주차 초기하분포의 결합입니다. 각 사건 시점마다 Fisher 정확검정의 초기하 구조를 세우고, 그것들을 시간에 걸쳐 합칩니다.
- 형태를 보세요: $\frac{(O - E)^2}{V}$ — 정확히 0장의 뼈대입니다.
- log-rank는 비례위험 상황에서 가장 강력합니다. 반대로 두 곡선이 교차하면 $O - E$ 가 앞뒤에서 상쇄되어 검정력을 거의 잃습니다. 그림을 반드시 먼저 봐야 하는 이유입니다.

10.4 Cox 비례위험모형

핵심 수식

$$h(t | \mathbf{x}) = h_0(t) \exp(\beta_1 x_1 + \cdots + \beta_p x_p)$$

$$\text{HR} = \frac{h(t | x + 1)}{h(t | x)} = e^\beta$$

모수는 **부분우도(partial likelihood)**로 추정합니다.

$$L(\beta) = \prod_{j: \text{사건}} \frac{\exp(\beta^\top \mathbf{x}_{(j)})}{\sum_{k \in R(t_j)} \exp(\beta^\top \mathbf{x}_k)}$$

$R(t_j)$ 는 t_j 시점의 위험집합입니다.

수식 뜯어보기

- Cox 모형의 천재적인 점: $h_0(t)$ (기저위험)를 전혀 추정하지 않습니다. 부분우도의 분자와 분모에 똑같이 $h_0(t_j)$ 가 들어가 약분되기 때문입니다. 그래서 “위험이 시간에 따라 어떻게 변하는가”를 몰라도 “군 간 위험비”는 추정할 수 있습니다. 그래서 **준모수적(semiparametric)**이라 부릅니다.
- 부분우도의 각 항은 “ t_j 시점에 위험집합에 있던 사람들 중, 하필 이 사람이 사건을 겪을 조건부

확률”입니다.

- **비례위험 가정:** $HR = e^{\beta}$ 에 t 가 없습니다. 즉 위험비가 시간에 무관하게 일정하다고 가정합니다. 이것이 Cox 모형의 유일하고 가장 중요한 가정입니다.
- **7주차와의 대응:** 로지스틱은 $\log(\text{오즈}) = \beta^T \mathbf{x}$ 이고 Cox는 $\log(\text{위험}) = \log h_0(t) + \beta^T \mathbf{x}$ 입니다. 좌변만 다르고 우변 구조는 동일합니다.

10.5 비례위험 가정의 검정 --- Schoenfeld 잔차

핵심 수식

각 사건 시점에서, 실제로 사건을 겪은 사람의 공변량값과 위험집합의 가중평균의 차이가 **Schoenfeld 잔차**입니다.

$$r_j = \mathbf{x}_{(j)} - \bar{\mathbf{x}}(\hat{\beta}, t_j), \quad \bar{\mathbf{x}} = \frac{\sum_{k \in R(t_j)} \mathbf{x}_k e^{\hat{\beta}^T \mathbf{x}_k}}{\sum_{k \in R(t_j)} e^{\hat{\beta}^T \mathbf{x}_k}}$$

검정: 척도화 Schoenfeld 잔차를 시간(또는 $\log t$, 순위)에 회귀시켜 기울기가 0인지 봅니다.

$$H_0 : \text{기울기} = 0 \iff \text{비례위험 성립}$$

R에서 `cox.zph()`가 이것입니다.

수식 뜯어보기

직관: 비례위험이 성립하면 잔차는 시간에 걸쳐 **무작위로 0 주변에 흩어져야** 합니다. 만약 잔차가 시간에 따라 증가한다면, 나중 시점일수록 실제 사건자가 예상보다 높은 공변량값을 갖는다는 뜻 — 즉 β 가 시간에 따라 커지고 있다는 뜻입니다.

가정이 깨졌을 때의 대안:

1. **시간분할:** 0-2년, 2-5년, 5년 이상으로 나누어 구간별 HR을 보고합니다.
2. **시간의존 계수:** $\beta(t) = \beta_0 + \beta_1 \log t$ 같은 상호작용항을 넣습니다.
3. **층화 Cox:** 위배되는 변수를 `strata()`로 넣어 그 변수별로 다른 $h_0(t)$ 를 허용합니다. 단, 그 변수의 HR은 추정되지 않습니다.
4. **RMST:** 제한 평균 생존시간(restricted mean survival time)은 비례위험을 가정하지 않는 요약치입니다.

10.6 제한 3차 스플라인 --- 선형성 가정을 푸는 법

혈당과 사망의 관계는 직선일까요? 아닐 가능성이 높습니다(저혈당도 위험, 고혈당도 위험 = J자 곡선). 그런데 Cox 모형은 $\beta \cdot x$ 로 **선형**을 가정합니다.

핵심 수식

제한 3차 스플라인(restricted cubic spline, RCS)은 x 의 범위를 매듭(knot) $k_1 < \dots < k_K$ 로 나누고, 구간마다 3차 다항식을 이어 붙이되

- 매듭에서 함수값·1차·2차 도함수가 연속이고,
- 양 끝 구간에서는 선형이 되도록 제한합니다(“제한”의 뜻).

K 개 매듭이면 자유도는 $K - 1$ 이고, 비선형성 검정은 $\beta_2 = \dots = \beta_{K-1} = 0$ 에 대한 우도비 검정입니다.

수식 뜯어보기

왜 끝을 선형으로 제한할까요? 3차 다항식은 자료가 희박한 양 끝에서 미친 듯이 요동칩니다. 끝을 직선으로 묶으면 그 불안정이 사라집니다.

매듭 개수는 보통 3~5개이며, 위치는 백분위수(예: 5, 27.5, 50, 72.5, 95%)에 놓습니다. **자료를 보고 매듭을 고르면 안 됩니다** — 그러면 검정의 제1종 오류율이 왜곡됩니다.

범주화보다 스플라인이 나은 이유: 연속변수를 사분위군으로 자르면 (i) 정보가 버려지고, (ii) 같은 군 안의 극단값들이 같게 취급되며, (iii) 절단점 위치에 따라 결과가 달라집니다. 스플라인은 이 셋을 모두 피합니다.

문제 19

어떤 논문이 혈당 사분위군 Q4 대 Q1의 사망 위험비를 $HR = 1.49$ (95% CI 1.12-1.98)로 보고했습니다. (a) $\hat{\beta}$ 와 $SE(\hat{\beta})$ 를 역산하시오. (b) $HR = 1.49$ 를 정확한 문장으로 해석하시오. “사망률이 49% 높다”가 왜 부정확한가? (c) `cox.zph()`의 $p = 0.003$ 이 나왔습니다. 무엇을 해야 하는가?

정답 19

(a) $\hat{\beta} = \log(1.49) = 0.3988$.

신뢰구간은 로그 스케일에서 대칭이므로

$$\log(1.98) - \log(1.12) = 0.6831 - 0.1133 = 0.5698 = 2 \times 1.96 \times SE$$

$$SE(\hat{\beta}) = \frac{0.5698}{3.92} = 0.1454$$

검산: $\hat{\beta}$ 의 중점 = $\frac{0.1133+0.6831}{2} = 0.3982 \approx 0.3988$ ✓ (반올림 오차)

Wald $z = 0.3988/0.1454 = 2.74$, $p = 0.006$.

(b) 정확한 해석: “다른 공변량이 같을 때, Q1군에 비해 Q4군의 순간 사망 위험(hazard)이 추적 기간 전체에 걸쳐 일정하게 1.49배이다.”

“사망률이 49% 높다”가 부정확한 이유는 두 가지입니다.

1. **hazard는 risk가 아닙니다.** hazard는 순간 비율이고 risk는 누적 확률입니다. 사건이 흔하면 HR과 위험비(RR)가 크게 벌어집니다 — 5주차의 OR/RR 문제와 같은 구조입니다. 실제 5년 사망 확률의 비는 1.49보다 작습니다.
2. “추적기간 전체에 걸쳐 일정하게”를 빼면 안 됩니다. 이것이 비례위험 가정이며, HR이라는 단 일 숫자가 의미를 갖기 위한 전제입니다.

(c) $p = 0.003$ 은 비례위험 가정이 위배되었다는 뜻입니다. 즉 HR이 시간에 따라 변합니다. 이 경

우 HR = 1.49라는 단일 숫자는 서로 다른 시기의 위험비를 평균낸 것에 불과해 해석이 어렵습니다.

해야 할 일:

1. **Schoenfeld 잔차 그림을 본다.** 기울기가 양수인지 음수인지, 특정 시점에서 꺾이는지 확인합니다.
2. **시간분할:** 예컨대 0-5년 HR과 5년 이후 HR을 따로 보고합니다. “초기에는 강한 연관이 있으나 시간이 지나며 약해진다”처럼 서술이 구체적이 됩니다.
3. 또는 **RMST 차이**를 함께 보고합니다(“5년간 평균 생존기간이 X개월 짧다”).
4. 논문에 **가정 위배 사실과 대응을 명시**합니다. $p = 0.003$ 을 알고도 단일 HR만 보고하는 것은 부적절합니다.

문제 20

NHANES Linked Mortality File로 재현하는데, 논문은 사건 수 1,204건, 추적 인년(person-years) 68,500을 보고했습니다. 여러분의 코드는 사건 1,204건(일치), 인년 74,100(불일치)을 냈습니다. (a) 가능한 원인을 두 가지 제시하시오. (b) 조사망률(crude rate)을 각각 계산하고 차이가 결과에 미치는 영향을 논하시오.

정답 20

(a)

1. **추적 시작 시점(time origin)의 정의 차이.** 조사 참여일부터인지, 검진일부터인지, 아니면 지연진입(left truncation)을 고려해 연령을 시간축으로 썼는지에 따라 인년이 달라집니다. 사건 수는 같은데 인년만 다르다는 것은 “언제부터 세기 시작했는가”의 차이를 강하게 시사합니다.
2. **추적 종료(administrative censoring) 시점 차이.** Linked Mortality File은 특정 기준일(예: 2019년 12월 31일)까지의 사망을 담고 있습니다. 논문이 쓴 파일 버전과 여러분이 내려받은 버전의 종료일이 다르면 인년이 달라집니다. 또는 논문이 “최대 10년”처럼 추적을 인위적으로 제한(administrative truncation)했을 수 있습니다.

(부수적으로: 사망일을 월 단위로만 제공받아 월 중간(15일)으로 대치했는지 여부도 소폭 차이를 만듭니다.)

(b)

$$\text{논문} : \frac{1204}{68500} = 0.01758 \text{ 건/인년} = \mathbf{17.6 \text{ 건/1000 인년}}$$

$$\text{재현} : \frac{1204}{74100} = 0.01625 \text{ 건/인년} = \mathbf{16.3 \text{ 건/1000 인년}}$$

차이는 약 7.6%입니다.

영향: 이 차이는 **절대율**(전체 사망률)에는 직접 영향을 주지만, **위험비(HR)**에는 영향이 훨씬 작습니다. 왜냐하면 시작/종료 시점을 모든 군에 동일하게 적용했다면 분모가 두 군 모두 비슷한 비율로 바뀌어 비율에서 상쇄되기 때문입니다.

그러나 **상쇄되지 않는 경우**가 있습니다. 지연진입을 잘못 처리해서 특정 연령대나 특정 노출군의 인년만 과대계산되었다면 HR도 편향됩니다. 따라서 다음을 확인해야 합니다.

- 군별 인년을 각각 계산해 비율이 논문과 맞는지

- KM 곡선의 위험집합표를 논문 그림과 대조
- 중앙 추적기간(median follow-up)을 reverse KM으로 계산해 대조

논문 읽을 때 확인할 것

- KM 그림 아래에 number-at-risk 표가 있는가?
- 비례위험 가정을 검정했다고 명시했는가? 그림 또는 p 값이 있는가?
- HR을 “위험이 X 배”로 서술했는가? 사건이 흔하면 과장입니다.
- 연속변수를 사분위군으로 잘랐다면, 스플라인 등 연속 형태 분석도 함께 제시했는가?
- 중앙 추적기간과 총 인년, 사건 수가 보고되었는가?

12주차 · 교란을 보정한다

이번 주 기법 성향점수 추정 · 짝짓기와 역확률가중 · 공변량 균형 평가 · 용량반응 · 미측정 교란 민감도분석(E-value)

논문 전자담배 사용과 만성콩팥병 위험: 성향점수 짝짓기 용량반응 분석 (BMC Public Health 2025, PMID 40866870)

한 줄 요약 관찰연구에서 “연관”을 “인과”에 가깝게 만드는 방법. 그리고 그것이 결코 완전할 수 없음을 정직하게 숫자로 말하는 방법.

11.1 교란이란 무엇인가

전자담배 사용자와 비사용자를 비교했더니 사용자의 만성콩팥병이 많았다고 합시다. 이것이 전자담배 때문일까요? 전자담배 사용자는 더 젊고, 흡연을 겸하고, 소득이 다르고, 고혈압 유병률도 다릅니다. **교란변수(confounder)**는 다음 세 조건을 모두 만족하는 변수입니다.

1. 노출과 연관되어 있고,
2. 노출과 독립적으로 결과의 원인이며,
3. 노출과 결과 사이의 인과경로 위에 있지 않다.

세 번째가 결정적입니다. 이것을 어기는 두 가지가 있습니다.

보정하면 안 되는 두 종류의 변수

- **중간변수(mediator)** — 노출 $\rightarrow$ M $\rightarrow$ 결과. 예: 전자담배 $\rightarrow$ 혈압상승 $\rightarrow$ 콩팥병. 혈압을 보정하면 전자담배의 효과 중 혈압을 통한 부분이 지워집니다. 총효과를 알고 싶다면 넣으면 안 됩니다.
- **충돌변수(collider)** — 노출 $\rightarrow$ C $\leftarrow$ 결과. 예: 노출과 결과가 모두 “입원”에 영향을 준다면, 입원 여부를 보정(또는 입원환자만 분석)하는 순간 **없던 연관이 생깁니다**. 이것을 충돌층화 편향(collider stratification bias) 또는 선택편향이라 합니다.

“공변량은 많을수록 좋다”는 완전히 틀린 생각입니다. 어떤 변수를 넣을지는 자료가 아니라 **인과 다이어그램(DAG)**으로 정해야 합니다. 12주차 검증과제가 “인공지능이 제안한 보정 변수에서 중간변수와 충돌변수를 식별해 배제하라”고 하는 이유입니다.

11.2 성향점수

핵심 수식

$$e(\mathbf{x}) = P(A = 1 \mid \mathbf{X} = \mathbf{x})$$

보통 로지스틱 회귀(7주차)로 추정합니다.

$$\text{logit}(\hat{e}(\mathbf{x})) = \hat{\alpha}_0 + \hat{\alpha}_1 x_1 + \cdots + \hat{\alpha}_p x_p$$

균형 성질(balancing property):

$$\mathbf{X} \perp\!\!\!\perp A \mid e(\mathbf{X})$$

수식 뜯어보기

균형 성질이 이 방법의 전부입니다. 뜻은 이렇습니다.

성향점수가 같은 사람들끼리 모아 놓으면, 그 안에서는 처치 여부가 마치 무작위로 배정된 것처럼 공변량 분포가 같아진다.

즉 20개의 공변량을 하나하나 맞추는 대신, **20차원을 1차원 숫자 하나로 압축**해서 그것만 맞추면 됩니다. 이것이 Rosenbaum-Rubin(1983)의 결과입니다.
성립하려면 두 가정이 필요합니다.

1. **교환가능성 / 무시가능성(ignorability)**: 측정된 $\mathbf{X}$ 를 조건으로 하면 미측정 교란이 없다. 검증 불가능한 가정입니다.
2. **양수성(positivity, overlap)**: 모든 $\mathbf{x}$ 에서 $0 < e(\mathbf{x}) < 1$. 즉 어떤 사람이든 두 군에 속할 가능성이 있어야 한다. 이것은 그림으로 확인 가능합니다.

11.3 짝짓기와 역확률가중 --- 두 가지 사용법

핵심 수식

① **짝짓기(matching)**: 처치군 각 개인에 대해 성향점수가 가장 가까운 대조군을 찾습니다. 보통 **캘리퍼(caliper)**를 두어 $|\text{logit } \hat{e}_i - \text{logit } \hat{e}_j| \leq 0.2 \times \text{SD}(\text{logit } \hat{e})$ 이내에서만 짝짓습니다. 추정 대상은 ATT(처치군에서의 평균 처치효과).

② **역확률가중(IPW)**: 각 개인에게 가중치를 줍니다.

$$w_i = \frac{A_i}{\hat{e}(\mathbf{X}_i)} + \frac{1 - A_i}{1 - \hat{e}(\mathbf{X}_i)}$$

추정 대상은 ATE(전체 집단에서의 평균 처치효과).

$$\widehat{\text{ATE}} = \frac{\sum_i \frac{A_i Y_i}{\hat{e}_i}}{\sum_i \frac{A_i}{\hat{e}_i}} - \frac{\sum_i \frac{(1 - A_i) Y_i}{1 - \hat{e}_i}}{\sum_i \frac{1 - A_i}{1 - \hat{e}_i}}$$

수식 뜯어보기

- IPW의 직관은 2주차·10주차와 동일합니다. 성향점수 0.1인 사람이 처치를 받았다면, 그런 사람 10명 중 1명꼴로만 처치를 받으므로 **자기 같은 사람 10명을 대표합니다**. 가중치 $1/0.1 = 10$.
- 짝짓기는 짝을 못 찾은 사람을 버립니다. 표본이 줄고 일반화 대상이 바뀝니다(ATT). IPW는 모두를 씁니다(ATE). **두 방법이 다른 답을 내는 것은 버그가 아니라 추정 대상이 다르기 때문입니다**. 12주차 R과 Python 양쪽으로 구현해 대조하라고 하는 것도, 짝짓기 알고리즘(greedy vs optimal, with/without replacement, 캘리퍼 폭)이 다르면 결과가 달라지기 때문입니다.
- 짝짓기 후에는 **짝 구조를 고려한 분석**을 해야 합니다(대응 t 검정, McNemar형, 또는 짝 ID를 군집으로 한 강건 표준오차). 3주차·5주차의 짝자료 이야기가 여기서 되살아납니다.

11.4 균형 평가 --- 표준화 평균차

핵심 수식

$$SMD = \frac{\bar{x}_1 - \bar{x}_0}{\sqrt{\frac{s_1^2 + s_0^2}{2}}}$$

이분형 변수는

$$SMD = \frac{\hat{p}_1 - \hat{p}_0}{\sqrt{\frac{\hat{p}_1(1 - \hat{p}_1) + \hat{p}_0(1 - \hat{p}_0)}{2}}}$$

관례적 기준: $|SMD| < 0.1$ 이면 균형이 맞았다고 봅니다.

수식 뜯어보기

- 이것은 3주차 **Cohen's d** 와 같은 식입니다. 분모의 pooled SD를 자유도 가중치 아니라 단순 평균으로 쓰는 것만 다릅니다.
- 왜 p 값으로 균형을 판정하면 안 되는가? 짝짓기를 하면 표본이 줄어듭니다. n 이 줄면 검정력이 떨어져 p 값이 자동으로 커집니다. 즉 **균형이 나빠져도 p 값은 좋아 보일 수 있습니다**. SMD는 n 에 의존하지 않는 순수 효과크기이므로 이 함정이 없습니다.
- **love plot**은 모든 공변량의 보정 전/후 SMD를 한 그림에 찍고 0.1 기준선을 그은 것입니다. 성향점수 논문의 필수 그림입니다.
- 평균만 맞추면 부족합니다. **분산비와 고차항·상호작용의 균형도** 확인해야 합니다. 안 맞으면 성향점수 모형에 그 항들을 추가합니다.

예시

보정 전: 처치군 나이 $\bar{x}_1 = 25.4$ ($s_1 = 4.0$), 대조군 $\bar{x}_0 = 24.0$ ($s_0 = 3.5$).

$$SMD = \frac{25.4 - 24.0}{\sqrt{\frac{4.0^2 + 3.5^2}{2}}} = \frac{1.4}{\sqrt{\frac{16 + 12.25}{2}}} = \frac{1.4}{\sqrt{14.125}} = \frac{1.4}{3.758} = 0.373$$

0.1을 크게 넘으므로 불균형입니다. 짝짓기 후 이 값이 0.1 아래로 내려가야 합니다.

겹침(positivity)이 없으면 아무것도 구제할 수 없다

성향점수 분포를 두 군에 대해 겹쳐 그렸을 때, 처치군에는 $e \approx 0.9$ 인 사람이 많은데 대조군에는 그 영역에 아무도 없다면, 그 영역에서는 **비교 대상 자체가 존재하지 않습니다**. 통계적으로 만들 어낼 수 없습니다.

대응: 공통지지영역(common support)으로 분석을 제한하거나, 극단 가중치를 절단합니다. 단, 그러면 **결론의 적용 대상이 좁아진다는** 점을 명시해야 합니다.

11.5 E-value --- 미측정 교란에 대한 정직한 답

성향점수는 **측정한 변수만** 보정합니다. 측정하지 않은 교란변수는 손도 못 댁니다. “그럼 우리 결과가 얼마나 취약한가?”를 숫자로 답하는 것이 E-value입니다.

핵심 수식

관측된 위험비 $RR \geq 1$ 에 대해

$$E\text{-value} = RR + \sqrt{RR(RR - 1)}$$

$RR < 1$ 이면 먼저 $RR \rightarrow 1/RR$ 로 뒤집은 뒤 같은 식을 씁니다.

신뢰구간의 경계(1에 가까운 쪽)에 대해서도 계산해 함께 보고합니다.

수식 뜯어보기

정확한 뜻: 관측된 연관을 완전히 설명해 없애려면, 미측정 교란변수가 노출과도 결과와도 **각각 최소 E-value 배의 위험비로** 연관되어 있어야 한다 — 이미 보정한 변수들을 넘어서.

- E-value가 **크면** 결과가 튼튼합니다. 그렇게 강력한 교란변수가 숨어 있기 어렵기 때문입니다.
- E-value가 **1에 가까우면** 약한 교란만 있어도 결과가 뒤집힙니다.
- 판단은 통계가 아니라 **도메인 지식**입니다. “E-value가 3.4인데, 우리가 놓쳤을 법한 변수 중 노출·결과 모두와 3.4배 연관된 것이 있는가?” 흡연 같은 강력한 변수는 폐암과 10배 이상 연관되므로, 흡연을 보정하지 않았다면 E-value 3.4는 전혀 안심할 수 없습니다.
- **한계:** E-value는 “얼마나 강한 교란이 필요한가”만 말할 뿐, 그런 교란이 **실제로 있는지**는 말해 주지 않습니다. 편향의 방향도 알려주지 않습니다.

예시

$$RR = 2.0 \Rightarrow E\text{-value} = 2.0 + \sqrt{2.0 \times 1.0} = 2.0 + 1.414 = \mathbf{3.41}$$

$$RR = 1.5 \Rightarrow E\text{-value} = 1.5 + \sqrt{1.5 \times 0.5} = 1.5 + 0.866 = \mathbf{2.37}$$

$$RR = 1.1 \Rightarrow E\text{-value} = 1.1 + \sqrt{1.1 \times 0.1} = 1.1 + 0.332 = \mathbf{1.43}$$

$RR = 1$ 이면 E-value는 정확히 1입니다(설명할 것이 없음).

문제 21

전자담배와 만성콩팥병 연구에서 성향점수 짝짓기 후 $OR = 1.62$ (95% CI 1.14–2.30)를 얻었습니다. 결과 유병률은 대조군에서 8%입니다. (a) OR을 근사 RR로 변환하십시오. (b) 점추정치와 CI 하한에 대한 E-value를 각각 구하십시오. (c) 이 결과의 강건성을 평가하십시오.

정답 21

(a) 5주차의 관계 $OR = RR \cdot \frac{1-p_0}{1-p_1}$ 을 씁니다. $p_0 = 0.08$.

$$RR \approx \frac{OR}{1 - p_0 + p_0 \cdot OR} = \frac{1.62}{0.92 + 0.08(1.62)} = \frac{1.62}{0.92 + 0.1296} = \frac{1.62}{1.0496} = 1.544$$

(같은 방식으로 CI 하한: $\frac{1.14}{0.92+0.08(1.14)} = \frac{1.14}{1.0112} = 1.127$)

유병률이 8%로 비교적 낮아 OR(1.62)과 RR(1.54)의 차이가 크지 않습니다. 유병률이 30%였다면 훨씬 벌어졌을 것입니다.

(b)

$$E\text{-value}_{\text{점추정}} = 1.544 + \sqrt{1.544 \times 0.544} = 1.544 + \sqrt{0.8399} = 1.544 + 0.9165 = 2.46$$

$$E\text{-value}_{\text{CI 하한}} = 1.127 + \sqrt{1.127 \times 0.127} = 1.127 + \sqrt{0.14313} = 1.127 + 0.3783 = 1.51$$

(c) 해석:

- 관측된 연관을 완전히 없애려면, 이미 보정한 변수들을 **넘어서** 노출·결과 양쪽 모두와 위험비 2.46배로 연관된 미측정 교란변수가 있어야 합니다.
- 그런데 연관을 단지 통계적으로 유의하지 않게 만드는 데는 1.51배면 충분합니다.
- **평가: 중간 정도의 강건성이며, 낙관할 수 없습니다.** 특히 전자담배 연구에서 일반 담배 흡연은 노출(전자담배 사용)과도 결과(콩팥병)와도 훨씬 강하게 연관됩니다. 흡연 이력을 세밀하게(현재/과거/pack-year) 보정하지 않았다면 잔여교란만으로 1.51은 쉽게 넘습니다.
- 논문이 해야 할 서술: “E-value 2.46(CI 하한 1.51)로, 중등도 강도의 미측정 교란이 존재할 경우 결과가 설명될 수 있다. 특히 흡연의 잔여교란 가능성을 배제할 수 없다.”

문제 22

어떤 인공지능이 성향점수 모형의 공변량으로 다음을 제안했습니다. 노출은 전자담배 사용, 결과는 만성콩팥병입니다.

나이 · 성별 · 소득 · 일반담배 흡연 · 혈압 · 추정사구체여과율(eGFR) · 연구 참여 후 입원 여부
각 변수를 (i) 정당한 교란변수, (ii) 중간변수, (iii) 충돌변수, (iv) 기타 문제로 분류하고 처리 방침을 쓰시오.

정답 22

변수	분류	처리
나이	(i) 교란변수	보정. 노출·결과 모두의 원인이며 인과경로 밖.
성별	(i) 교란변수	보정.
소득	(i) 교란변수	보정.
일반담배 흡연	(i) 교란변수	반드시 보정. 가장 강력한 교란원.
혈압	(ii) 중간변수	제외 (총효과 추정 시).
eGFR	(iv) 결과 그 자체	제외 . 콩팥병의 정의 요소.
입원 여부	(iii) 충돌변수	제외 .

각각의 이유:

- **혈압** — 전자담배 → 혈압상승 → 콩팥손상은 그럴듯한 인과경로입니다. 혈압을 보정하면 그 경로를 통한 효과가 지워져 **총효과가 0 쪽으로 편향**됩니다. 총효과를 원하면 제외하고, 혈압을 통하지 않는 직접효과가 궁금하다면 매개분석의 틀에서 별도로 다뤄야 합니다.
- **eGFR** — 만성콩팥병은 보통 $eGFR < 60$ 으로 정의됩니다. 결과의 구성요소를 공변량으로 넣으면 정의상 순환이며 효과가 인위적으로 사라집니다. (단, **기저 시점**의 eGFR을 넣고 그 이후의 신기능 저하를 결과로 보는 설계라면 정당한 보정입니다. **시점을 반드시 확인해야 합니다.**)
- **연구 참여 후 입원 여부** — 시간적으로 노출 이후에 발생했고, 전자담배 사용과 콩팥병 모두가 입원 확률을 높입니다. 즉 노출 → 입원 ← 결과의 충돌 구조입니다. 이를 보정하면 **없던 연관 (대개 음의 방향)이 인위적으로 생깁니다.**

일반 원칙: 공변량은 노출 시점 이전(또는 동시)에 측정된 것만 넣습니다. “노출 이후에 측정된 변수는 일단 의심한다”는 규칙만 지켜도 중간변수와 충돌변수의 대부분을 걸러낼 수 있습니다.

연결고리

- → **2·10주차:** 성향점수 가중치 $1/\hat{e}$ 는 NHANES 표본가중치 w_i 와 같은 구조입니다. 전자는 추정된 확률, 후자는 설계로 알려진 확률.
- → **3주차:** SMD는 Cohen's d 입니다.
- → **7주차:** 성향점수 자체가 로지스틱 회귀의 예측확률입니다. 다만 여기서는 **판별력(AUC)이 높은 것이 좋은 게 아닙니다** — AUC가 너무 높으면 겹침이 없다는 뜻이니깐요.
- → **10주차:** 성향점수 추정의 불확실성까지 반영하려면 부트스트랩을 **추정 단계부터** 감싸야 합니다.

13주차 · 여러 연구를 하나로 합친다

이번 주 기법 고정효과·랜덤효과 메타분석 · 이질성 통계량 · 베이지안 계층모형 · 축소 · 사전분포 민감도

논문 뇌졸중과 외상성 뇌손상에서 코르티코스테로이드의 효과와 안전성 (Systematic Reviews 2025, PMID 40038828)

한 줄 요약 메타분석은 “정밀한 연구에 더 큰 가중치를 주는 가중평균”이다. 그 이상도 이하도 아니다.

12.1 역분산 가중 --- 메타분석의 핵심 한 줄

k 개 연구가 각각 효과추정치 $\hat{\theta}_i$ 와 그 분산 $v_i = \text{SE}(\hat{\theta}_i)^2$ 를 보고했습니다. (여기서 θ 는 보통 **로그 오즈 비**나 **로그 위험비**입니다 — 2주차와 5주차에서 본 이유로, 로그 스케일이라야 정규근사와 대칭 신뢰구간이 성립합니다.)

고정효과(fixed-effect) 모형

$$w_i = \frac{1}{v_i}, \quad \hat{\theta}_{\text{FE}} = \frac{\sum_{i=1}^k w_i \hat{\theta}_i}{\sum_{i=1}^k w_i}, \quad \text{SE}(\hat{\theta}_{\text{FE}}) = \frac{1}{\sqrt{\sum_{i=1}^k w_i}}$$

가정: 모든 연구가 동일한 참 효과 θ 를 추정하고 있다.

수식 뜯어보기

- 왜 하필 $1/v_i$ 가 가중치인가? 가중평균 $\hat{\theta} = \sum a_i \hat{\theta}_i$ ($\sum a_i = 1$)의 분산은 $\sum a_i^2 v_i$ 입니다. 라그랑주 승수법으로 이를 최소화하면 $a_i \propto 1/v_i$ 가 나옵니다. 즉 **역분산 가중**은 분산을 최소로 만드는 유일한 가중치입니다. 임의로 고른 값이 아닙니다.
- 결과적으로 $\text{SE}(\hat{\theta}_{\text{FE}}) = 1/\sqrt{\sum w_i}$ 입니다. 연구를 더할수록 $\sum w_i$ 가 커져 정밀도가 올라갑니다.
- forest plot에서 사각형의 **크기**가 w_i 입니다. 큰 연구가 큰 사각형을 갖는 이유입니다.
- 표본이 큰 연구는 v_i 가 작으므로($v \propto 1/n$) 가중치가 큼니다. 이것은 0장 $\text{SE} = s/\sqrt{n}$ 의 직접적 귀결입니다.

12.2 이질성 --- 연구들이 정말 같은 것을 재고 있는가

핵심 수식

$$Q = \sum_{i=1}^k w_i (\hat{\theta}_i - \hat{\theta}_{FE})^2 \sim \chi_{k-1}^2 \quad \text{under } H_0 : \text{이질성 없음}$$

$$I^2 = \max\left(0, \frac{Q - (k-1)}{Q}\right) \times 100\%$$

DerSimonian--Laird의 연구간 분산 추정치:

$$\hat{\tau}^2 = \max\left(0, \frac{Q - (k-1)}{\sum_i w_i - \frac{\sum_i w_i^2}{\sum_i w_i}}\right)$$

수식 뜯어보기

- Q 의 구조는 또 0장의 뼈대입니다. $w_i(\hat{\theta}_i - \hat{\theta})^2 = \left(\frac{\hat{\theta}_i - \hat{\theta}}{\sqrt{v_i}}\right)^2$ 이므로, 표준화 잔차의 제곱합입니다. 5주차 $\chi^2 = \sum \frac{(O-E)^2}{E}$ 와 완전히 같은 형태입니다.
- 왜 Q 에서 $k-1$ 을 빼는가? H_0 (이질성 없음)가 참이어도 표본오차 때문에 $\hat{\theta}_i$ 들은 흩어집니다. 그 “당연한 흩어짐”의 기댓값이 정확히 $\mathbb{E}[Q] = k-1$ 입니다. 그것을 넘는 부분만이 진짜 이질성입니다.
- I^2 의 정확한 뜻: 관측된 전체 변동 중 표본오차가 아니라 진짜 연구간 차이에서 오는 비율. 관례: 25% 낮음, 50% 중간, 75% 높음.
- I^2 는 τ^2 의 크기가 아닙니다. 연구들이 모두 거대하면 v_i 가 매우 작아져서, 임상적으로 사소한 τ^2 에도 I^2 가 90%를 넘습니다. I^2 와 τ^2 (또는 예측구간)를 함께 봐야 합니다.
- Q 검정은 k 가 작으면 검정력이 매우 낮습니다. $p > 0.05$ 라고 “이질성 없음”이라 결론지으면 안 됩니다(0장의 오해와 같은 구조).

12.3 랜덤효과 모형

핵심 수식

연구마다 참 효과가 다르다고 봅니다.

$$\hat{\theta}_i \mid \theta_i \sim N(\theta_i, v_i), \quad \theta_i \sim N(\mu, \tau^2)$$

따라서 주변적으로 $\hat{\theta}_i \sim N(\mu, v_i + \tau^2)$ 이고, 가중치가 바뀝니다.

$$w_i^* = \frac{1}{v_i + \hat{\tau}^2}, \quad \hat{\mu}_{RE} = \frac{\sum_i w_i^* \hat{\theta}_i}{\sum_i w_i^*}, \quad SE(\hat{\mu}_{RE}) = \frac{1}{\sqrt{\sum_i w_i^*}}$$

수식 뜯어보기

- τ^2 이 분모에 더해지면서 두 가지가 일어납니다. (i) **신뢰구간이 넓어집니다** — 이질성의 불확실성을 정직하게 반영. (ii) **가중치가 평균화됩니다** — v_i 가 작은 거대 연구도 τ^2 때문에 무한정 큰 가중치를 갖지 못합니다. 그래서 작은 연구의 상대적 영향력이 커집니다.
- $\hat{\tau}^2 = 0$ 이면 랜덤효과는 고정효과와 정확히 같아집니다.
- **해석이 다릅니다.** 고정효과의 $\hat{\theta}$ 는 “그 하나의 참 효과”이고, 랜덤효과의 $\hat{\mu}$ 는 “참 효과들의 평균”입니다. 후자에서는 **예측구간** $\hat{\mu} \pm t_{k-2} \sqrt{\hat{\tau}^2 + \text{SE}(\hat{\mu})^2}$ 이 “다음 연구에서 어떤 효과가 나올까”를 말해 주며, 신뢰구간보다 훨씬 넓습니다. **임상적 판단에는 예측구간이 더 중요합니다.**

고정효과와 랜덤효과가 얼마나 다를 수 있는가

3개 연구, 로그오즈비 $\hat{\theta} = (0.1, 0.5, 0.9)$, 모두 $v_i = 0.01$ (즉 $\text{SE}_i = 0.1$).

고정효과: $w_i = 1/0.01 = 100$ (모두 동일), $\sum w_i = 300$.

$$\hat{\theta}_{\text{FE}} = \frac{100(0.1) + 100(0.5) + 100(0.9)}{300} = \frac{150}{300} = 0.500$$

$$\text{SE}_{\text{FE}} = \frac{1}{\sqrt{300}} = 0.0577$$

$$\text{OR} = e^{0.5} = 1.649, \quad \text{CI} = e^{0.5 \pm 1.96(0.0577)} = (1.47, 1.85)$$

이질성:

$$Q = 100(0.1 - 0.5)^2 + 100(0)^2 + 100(0.9 - 0.5)^2 = 100(0.16) + 0 + 100(0.16) = 32.0$$

$$I^2 = \frac{32 - 2}{32} = 0.9375 \Rightarrow 93.8\% \quad (\text{매우 높음})$$

$$\hat{\tau}^2 = \frac{32 - 2}{300 - \frac{30000}{300}} = \frac{30}{300 - 100} = \frac{30}{200} = 0.15$$

랜덤효과: $w_i^* = \frac{1}{0.01 + 0.15} = 6.25$, $\sum w_i^* = 18.75$.

$$\hat{\mu}_{\text{RE}} = 0.500 \quad (\text{가중치가 모두 같으므로 점추정치는 동일})$$

$$\text{SE}_{\text{RE}} = \frac{1}{\sqrt{18.75}} = 0.2309$$

$$\text{CI} = e^{0.5 \pm 1.96(0.2309)} = (1.05, 2.59)$$

	통합 OR	95% CI	CI 폭(로그)
고정효과	1.65	1.47 – 1.85	0.226
랜덤효과	1.65	1.05 – 2.59	0.905

점추정치는 같은데 신뢰구간이 4배 넓습니다. 고정효과는 “확실히 유의”라고 말하지만, 랜덤효과는 겨우 1을 벗어납니다. $I^2 = 94\%$ 인 자료에 고정효과를 쓰는 것은 불확실성을 감추는 것입니다.

12.4 베이저안 계층모형과 축소

핵심 수식

랜덤효과 모형을 베이저안으로 쓰면 그대로 **계층모형(hierarchical model)**입니다.

$$\hat{\theta}_i | \theta_i \sim N(\theta_i, v_i), \quad \theta_i | \mu, \tau \sim N(\mu, \tau^2), \quad \mu \sim \pi(\mu), \quad \tau \sim \pi(\tau)$$

μ, τ 를 알고 있다고 하면 개별 연구의 사후평균은

$$\mathbb{E}[\theta_i | \hat{\theta}_i, \mu, \tau] = \frac{\frac{1}{v_i}\hat{\theta}_i + \frac{1}{\tau^2}\mu}{\frac{1}{v_i} + \frac{1}{\tau^2}} = B_i \mu + (1 - B_i) \hat{\theta}_i, \quad B_i = \frac{v_i}{v_i + \tau^2}$$

수식 뜯어보기

- 이것이 **축소(shrinkage)**입니다. 각 연구의 추정치가 전체 평균 μ 쪽으로 당겨집니다.
- B_i 가 축소의 강도입니다. 연구가 작아서 v_i 가 크면 B_i 가 커져 강하게 당겨지고, 연구가 정밀하면 v_i 가 작아 거의 당겨지지 않습니다. 매우 합리적입니다 — 정보가 적은 연구일수록 전체 정보를 더 빌려 씁니다(borrowing strength).
- $\tau^2 \rightarrow 0$ (연구들이 동질)이면 $B_i \rightarrow 1$ 로 모두 μ 로 완전히 축소됩니다. $\tau^2 \rightarrow \infty$ (전혀 무관)이면 $B_i \rightarrow 0$ 으로 축소가 없습니다.
- **4주차 다중비교와의 관계:** 여러 개를 동시에 추정할 때 극단값은 대개 우연에 의한 것입니다(승자의 저주). 축소는 그 극단값을 자동으로 되돌립니다. 빈도주의는 p 값을 보정해서, 베이저안은 추정치를 축소해서 같은 문제를 다룹니다.

예시

앞 예시에서 $\mu = 0.5, \tau^2 = 0.15, v_1 = 0.01$ 일 때 첫 연구($\hat{\theta}_1 = 0.1$)의 사후평균은

$$B_1 = \frac{0.01}{0.01 + 0.15} = 0.0625$$

$$\mathbb{E}[\theta_1 | \cdot] = 0.0625(0.5) + 0.9375(0.1) = 0.03125 + 0.09375 = \mathbf{0.125}$$

0.1에서 0.125로 아주 조금만 당겨졌습니다. 이 연구가 정밀(v_1 이 τ^2 보다 15배 작음)하기 때문입니다.

만약 이 연구가 작아서 $v_1 = 0.30$ 이었다면

$$B_1 = \frac{0.30}{0.30 + 0.15} = 0.667 \Rightarrow \mathbb{E}[\theta_1 | \cdot] = 0.667(0.5) + 0.333(0.1) = 0.367$$

0.1에서 0.367로 크게 당겨집니다.

12.5 사후분포를 계산하는 두 방법

핵심 수식

- ① NUTS (No-U-Turn Sampler) — 해밀토니안 몬테카를로의 자동조율 버전. 사후분포에서 표본을 뽑습니다. 충분히 돌리면 정확한 사후분포에 수렴합니다.
- ② SVI (변분추론, Stochastic Variational Inference) — 사후분포 p 를 다루기 쉬운 분포족 q_ϕ (가이드)로 근사합니다. 다음을 최대화합니다.

$$\text{ELBO}(\phi) = \mathbb{E}_{q_\phi}[\log p(\text{자료}, \theta)] - \mathbb{E}_{q_\phi}[\log q_\phi(\theta)] = \log p(\text{자료}) - \text{KL}(q_\phi \parallel p)$$

수식 뜯어보기

- ELBO를 최대화하는 것은 $\text{KL}(q \parallel p)$ 를 최소화하는 것과 같습니다($\log p(\text{자료})$ 가 ϕ 와 무관하므로).
- 13주차 검증과제의 핵심: $\text{KL}(q \parallel p)$ 는 q 가 큰 곳에서만 별점을 줍니다. 따라서 q 는 p 의 한 봉우리 안에 안전하게 숨는 쪽을 택합니다(mode-seeking). 그 결과 변분추론은 사후분산을 체계적으로 과소추정합니다. 신뢰구간이 실제보다 좁게 나옵니다. 특히 모수 간 상관성이 강한데 가이드를 대각(mean-field)으로 잡으면 심합니다.
- 진단 지표:
 - $\hat{R}$ (R-hat): 여러 체인의 분산과 체인 내 분산의 비. $\hat{R} \leq 1.01$ 이어야 수렴한 것입니다.
 - 발산 전이(divergent transitions): NUTS가 기하학이 험한 영역에서 실패한 것. 하나라도 있으면 결과를 신뢰하면 안 됩니다. 계층모형에서 τ 가 0 근처일 때 자주 발생하며(“갈때기”), **비중심화 모수화**로 해결합니다.
 - 유효표본수(ESS): 자기상관을 감안한 실질 표본 수. 최소 400 이상 권장.
 - ELBO 수렴도: 평평해져야 학습이 끝난 것입니다.
- τ 의 사전분포에 결과가 민감합니다. 연구 수 k 가 작으면($k < 10$) τ 에 대한 정보가 거의 없어서 사전분포가 사후를 지배합니다. Half-Cauchy(0, 1)나 Half-Normal(0, 0.5) 등 여러 사전분포로 돌려 보고 결론이 안 바뀌는지 확인하는 것이 **민감도분석**입니다.

문제 23

5개 연구의 로그위험비와 표준오차입니다.

연구	$\hat{\theta}_i$	SE_i	v_i
1	-0.20	0.100	0.0100
2	-0.10	0.200	0.0400
3	-0.35	0.150	0.0225
4	0.05	0.250	0.0625
5	-0.25	0.120	0.0144

(a) 고정효과 통합추정치와 95% CI를 구하시오(위험비로 변환). (b) Q 와 I^2 을 구하시오. (c) 결론을 쓰시오.

정답 23

(a) $w_i = 1/v_i$:

$$w = (100.00, 25.00, 44.44, 16.00, 69.44), \quad \sum w_i = 254.89$$

$$\begin{aligned} \sum w_i \hat{\theta}_i &= 100(-0.20) + 25(-0.10) + 44.44(-0.35) + 16(0.05) + 69.44(-0.25) \\ &= -20.000 - 2.500 - 15.556 + 0.800 - 17.361 = -54.617 \end{aligned}$$

$$\hat{\theta}_{FE} = \frac{-54.617}{254.89} = -0.2143$$

$$SE = \frac{1}{\sqrt{254.89}} = \frac{1}{15.965} = 0.06264$$

$$CI_{log} = -0.2143 \pm 1.96(0.06264) = (-0.3371, -0.0915)$$

$$RR = e^{-0.2143} = 0.807, \quad CI = (e^{-0.3371}, e^{-0.0915}) = (0.714, 0.913)$$

(b)

$$Q = \sum w_i (\hat{\theta}_i + 0.2143)^2$$

i	$\hat{\theta}_i - \hat{\theta}_{FE}$	$(\cdot)^2$	w_i	기여
1	0.0143	0.000204	100.00	0.0204
2	0.1143	0.013064	25.00	0.3266
3	-0.1357	0.018414	44.44	0.8184
4	0.2643	0.069854	16.00	1.1177
5	-0.0357	0.001274	69.44	0.0885
				$Q = 2.372$

$df = k - 1 = 4, p \approx 0.67$.

$$I^2 = \max\left(0, \frac{2.372 - 4}{2.372}\right) = \max(0, -0.686) = 0\%$$

$Q < k - 1$ 이므로 $I^2 = 0$ 입니다. $\hat{\tau}^2 = 0$ 이 되어 **랜덤효과 결과는 고정효과와 동일합니다.**

(c) “5개 연구를 통합한 위험비는 0.81 (95% CI 0.71–0.91)로, 개입이 사건 위험을 약 19% 감소시켰다. 이질성은 관찰되지 않았다($I^2 = 0\%$, $Q = 2.37$, $df=4$, $p = 0.67$).”

단서를 반드시 붙여야 합니다: $k = 5$ 로 작아 Q 검정의 검정력이 낮습니다. $I^2 = 0\%$ 를 “이질성이 없음이 증명되었다”로 읽으면 안 되며(0장의 오해), “검출되지 않았다”가 정확합니다. 연구 4는 방향이 반대이고 가장 부정확하므로 민감도분석(연구 하나씩 제외)을 권장합니다.

문제 24

Pyro로 베이지안 랜덤효과 메타분석을 돌렸습니다. NUTS 결과 $\hat{\mu} = -0.21$, 95% 신용구간 $(-0.42, -0.01)$, $\hat{R} = 1.00$, 발산 전이 3건. SVI(mean-field) 결과 $\hat{\mu} = -0.21$, 95% 구간 $(-0.29, -0.13)$. (a) 두 구간의 차이를 설명하십시오. (b) 발산 전이 3건을 어떻게 처리해야 하는가? (c) 빈도주의 DerSimonian–Laird 결과와 어떻게 대조하겠는가?

정답 24

(a) SVI 구간이 NUTS의 약 40% 폭에 불과합니다. 이것은 **변분추론의 사후분산 과소추정**의 전형입니다. 원인은 두 가지입니다.

1. $KL(q||p)$ 가 mode-seeking이라 q 가 사후분포의 꼬리를 덮지 않습니다.
2. mean-field 가이드는 μ 와 τ 의 사후 상관을 0으로 강제합니다. 계층모형에서 이 둘은 강하게 상관되어 있어(특히 τ 가 클수록 μ 가 불확실해짐), 상관을 무시하면 μ 의 불확실성이 크게 줄어 듭니다.

보고해야 할 것은 NUTS 결과입니다. SVI는 탐색용으로만 씁니다. (개선하려면 full-rank 가우시안 가이드나 정규화 흐름 가이드를 씁니다.)

(b) **발산 전이는 0건이어야 합니다.** 3건이라도 사후분포의 특정 영역(대개 $\tau \approx 0$ 근처의 좁은 “갈때기”)을 표본추출기가 탐색하지 못했다는 뜻이며, 이는 $\hat{R} = 1.00$ 이어도 결과를 신뢰할 수 없다는 의미입니다($\hat{R}$ 은 체인들이 서로 일치하는지만 보므로, 모든 체인이 똑같이 갈때기를 못 들어가면 $\hat{R}$ 은 멀쩡합니다).

조치 순서:

1. **비중심화 모수화**로 바꿉니다: $\theta_i = \mu + \tau z_i$, $z_i \sim N(0, 1)$. 계층모형 갈때기 문제의 표준 해법입니다.
2. target_accept_prob을 0.8에서 0.95 이상으로 올립니다(적응 단계가 더 작은 스텝을 씁니다).
3. τ 의 사전분포를 약간 정보적으로(예: Half-Normal(0, 0.5)) 바꿔 0 근처의 극단적 기하를 완화합니다.
4. 그래도 남으면 발산 지점을 pair plot에 표시해 어느 모수에서 문제가 생기는지 확인합니다.

(c) 대조 방법:

- DL의 $\hat{\mu}$ 와 95% CI를 NUTS의 사후평균·95% 신용구간과 나란히 놓습니다. **정보가 약한 (weakly informative) 사전분포를 쓰면 k 가 클 때 둘이 거의 일치해야 합니다.**
- k 가 작으면(여기서는 그럴 가능성이 높음) **베이지안 구간이 더 넓게 나오는 것이 정상**입니다. DL은 $\hat{\tau}^2$ 을 “알려진 값”처럼 취급해 τ 추정의 불확실성을 무시하기 때문입니다. 베이지안은 τ 를 주변화하므로 그 불확실성을 반영합니다.
- $\hat{\tau}_{DL}^2$ 과 τ 의 사후 중앙값을 비교합니다. DL은 τ^2 을 0으로 절단하므로 작은 k 에서 과소추정 경향이 있습니다.
- **민감도분석:** τ 의 사전분포를 2~3가지로 바꿔 $\hat{\mu}$ 와 구간이 얼마나 움직이는지 표로 제시합니다. 결론이 바뀌면 “자료가 τ 를 결정하지 못한다”고 정직하게 써야 합니다.

연결고리

- → **0주차:** 역분산 가중은 $SE = s/\sqrt{n}$ 의 논리적 귀결이고, $SE_{FE} = 1/\sqrt{\sum w_i}$ 는 “정보가 더해진다”는 같은 말입니다.
- → **2·5주차:** 효과척도를 로그로 다루는 이유가 여기서 완성됩니다. forest plot의 로그 축.
- → **4주차:** 축소는 다중성 문제의 베이지안 해법입니다.

- → **8·9·10주차**: NUTS는 몬테카를로이므로 MCSE 개념이 그대로 적용됩니다. ESS가 곧 유효 B 입니다.

14주차 · 재현하고, 교차검증하고, 통합한다

과제 선정 논문의 주 분석 재현 · 불일치 항목마다 원인 규명 · 2개 이상 언어로 구현해 대조 · 인 공지능이 범한 오류 중 결과에 영향을 준 것 최소 1건 제시
한 줄 요약 앞의 12주 내용을 하나의 논문에 전부 적용한다.

13.1 전체 통합 --- 한 장으로 보는 개념 지도

모든 기법이 같은 식이다


주차	분자 (신호)	분모 (잡음)	결과 통계량
3	$\bar{X}_1 - \bar{X}_2$	$s_p \sqrt{1/n_1 + 1/n_2}$	t (pooled)
3	$\bar{X}_1 - \bar{X}_2$	$\sqrt{s_1^2/n_1 + s_2^2/n_2}$	t (Welch)
3	$\bar{d}$	$s_d/\sqrt{n}$	t (대응)
3	$W_1 - \mathbb{E}[W_1]$	$\sqrt{\text{Var}(W_1)}$	Wilcoxon z
4	MSB	MSW	F
5	$O - E$	$\sqrt{E}$	χ^2 의 각 항
5	$b - c$	$\sqrt{b + c}$	McNemar z
6	$\hat{\beta}_j$	$\text{SE}(\hat{\beta}_j)$	회귀 t
7	$\hat{\beta}_j$	$\text{SE}(\hat{\beta}_j)$	Wald z
11	$\sum O_{1j} - \sum E_{1j}$	$\sqrt{\sum V_j}$	log-rank z
13	$\hat{\theta}_i - \hat{\theta}_{\text{pool}}$	$\sqrt{v_i}$	Q 의 각 항

반복되는 다섯 개의 아이디어

아이디어	어디에 나오는가
표준화	왜도 g_1 (2주) → Cohen's d (3주) → Pearson r (6주) → SMD (12주). 전부 “차이 나누기 산포”.
로그 스케일	로그변환 (2주) → log OR의 CI (5주) → 로짓 링크 (7주) → log HR (11주) → forest plot 축 (13주). 비율을 대칭으로 만드는 유일한 방법.
역확률 가중	NHANES 표본가중치 (2주) → Rao-Scott 설계효과 (5주) → IPW (10주) → 성향점수 가중 (12주). 전부 1/선택확률.
재표집	순열검정 (3주) → Fisher 완전열거 (5·8주) → 검정력 모의실험 (9주) → 부트스트랩 (10주) → NUTS/MCMC (13주). “분포를 계산 대신 생성한다.”
다중성/축소	$1 - (1 - \alpha)^m$ (4주) → Bonferroni·BH (4주) → 베이지안 축소 (13주). 같은 문제, 두 철학.

13.2 재현이 안 될 때 --- 원인 규명의 순서

논문 숫자와 내 숫자가 다를 때, 다음 순서로 좁혀 갑니다. 위쪽일수록 흔하고 영향이 큼니다.



“일치”의 판정 기준

- 결정론적 계산(평균, χ^2 , 회귀계수, KM 추정치): 부동소수점 오차 수준까지 일치해야 합니다. 소수 넷째 자리에서 어긋나면 구현 차이입니다.
- 확률적 계산(부트스트랩, 순열, MCMC): 몬테카를로 오차 범위 안이면 일치입니다.

$$|\hat{\theta}_A - \hat{\theta}_B| \lesssim 3 \times \sqrt{\text{MCSE}_A^2 + \text{MCSE}_B^2}$$

- 논문 대비 재현: 논문이 반올림해 보고했으므로, 보고된 자릿수까지 일치하면 충분합니다. 다만 방향과 유의성이 바뀌면 자릿수 문제가 아닙니다.

13.3 인공지능이 통계 코드에서 실제로 범하는 오류 목록

14주차 과제가 요구하는 “결과에 영향을 준 오류 1건”을 찾을 때의 사냥터입니다. 각 항목은 앞 장들과 연결됩니다.

오류 유형	구체적 형태
설계 무시 (2·5주)	<code>mean()/glm()</code> 을 써서 복합표본 가중치·층·군집을 통째로 무시. 하위표본 전용 가중치 미사용.
사전검정 남용 (2·3주)	Levene → t 검정 선택의 2단계 절차를 자동으로 작성. 제1종 오류율 왜곡.
비모수 오해 (3주)	Wilcoxon 결과를 “중앙값 차이”로 서술.
보정 누락 (4주)	수십 개 비교를 하면서 다중비교 보정을 언급조차 하지 않음.
OR/RR 혼동 (5·7주)	유병률 30%인 단면연구의 OR을 “위험이 X 배”로 해석.
상관=일치 (6주)	Bland-Altman 대신 r 을 보고. LoA에 s_d 대신 SE 사용.
규제 기본값 (7주)	<code>sklearn.LogisticRegression</code> 의 L2 규제를 끄지 않아 계수가 축소.
난수 편향 (8주)	<code>rand()</code> % n 으로 인한 modulo bias, 조합수 정수 오버플로.
병렬 난수 공유 (9주)	스레드가 생성기를 공유해 재현 불가·비독립.
2단계 부트스트랩 실패 (10주)	성향점수를 원자료에서 한 번만 추정하고 고정 → SE 과소추정.
절단 축약 (11주)	생존자료를 이분형으로 바꿔 로지스틱 회귀. 비례위험 가정 미검정.
나쁜 공변량 (12주)	중간변수·충돌변수를 “많을수록 좋다”며 투입. 균형을 p 값으로 판정.
VI 과신 (13주)	SVI 신용구간을 그대로 보고. 발산 전이를 무시.

가장 위험한 오류는 코드가 잘 돌아갈 때 생긴다

문법 오류는 즉시 드러납니다. 그러나 위 목록의 오류들은 전부 정상적으로 실행되고 그럴듯한 숫자를 냅니다. 그래서 검증은 “에러가 나는가”가 아니라 “이 숫자가 나와야 할 이유가 있는가”를 묻는 방식이어야 합니다.

세 가지 검증 습관:

1. **손계산 대조** — 작은 부분집합에서 손으로 계산되는 값(예: 2×2 표의 χ^2)을 확인.
2. **알려진 정답 대조** — 이론값이 존재하는 상황($1 - 0.95^m$, 정확 p 값, 해석적 검정력)을 만들어 대조.
3. **언어 간 교차검증** — 같은 알고리즘을 다른 언어로 구현. 난수는 파일로 공유(10주차).

13.4 최종 문제 --- 전 과정 통합

문제 25

어떤 NHANES 기반 논문이 다음을 보고했습니다. “비만군(Q4)은 정상군(Q1) 대비 사망 위험이 유의하게 높았다(HR = 1.42, 95% CI 1.05–1.92, $p = 0.023$). I^2 은 해당 없음. 성향점수 짝짓기 후에도 결과는 유지되었다(OR = 1.38, 95% CI 1.02–1.87).”

이 문장에서 확인해야 할 항목을 앞 장들과 연결해 최소 6가지 제시하고, 각각 무엇이 문제될 수 있는지 쓰시오.

정답 25

1. **복합표본 설계 반영 여부** (2·5주차). NHANES인데 svycoxph/svyglm을 썼는가? 안 썼다면 점 추정치가 편향되고 신뢰구간이 좁아집니다. CI = 1.05–1.92의 하한이 1에 가까우므로, 설계 효과 $\hat{d} = 1.5$ 만 되어도 구간이 $\sqrt{1.5} = 1.22$ 배 넓어져 **1을 포함하게 될 수 있습니다**. 결론이 뒤집힙니다.
2. **비례위험 가정** (11주차). cox.zph() 결과가 제시되었는가? 비만-사망 관계는 시간에 따라 변하는 것으로 알려져 있어(역인과, 초기 추적기간의 질병 관련 체중감소) 위배 가능성이 높습니다. 위배 시 단일 HR 1.42는 해석 불가능합니다.
3. **HR을 “위험”으로 서술** (5·11주차). “사망 위험이 1.42배”는 hazard를 risk로 바꿔 읽은 것입니다. 사건이 흔하면 누적 사망 확률의 비는 1.42보다 작습니다.
4. **연속변수의 사분위 범주화** (11주차). BMI를 사분위로 자르면 정보가 버려지고 절단점 의존성이 생깁니다. 게다가 비만과 사망은 J자 관계로 알려져 있어, Q1(가장 마른 군)이 기준군이면 **Q1의 사망률이 오히려 높아** HR이 과소추정될 수 있습니다. 제한 3차 스플라인 결과가 함께 있어야 합니다.
5. **성향점수 분석의 정합성** (12주차). (i) 짝짓기 후 **SMD love plot**이 있는가? p 값으로 균형을 판정했다면 무효입니다. (ii) **겹침(positivity)** 그림이 있는가? (iii) 공변량에 중간변수(예: 고혈압, 당뇨 — 비만→대사이상→사망 경로)가 들어갔다면 총효과가 0 쪽으로 편향됩니다. (iv) 짝짓기 후 **OR**을 보고한 것도 이상합니다 — 앞에서는 생존분석(HR)을 했는데 여기서 이분형으로 바꿨다면 **절단 정보를 버린 것**입니다(11주차 검증과제).
6. **미측정 교란** (12주차). E-value가 없습니다. $RR \approx 1.42$ 면

$$E\text{-value} = 1.42 + \sqrt{1.42 \times 0.42} = 1.42 + 0.772 = 2.19$$

CI 하한 1.05에 대해서는

$$1.05 + \sqrt{1.05 \times 0.05} = 1.05 + 0.229 = 1.28$$

즉 1.28배 강도의 미측정 교란만 있어도 유의성이 사라집니다. 흡연(체중을 낮추고 사망을 높임)의 잔여교란만으로도 충분히 도달 가능한 수준입니다. 매우 취약한 결과입니다.

7. **다중비교** (4주차). 논문이 여러 결과변수나 여러 하위군을 분석했다면 $p = 0.023$ 은 보정 전 값일 수 있습니다. $m = 10$ 이면 Bonferroni 문턱은 0.005로 유의하지 않습니다.
8. **“ I^2 은 해당 없음”** (13주차). 단일 연구이므로 맞는 서술이지만, 이 문장이 있다는 것은 저자가 메타분석 용어를 혼용하고 있을 가능성을 시사합니다. Methods 전체의 용어 정확성을 점검할 신호입니다.

종합 판정: 이 결과는 (i) 설계 미반영, (ii) 비례위험 위배 가능성, (iii) 낮은 E-value 세 가지 중 어느 하나만으로도 무너질 수 있습니다. **“유의하게 높았다”는 서술은 과합니다.**

13.5 최단 경로 요약 --- 이 자료를 한 페이지로

외워야 할 것은 이것뿐입니다

- 1. 뼈대** 검정통계량 = $\frac{\text{효과}}{\text{표준오차}}$, $SE = \frac{s}{\sqrt{n}}$, $CI = \hat{\theta} \pm c SE$
- 2. p값** $P(\text{자료} | H_0)$ 이지 $P(H_0 | \text{자료})$ 가 아님. H_0 하에서 균등분포.
- 3. 표본크기** $SE \propto n^{-1/2}$, $n \propto \Delta^{-2}$. 효과가 절반이면 사람은 4배.
- 4. 두 군** pooled t / Welch t / 대응 t / Wilcoxon / 순열. 등분산이 의심되면 항상 Welch.
- 5. 다중성** $1 - (1 - \alpha)^m$. FWER은 Bonferroni, FDR은 BH(step-up).
- 6. 범주형** $\chi^2 = \sum \frac{(O-E)^2}{E}$, $OR = \frac{ad}{bc}$, $OR = RR \cdot \frac{1-p_0}{1-p_1}$. CI는 로그에서.
- 7. 회귀** 연속 $\rightarrow$ 선형, 이분형 $\rightarrow$ 로짓, 시간 $\rightarrow$ Cox. 우변은 언제나 $\beta^T \mathbf{x}$.
- 8. 예측** 판별력(AUC) + 보정(calibration) + 순이익(NB). 셋 다 필요.
- 9. 일치도** 상관 $\neq$ 일치. Bland-Altman LoA = $\bar{d} \pm 1.96 s_d$ (SE 아님).
- 10. 재표집** 라벨을 섞으면 순열검정(귀무분포), 자료를 복원추출하면 부트스트랩(추정치 분포). MCSE = $\sqrt{\hat{\pi}(1-\hat{\pi})/B}$.
- 11. 인과** 성향점수 $e(x) = P(A = 1 | x)$, 균형은 SMD < 0.1, 중간변수·충돌변수 배제, E-value = $RR + \sqrt{RR(RR-1)}$.
- 12. 통합** 역분산 가중 $w_i = 1/v_i$. 이질성 $I^2 = \frac{Q-(k-1)}{Q}$. 랜덤효과는 $w_i^* = \frac{1}{v_i + \tau^2}$.

어떤 논문을 읽든 이 순서로

- 1. 설계** — 무엇을 무엇과 비교했나? 언제 측정했나? (단면/코호트/시험)
- 2. 대상** — flow chart의 n . 누가 빠졌고 왜 빠졌나?
- 3. 척도** — OR인가 RR인가 HR인가? 결과가 혼한가?
- 4. 모형** — 무엇을 보정했나? 중간변수나 충돌변수가 있나?
- 5. 가정** — 등분산, 정규성, 비례위험, 겹침 — 검증했다는 서술이 있나?
- 6. 불확실성** — p 값만 있나, 신뢰구간과 효과크기가 있나?
- 7. 다중성** — 몇 번 검정했나? 보정했나?
- 8. 강건성** — 민감도분석, E-value, 다른 방법으로도 확인했나?

마지막으로

이 강의의 진짜 목표는 통계를 외우는 것이 아니라, **인공지능이 만든 코드와 설명을 스스로 검증할 수 있는 사람**이 되는 것입니다.

인공지능은 문법적으로 완벽하고 그럴듯한 코드를 순식간에 만들어 줍니다. 그러나 “이 자료에 이 검정이 타당한가”, “이 계수를 이렇게 해석해도 되는가”, “이 숫자가 왜 논문과 다른가”는 답해 주지 못합니다.

그 판단이 이 자료가 다룬 전부입니다.