


표본이 커질수록 Wilcoxon 검정은 없는 차이를 찾아낸다

평균도 같고 중앙값도 같은 두 분포에서 표본을 뽑았는데, 표준편차만 10% 다르다. t 검정은 정직하게 5% 근처에서 기각한다. Wilcoxon 검정은 표본이 커질수록 기각률이 올라가 결국 거의 매번 "차이가 있다"고 말한다. 이번 과제는 이 현상을 R로 직접 만들어 보이고, 왜 이것이 오류가 아니라 다른 질문에 대한 정답 인지를 설명하는 일이다.



과제 지도

논문이 말하는 역설

통계 — 6가지 도구

독립 2표본 · Welch · 대응

Wilcoxon · 순열 · 효과크기

자료 — 무엇을 어떻게 생성하나

도표 — 네 그림이 답하는 질문

언어 — replicate와 재현성

검증 과제 ① Satterthwaite

검증 과제 ② 반례 구성

제출 전 점검

과제 지도

과제표의 여섯 소제목은 따로 노는 목적이 아니라, 하나의 재현 실험을 여섯 각도에서 자른 것이다.

소제목	이 과제에서 맡는 역할
통계	비교 대상 검정들. t 계열은 "평균이 같은가", WMW는 "무작위로 뽑은 한 값이 다른 쪽보다 작을 확률이 0.5인가"를 묻는다. 서로 다른 질문이라는 점이 실험의 전제다.
논문	재현 대상. 귀무가설이 참인 상황을 인위적으로 만들고, 표본크기를 키우며 각 검정의 기각률(=제1종 오류율)을 세는 구조.
자료	모의자료는 "정답을 아는" 실험실이고, NHANES는 "현실에서도 이 일이 일어나는가"를 확인하는 사례다.
도표	네 그림이 각각 가정 점검 → p값의 정체 → 추정의 언어 → 전체 결론의 순서를 담당한다.
언어	수만 번 반복하는 실험이라 반복 구조와 난수 통제가 곧 결과의 신뢰도다.
검증 과제	블랙박스로 쓰던 것을 직접 만들어 보는 두 문제. <code>t.test()</code> 의 자유도를 손으로 계산해 맞춰보고, WMW가 중앙값 검정이 아님을 반례로 증명한다.

논문이 말하는 역설

Fagerland의 관찰은 두 가지 추세가 동시에 일어났다는 것이다. 고영향 의학저널의 연구 표본크기는 1970년대 30명대에서 2000년대 3,000명대로 약 100배 커졌다. 그런데 같은 기간 t 검정 사용 비율은 44%에서 26%로 줄고 비모수 검정은 11%에서 27%로 늘었다.

이것이 역설인 이유는 이렇다. 비모수 검정을 t 검정의 대안으로 쓰는 이유는 정규성이 의심스럽기 때문인데, t 검정은 중심극한정리 덕분에 **표본이 커질수록** 정규성 위반에 강해진다. 반대로 WMW 검정은 표본이 커질수록 **위치 이외의 분포 차이**를 잡아내는 능력이 커진다. 그러니 연구가 커질수록 비모수 검정 비율은 줄어야 맞는데 실제로는 늘었다.

실험의 논리 구조

평균도 같고 중앙값도 같게 만들면, "평균 차이"와 "중앙값 차이"라는 두 귀무가설은 모두 참이다. 이 상태에서 기각이 일어나면 그것은 전부 제1종 오류다. 다만 표준편차를 조금 다르게 두면 WMW의 진짜 귀무가설인 $P(X < Y) = 0.5$ 는 **거짓**이 된다. 그래서 WMW의 높은 기각률은 오류가 아니라 검정력이며, 문제는 연구자가 그 결과를 "중앙값이 다르다"로 읽는다는 데 있다.

논문의 가장 강한 수치: 왜도 3인 감마분포 쌍에서 표준편차가 10%만 다르고 각 군 1,000명이면 WMW의 기각률은 99%, t 검정은 5.1%다. 같은 조건의 로그정규분포에서는 WMW 28%, t 검정 4.9%다. 표 5는 한 걸음 더 나간다 — 각 군 1,000명일 때 **WMW의 p값이 t 검정의 p값보다 작을 확률이 90%**다. p값을 쇼핑하면 비모수 검정이 이긴다는 뜻이다.

통계 — 6가지 도구

각 검정을 "무엇을 가정하고, 정확히 어떤 귀무가설을 검정하며, 이 과제에서 어떤 역할인지"로 정리한다.

독립 2표본 t 검정 (Student, 합동분산)

$$H_0 : \mu_1 = \mu_2$$

두 군의 분산이 같다고 믿고, 두 표본분산을 자유도로 가중평균한 합동분산 s_p^2 하나로 표준오차를 만든다.

$$s_p^2 = \frac{(n_1-1)s_1^2 + (n_2-1)s_2^2}{n_1 + n_2 - 2}, \quad t = \frac{\bar{x}_1 - \bar{x}_2}{s_p \sqrt{1/n_1 + 1/n_2}}, \quad df = n_1 + n_2 - 2$$

가정 세 가지는 독립성, 정규성, 등분산이다. 이 중 정규성은 표본이 커지면 깨져도 괜찮지만 등분산 위반은 표본을 키워도 저절로 낫지 않는다. 다만 **두 군의 크기가 같으면** 이분산에도 꽤 견고하다. 무너지는 것은 크기가 다를 때다.

이분산 정규분포 자료가 보여줄 패턴

작은 군이 큰 분산을 가지면 합동분산이 실제 표준오차를 과소추정해 t가 부풀고 **유의수준이 팽창**한다. 반대로 큰 군이 큰 분산을 가지면 **지나치게 보수적**이 된다. 격자도의 축을 표본크기비 $\times$ 표준편차비로 잡으면 이 두 방향이 대각선 대칭으로 나타난다.

Welch 검정

$$H_0 : \mu_1 = \mu_2 \text{ (등분산 가정 없음)}$$

한듯하지 않고 각 군의 분산을 각자의 표본크기로 나눠 더한다. 대신 $\sqrt{}$ 한의 부푸가 정확하

이것이 Satterthwaite 근사이자 검증 과제 ①이다. 분산이 다른 두 정규 모집단의 평균을 비교하는 문제를 Behrens-Fisher 문제라 부르고, Welch 검정은 그 실용적 해답이다.

$$t = \frac{\bar{x}_1 - \bar{x}_2}{\sqrt{(s_1^2/n_1 + s_2^2/n_2)}}$$

R의 `t.test()` 는 `var.equal = FALSE` 가 기본값이다. Fagerland가 논문 내내 "t 검정"이라 부른 것도 바로 이 Welch 검정이므로, 재현할 때 실수로 `var.equal = TRUE` 를 주면 안 된다.

대응 t 검정

$H_0 : \mu_d = 0$ (짝 차이의 평균)

짝지어진 관측치의 차이 $d_i = x_i - y_i$ 를 만들어 1표본 t 검정을 한다. 자유도는 $n - 1$. 짝 내 상관 ρ 가 양수이면 차이의 분산이 $\sigma_1^2 + \sigma_2^2 - 2\rho\sigma_1\sigma_2$ 로 줄어들어 독립 검정보다 검정력이 높다. 짝 구조를 무시하는 것은 정보를 버리는 일이다.

이번 실험에도 대응 구조가 숨어 있다

같은 난수 표본에 t 검정과 WMW를 둘 다 적용해 p값을 비교하면, 두 p값은 독립이 아니라 짝지어진 값이다. Fagerland의 표 5 "WMW의 p값이 더 작을 확률"이 바로 이 대응 비교다. 조건마다 동일한 표본을 쓰는 것을 공통난수(common random numbers)라 하며, 검정 간 차이를 훨씬 적은 반복으로 정확히 잡아낸다.

비모수 짝은 Wilcoxon 부호순위 검정이다. R에서는 `wilcox.test(x, y, paired = TRUE)`로, 독립 2표본용 순위합 검정과 같은 함수를 쓰지만 **완전히 다른 통계량**이다. 이름이 둘 다 "Wilcoxon"이라 혼동하기 쉬우니 보고서에는 순위합(rank sum) / 부호순위(signed rank)를 명시한다.

Wilcoxon 순위합 검정 (Mann-Whitney U)

$H_0 : P(X < Y) = 0.5$

이 한 줄이 과제 전체의 핵심이다. 흔히 "중양값 검정"이라고 배우지만 그것은 **두 분포가 위치만 다르고 모양과 퍼짐은 같다**는 추가 가정(위치이동 모형)이 성립할 때만 맞는 말이다. 그 가정이 없으면 WMW의 귀무가설은 위 확률 진술일 뿐이며, 중양값과는 직접 관계가 없다.

통계량은 두 군의 모든 쌍을 비교해 앞 군이 큰 쌍의 수를 센 U 이고, 순위합 W 와는 $W = U + n_1(n_1+1)/2$ 로 연결된다. 그리고 $U / (n_1n_2)$ 는 $P(X > Y)$ 의 불편추정량이다 — 즉 WMW는 "확률을 추정하는 검정"이다.

재현 시 반드시 고칠 것

`wilcox.test()` 는 표본이 작고 동점이 없으면 정확검정을, 크면 정규근사를 자동으로 고른다. 표본크기를 10부터 1000까지 훑는 격자 실험에서 이 자동 전환이 일어나면 기각률 곡선에 인위적인 계단이 생긴다. `exact = FALSE`, `correct = FALSE` 로 통일하고 그 선택을 보고서에 적는다. 속도도 크게 빨라진다.

순열검정

H_0 : 두 군의 분포가 동일하다 (교환가능성)

군 라벨을 무작위로 섞어 통계량을 다시 계산하기를 B번 반복해 귀무분포를 만들고, 관측 통계량이 그 분포의 어디쯤인지로 p값을 낸다. p값은 $(1 + \text{극단값 개수}) / (B + 1)$ 로 계산해 0이 나오지 않게 한다.

WMW는 사실 순열검정이다

순위로 바꾼 뒤 라벨을 섞는 순열검정이 곧 WMW다. 그래서 WMW의 귀무가설이 "분포 동일"에 가깝고, 퍼짐의 차이에 반응하는 것이 자연스럽다. 같은 이유로 **평균**

차이를 보려고 원자료에 순열검정을 쓰는 것도 이분산 상황에서는 타당하지 않다.
해결책은 평균차 대신 Welch 통계량을 치환하는 스튜던트와 순열검정이다. 이 사실을
보고서에 넣으면 "비모수면 안전하다"는 통념을 정면으로 반박하는 좋은 논거가 된다.

효과크기

p값은 표본크기에 따라 얼마든지 작아지지만 효과크기는 그렇지 않다. 이 과제에서
효과크기는 장식이 아니라 **검증 도구**다.

Cohen's $d = (\bar{x}_1 - \bar{x}_2) / s_p$

합동표준편차 기준. 소표본에서 과대추정되므로 Hedges' $g = d \cdot (1 - 3/(4N - 9))$ 로 보정한다.

Glass's Δ

대조군 표준편차만으로 나눈다. 두 군의 분산이 다를 때 합동분산이 의미를 잃으므로 이 과제의
이분산 자료에 적합하다.

Cliff's $\delta = P(X > Y) - P(X < Y)$

순위이연 상관계수와 같고, U 로부터 $\delta = 2U/(n_1n_2) - 1$ 로 바로 계산된다. **WMW의 귀무가설은
정확히 $\delta = 0$ 이다.**

공통언어 효과크기 **CLES** = $P(X < Y)$

"한 군에서 아무나 뽑고 다른 군에서 아무나 뽑았을 때 앞이 작을 확률". 비전공자에게 가장
설명하기 쉬운 지표다.

Fagerland 표 2의 정제

논문 표 2는 각 시나리오의 참 $P(X < Y)$ 를 나열한 것, 곧 **모집단 CLES** 표다. 자료를
생성한 뒤 아주 큰 표본으로 $P(X < Y)$ 를 직접 추정해 표 2와 맞춰보면, 내 분포 구성이
논문 조건을 제대로 재현했는지 검증 전에 확인할 수 있다. 재현 작업의 가장 좋은
자가검증이다.

자료 — 무엇을 어떻게 생성하나

모의자료 두 종류와 실제자료 한 종류. 각각 답하는 질문이 다르다.

이분산 정규분포 — 가정 위반의 기준선

정규성은 완벽하고 등분산만 깨진 자료다. 여기서는 Student t와 Welch t의 차이만
순수하게 드러난다. 격자 축은 표본크기비와 표준편차비로 잡는다.

```
# 귀무가설이 참(평균 동일)인데 분산만 다른 두 정규 모집단
sim1 <- function(n1, n2, sd1, sd2) {
  x <- rnorm(n1, 0, sd1); y <- rnorm(n2, 0, sd2)
  c(student = t.test(x, y, var.equal = TRUE)$p.value,
    welch   = t.test(x, y, var.equal = FALSE)$p.value,
    wmw     = wilcox.test(x, y, exact = FALSE, correct = FALSE)$p.value)
}
set.seed(2026)
p <- replicate(10000, sim1(n1 = 10, n2 = 40, sd1 = 3, sd2 = 1))
rowMeans(p < 0.05)  # 작은 군이 큰 분산 → student가 5%를 크게 넘는다
```

로그정규분포 — 치우침의 표준 모형

중성지방, CRP, 입원일수, 소득처럼 생의학·사회 자료의 오른쪽 치우친 변수를 대표한다.
모수와 특성의 관계를 외워두면 분포를 설계할 수 있다.

중앙값 = e^μ · 평균 = $e^{\mu+\sigma^2/2}$ · 표준편차 = $e^{\mu+\sigma^2/2}\sqrt{(e^{\sigma^2}-1)}$ · 왜도 = $(e^{\sigma^2}+2)\sqrt{(e^{\sigma^2}-1)}$

왜도가 σ 하나로 정해진다는 점이 중요하다. 즉 모수가 두 개뿐인 로그정규분포로는 평균·
중앙값·표준편차·왜도를 동시에 지정할 수 없다.

재현의 진짜 난관: 평균·중앙값은 같고 표준편차만 다른 치우친 분포

논문은 "평균과 중앙값과 왜도는 같고 표준편차만 다르다"고 서술한다. 그런데 제약을 세어보면 맞춰야 할 값이 네 개(평균, 중앙값, 표준편차, 왜도)인데 로그정규는 모수가 두 개, 위치를 평행이동시킨 편이 로그정규도 세 개다. 자유도가 모자라므로 **세 모수 쪽 안에서는 네 조건을 동시에 만족시킬 수 없다**. 논문 본문만으로는 정확한 구성이 복원되지 않는 지점이고, 재현 보고서에서 반드시 짚고 넘어가야 할 부분이다.

실용적 해법은 **평균·중앙값·표준편차 세 개를 정확히 맞추고 왜도는 결과로 받아들이는** 것이다. 귀무가설(평균 동일, 중앙값 동일)은 정확히 성립하므로 논문의 논지를 재현하는 데 아무 문제가 없다. 편이 로그정규 $W = \gamma + \exp(\mu + \sigma Z)$ 를 쓰면 세 모수 세 방정식이라 수치적으로 풀린다.

```
# 목표 평균·중앙값·표준편차를 갖는 편이 로그정규의 모수 찾기
fit_slnorm <- function(m, med, s) {
  obj <- function(par) {
    A <- exp(par[1]); sig <- exp(par[2]); k <- exp(sig^2 / 2)
    gam <- med - A # 중앙값 조건으로 이동량 결정
    (gam + A * k - m)^2 + (A * k * sqrt(exp(sig^2) - 1) - s)^2
  }
  o <- optim(c(0, -0.5), obj, method = "BFGS")
  A <- exp(o$par[1]); sig <- exp(o$par[2])
  list(gamma = med - A, meanlog = log(A), sdlog = sig, value = o$value)
}
```

SD 비	Y의 γ	Y의 meanlog	Y의 sdlog	Y의 표준 편 차	Y의 왜 도
기준 X	0	0	0.71557	1.0563	3.00
1.05	-0.2323	0.2098	0.6519	1.1091	2.57
1.10	-0.4620	0.3796	0.6033	1.1620	2.28
1.15	-0.6945	0.5274	0.5637	1.2148	2.06
1.20	-0.9326	0.6590	0.5303	1.2676	1.89

기준 분포 X를 중앙값 1, 평균 1.2918, 왜도 3(표준 로그정규, $\sigma=0.71557$)으로 두고, 평균·중앙값을 유지한 채 표준편차만 키운 짝 Y. 수치 해를 직접 확인한 결과다.

이 표 자체가 하나의 발견이다. 평균과 중앙값을 고정하면 **덜 치우친 쪽이 더 큰 표준편차를 갖는다**. 평균과 중앙값의 간격이 같아야 하는데 왜도가 낮으면 그 간격을 만들기 위해 퍼짐이 더 커져야 하기 때문이다. 보고서에서 "왜도를 동일하게 유지할 수 없었던 이유"를 이 논리로 설명하면 된다.

NHANES — 현실 자료로의 이전

2주차에서 다룬 NHANES 변수 중 오른쪽으로 크게 치우친 것(예: 중성지방, CRP, BMI)을 두 군(성별, 흡연 여부 등)으로 나눠 같은 검정들을 적용한다. 여기서 핵심 질문은 "이 자료에서 t 검정과 WMW의 p값이 얼마나 벌어지는가, 그리고 표본을 무작위로 줄이면 그 격차가 어떻게 변하는가"다.

NHANES 고유의 함정

NHANES는 단순임의표본이 아니라 층화·군집 복합표본설계이고 표본가중치가 달려 있다. 엄밀한 모집단 추론은 `survey` 패키지의 설계 기반 검정이 필요하다. 이 과제의 목적이 검정 간 비교라면 단순 비교로도 되지만, **그 한계를 명시**해야 한다. 결측 처리 방식(`na.rm` , 완전사례 분석)도 반드시 기록한다.

도표 — 네 그림이 답하는 질문

가정 점검 → p값의 정체 → 추정의 언어 → 전체 결론. 네 도표는 이 순서를 이룬다.

군별 Q-Q plot

각 군의 표본 분위수를 정규분포 이론 분위수와 맞대어 그린다. 직선에서 벗어나는 방향이 정보다 — 오른쪽 끝이 위로 휘면 오른쪽 치우침, 양끝이 모두 바깥으로 벌어지면 두꺼운 꼬리다. **두 군을 반드시 따로** 그려야 분산 차이가 기울기 차이로 보인다.

정규성 검정을 쓰지 않는 이유

논문이 명시적으로 반대하는 관행이 "Shapiro-Wilk로 정규성을 검정해 t 검정과 비모수 검정 중 고르기"다. 대표본에서 정규성 검정은 실질적으로 무해한 이탈에도 유의해지므로, 표본이 클수록 t 검정을 쓰지 말라고 권고하게 된다 — 정확히 거꾸로다. 그래서 이 과제는 검정이 아니라 **그림으로** 정규성을 본다.

재표본 분포

순열로 만든 귀무분포, 또는 부트스트랩으로 만든 통계량의 표본분포를 히스토그램으로 그리고 관측 통계량을 수직선으로 얹는다. 보여주는 것은 두 가지다. 첫째, p값은 결국 이 분포의 꼬리 면적이라는 기하학적 사실. 둘째, 원자료가 아무리 치우쳐도 **평균치의 분포는 표본이 커질수록 종모양에 가까워진다는** 중심극한정리의 작동 — t 검정이 견고한 이유를 한 장으로 설명하는 그림이다.

신뢰구간 병치도

같은 자료에 대해 Student / Welch / 부트스트랩 / 순열 기반 구간을 세로로 나란히 놓는다. 점은 추정치, 가로선은 구간, 0 위치에 기준선을 긋는다. 비교 포인트는 구간의 중심이 아니라 **폭**이다.

WMW는 이 그림에 자연스럽게 들어오지 않는다

`wilcox.test(conf.int = TRUE)` 가 주는 것은 평균차가 아니라 Hodges-Lehmann 추정량 (두 군 간 모든 차이의 중앙값)의 구간이다. 축이 다르므로 같은 그림에 얹으려면 주석이 필요하다. 이 불일치 자체가 논문의 메시지다 — t 검정은 검정과 구간추정이 같은 표준오차를 공유하지만, WMW는 "그래서 얼마나 다른데?"에 같은 언어로 답하지 못한다.

제1종 오류율 격자도

최종 결론 도표다. x축 왜도, y축 표준편차비, 칸의 색은 기각률, 면 분할은 표본크기 × 검정 종류. 색 눈금은 5%에서 꺾이도록 발산형 팔레트를 쓰고 중립점을 0.05에 둔다 — 그래야 "5% 위/아래"가 한눈에 보인다. 논문 표 3·표 4의 재현물이다.

```
grid <- expand.grid(n = c(10, 25, 50, 100, 250, 500, 1000),
                    sd_ratio = c(1.05, 1.10, 1.15, 1.20, 1.25, 1.30, 1.40, 1.50),
                    skew = c(1, 2, 3, 4))
# 칸마다 B회 반복 → 기각률. 448칸 × 10,000회이므로 함수 오버헤드를 줄여야 한다.
```

언어 — replicate와 재현성

반복 구조

`replicate(B, expr)` 는 표현식을 B번 평가해 결과를 단순화한다. 스칼라를 반환하면 길이 B 벡터, 길이 k 벡터를 반환하면 $k \times B$ 행렬이 된다(반복이 열 방향). 그래서 검정 세 개의 p값을 한 번에 반환하도록 짜면 `rowMeans(p < 0.05)` 한 줄로 기각률이 나온다. `simplify = FALSE` 를 주면 리스트가 된다.

시드 고정과 재현성

```
set.seed(2026)
```

```
# 기본 Mersenne-Twister
```

```
RNGkind("L'Ecuyer-CMRG"); set.seed(2026) # 병렬 계산을 할 경우
# parallel::clusterSetRNGStream(cl, 2026) 또는 future.apply(..., future.seed = TRUE)
sessionInfo() # R 패키지 버전을 결과 파일과 함께 저장
```

mcLapply 나 foreach 로 병렬화하면서 set.seed() 만 부르면 재현되지 않거나
작업자끼리 난수가 겹친다. 반드시 스트림 기반 난수(L'Ecuyer-CMRG)를 쓴다.

시드를 어디에 두느냐가 결론을 바꾼다

격자의 각 칸마다 시드를 새로 고정하면 조건 간 난수가 공통이 되어(공통난수)
검정끼리의 비교 분산이 줄고, "WMW $p < t$ p " 같은 대응 비교가 훨씬 안정된다. 반면
전체 루프 앞에서 한 번만 고정하면 칸마다 독립 표본이 된다. 둘 다 타당하지만 어느
쪽을 썼는지 보고해야 다른 사람이 같은 숫자를 얻는다.

몬테카를로 표준오차

$$SE = \frac{\sqrt{p(1-p)}}{\sqrt{B}} \rightarrow p=0.05, B=10,000 \text{ 이면 } SE \approx 0.00218$$

즉 4.8%와 5.2%는 사실상 구별되지 않는다. 기각률을 소수 첫째 자리까지만 보고하고,
격자도에는 이 불확실성을 캡션에 적는다. 10,000회 반복은 이 정밀도를 얻기 위한 숫자다.

속도

448개 시나리오 $\times$ 10,000회 = 448만 번의 검정이다. t.test() 는 formula 처리·클래스
생성 등 부대비용이 커서 수치만 필요한 모의실험에는 낭비다. 통계량을 직접 계산하면 10배
이상 빨라진다.

```
welch_p <- function(x, y) {
  n1 <- length(x); n2 <- length(y)
  a <- var(x) / n1; b <- var(y) / n2
  tt <- (mean(x) - mean(y)) / sqrt(a + b)
  df <- (a + b)^2 / (a^2 / (n1 - 1) + b^2 / (n2 - 1))
  2 * pt(-abs(tt), df)
}
# 중간 결과는 saveRDS()로 캐시 - 도표를 고칠 때마다 재계산하지 않는다
```

① 검증 과제 · Satterthwaite 자유도

목표: t.test() 가 출력하는 소수점 자유도를 손으로 계산해 완전히 일치시키는 것.

왜 소수점 자유도가 나오는가

Welch 통계량의 분모 안에 있는 $s_1^2/n_1 + s_2^2/n_2$ 는 자유도가 다른 두 χ^2 변수의 가중합이라
 χ^2 분포를 따르지 않는다. Satterthwaite의 아이디어는 이것을 $c \cdot \chi^2/v$ 하나로 근사하되,
근사 분포의 평균과 분산이 원래 것과 같아지도록 c 와 v 를 정하는 것이다(적률 적합). 그
결과 v 가 정수가 아니게 된다.

$$v = \frac{(s_1^2/n_1 + s_2^2/n_2)^2}{(s_1^2/n_1)^2 / (n_1-1) + (s_2^2/n_2)^2 / (n_2-1)}$$

분모가 각 항의 제곱을 자기 자유도로 나눈 합이라는 구조를 기억하면 공식을 외울 필요가
없다.

반드시 함께 검증할 성질

- 범위: $\min(n_1, n_2) - 1 < v < n_1 + n_2 - 2$

- 한쪽 분산이 압도적으로 크면 v 는 그 군의 자유도 $n - 1$ 로 수렴한다 — 사실상 1표본 검정이 된다.
- $n_1 = n_2$ 이고 $s_1 = s_2$ 이면 $v = n_1 + n_2 - 2$ 로 Student와 일치한다.
- v 는 **표본분산에 의존**하므로 확률변수다. 같은 설계라도 표본마다 자유도가 달라진다.

```
welch_df <- function(x, y) {
  n1 <- length(x); n2 <- length(y)
  a <- var(x) / n1; b <- var(y) / n2
  (a + b)^2 / (a^2 / (n1 - 1) + b^2 / (n2 - 1))
}

# 여러 설계에서 t.test()와 완전 일치하는지 확인
set.seed(11)
chk <- do.call(rbind, lapply(1:200, function(i) {
  n1 <- sample(5:80, 1); n2 <- sample(5:80, 1)
  x <- rnorm(n1, 0, runif(1, 0.2, 6)); y <- rnorm(n2, 0, runif(1, 0.2, 6))
  c(mine = welch_df(x, y), R = unname(t.test(x, y)$parameter),
    lo = min(n1, n2) - 1, hi = n1 + n2 - 2)
}))
max(abs(chk[, "mine"] - chk[, "R"]))          # 1e-12 수준이어야 한다
all(chk[, "mine"] >= chk[, "lo"] & chk[, "mine"] <= chk[, "hi"]) # TRUE
```

자유도만 맞추지 말고 **p값까지 복원**해서 `t.test()`\$p.value 와 비교하면 검증이 완결된다.
 양측 p값은 $2 * pt(-abs(t), df)$ 다. 여기까지 일치하면 Welch 검정을 블랙박스가 아니라 직접 구현한 것이 된다 — 격자 실험의 속도 문제도 이 함수로 해결된다.

② 검증 과제 · 중앙값이 같은데 유의한 반례

두 단계로 구성하면 설득력이 가장 높다. 먼저 극단적 최소 반례로 원리를 보이고, 그다음 논문형 반례로 역설을 재현한다.

왜 반례가 존재하는가

WMW가 실제로 검정하는 것은 $P(X < Y) = 0.5$ 다. 중앙값이 같다는 것은 각 분포가 **자신의 중앙값을 기준으로 반씩 나뉜다**는 뜻일 뿐, 두 분포를 **서로** 비교했을 때의 확률과는 다른 조건이다. 따라서 중앙값을 같게 고정한 채 나머지 모양을 비틀면 $P(X < Y)$ 를 얼마든지 0.5에서 떼어놓을 수 있다.

반례 A · 최소 구성 (원리 증명)

각 분포의 절반을 0 아래, 절반을 0 위에 두면 중앙값은 **정확히 0**으로 같다. 그 상태에서 한쪽은 위로 길게, 다른 쪽은 아래로 길게 꼬리를 둔다.

```
rX <- function(n) ifelse(runif(n) < 0.5, runif(n, -1, 0), runif(n, 0, 10))
rY <- function(n) ifelse(runif(n) < 0.5, runif(n, -10, 0), runif(n, 0, 1))

set.seed(7)
a <- rX(2e6); b <- rY(2e6)
median(a); median(b)      # 둘 다 0
mean(a < b)               # P(X < Y) ≈ 0.275
```

참값은 손으로도 계산된다. 네 조합에 각각 1/4의 확률이 걸리고 $0.25 \cdot 0.75 \dots$ 가 아니라 $0.25 \cdot 1 + 0.25 \cdot 0.05 + 0.25 \cdot 0 + 0.25 \cdot 0.05 = \mathbf{0.275}$ 다. Cliff's $\delta = 0.45$ 로 큰 효과다. 실제로 각 군 20명만 있어도 WMW가 약 71% 기각한다.

이 반례의 한계를 스스로 지적하라

반례 A는 중앙값은 같지만 평균이 2.25와 -2.25로 크게 다르다. 그래서 t 검정도 거의 100% 기각한다. "WMW는 중앙값 검정이 아니다"는 증명했지만, "t는 옳고 WMW만 틀렸다"는 역설은 아직 보이지 못한다. 그 역설에는 평균까지 같아야 한다.

반례 B · 논문형 구성 (역설 재현)

앞서 만든 편이 로그정규 쌍을 쓴다. 평균 1.2918, 중앙값 1이 두 분포에서 정확히 같고 표준편차만 10% 다르다. 평균 차이와 중앙값 차이라는 두 귀무가설이 모두 참이므로, 모든 기각은 제1종 오류로 해석할 여지가 있다.

```
# X: 중앙값 1, 평균 1.29176, SD 1.05633, 왜도 3.00
rX <- function(n) rlnorm(n, meanlog = 0, sdlog = 0.71557)
# Y: 중앙값 1, 평균 1.29176, SD 1.16215(=1.10배), 왜도 2.28
rY <- function(n) -0.46200 + rlnorm(n, meanlog = log(1.46200), sdlog = 0.60330)

set.seed(20260920)
sim <- function(n) c(
  welch = t.test(rX(n), rY(n))$p.value,
  wmw = wilcox.test(rX(n), rY(n), exact = FALSE, correct = FALSE)$p.value)
# 실제 재현에서는 같은 표본을 두 검정에 함께 넣어야 한다(공통난수)
```

각 군 관측치 수	Welch t	Wilcoxon
25	4.3%	5.4%
50	4.5%	6.8%
100	5.0%	6.9%
250	4.9%	10.2%
500	5.7%	16.7%
1000	5.1%	30.0%

위 구성으로 각 군 n개씩, 2,000회 반복한 5% 기각률. $P(X < Y) = 0.4824$ 로 0.5에서 겨우 0.018 떨어져 있을 뿐인데, 표본이 커지면 WMW가 그 미세한 차이를 확실하게 잡아낸다.

이 표가 그대로 논문 그림 3의 구조다. Welch는 표본크기와 무관하게 5% 근처에 머물고, WMW는 단조 증가한다. 왜도를 3보다 키우거나 표준편차비를 1.10보다 벌리면 상승은 훨씬 가팔라져 논문의 99%에 접근한다. 격자도를 그릴 때 이 두 축을 넓게 잡는 이유다.

결론을 쓰는 방식

"WMW가 틀렸다"고 쓰면 안 된다. WMW는 $P(X < Y) = 0.5$ 라는 자기 귀무가설을 정확히 검정했고, 그 가설은 실제로 거짓이었다. 그러므로 30%는 오류율이 아니라 검정력이다. 틀린 것은 검정이 아니라, 그 p값을 "중앙값이 다르다"로 번역한 해석이다. 대표본에서는 t 검정이 치우침에 충분히 견고하므로, 평균을 비교하려면 t 검정과 그 신뢰구간을 쓰는 것이 옳다. 비모수 검정은 소표본과 순서형 자료에서 가장 유용하다.

제출 전 점검

- t.test() 의 var.equal 기본값이 FALSE 임을 알고 의도적으로 선택했는가.
- wilcox.test() 의 정확검정/근사 전환을 exact = FALSE, correct = FALSE 로 고정했는가.
- 순위합 검정과 부호순위 검정을 보고서에서 구분해 불렀는가.
- 분포 구성 후 $P(X < Y)$ 를 대표본으로 추정해 의도한 값과 맞는지 검정 전에 확인했는가.
- 왜도를 동일하게 맞추지 못한 이유(제약 4개 > 모수 3개)를 명시했는가.
- 기각률을 몬테카를로 표준오차(10,000회에서 약 0.22%p)와 함께 제시했는가.
- 시드를 루프 밖에 한 번 고정했는지, 칸마다 고정했는지 기록했는가.
- 병렬 처리를 했다면 스트림 기반 난수를 썼는가.

- NHANES 분석에 복합표본설계와 결측 처리에 대한 단서를 달았는가.
- Satterthwaite 구현이 자유도뿐 아니라 p값까지 `t.test()` 와 일치하는가.

참고: Fagerland MW. t-tests, non-parametric tests, and large studies—a paradox of statistical practice? BMC Medical Research Methodology 2012;12:78. 표에 실린 재현 수치는 본 자료를 만들며 직접 모의실험으로 확인한 값으로, 난수 시드와 반복 횟수에 따라 소수점 수준에서 달라질 수 있다.